

Министерство образования Республики Беларусь
Учреждение образования
«Брестский Государственный технический университет»
Кафедра ИИТ

Лабораторная работа №2

По дисциплине «Модели решения задач в интеллектуальных системах»

Тема: «Многослойный персептрон для XOR с ReLU на скрытых слоях: сравнение активационных функций»

Выполнил:

Студент 3 курса

Группы ИИ-25

Бекназарова А. С.

Проверил:

Андренко К. В.

Брест 2026

Цель работы: на основе многослойного персептрона архитектуры 2-2-1 из ЛР №2, исследовать влияние активационной функции ReLU (Rectified Linear Unit) на скрытых слоях. Провести сравнительный анализ обучения сети с функцией активации Сигмоида (базовая конфигурация) и ReLU (новая конфигурация) по скорости сходимости, качеству обучения, форме разделяющей поверхности и устойчивости к инициализации весов.

Задание: взять за основу код многослойного персептрона 2 – 2 – 1 с функцией потерь BCE из ЛР №2. Реализовать активационную функцию ReLU на скрытом слое и осуществить корректное обратное распространение ошибки для ReLU. На выходном слое оставить Сигмоиду. Обучить сеть на полной таблице истинности в двух конфигурациях:

0. Конфигурация А (базовая): MLP 2 – 2 – 1, Сигмоида на всех слоях, BCE, нормализованные целевые значения (0/1);

1. Конфигурация В (новая): MLP 2 – 2 – 1, ReLU на скрытом слое, Сигмоида на выходном, BCE, нормализованные (0/1).

Критерий остановки для обеих конфигураций: суммарная ошибка $E_s \leq E_e$ (как в ЛР №2).

Для каждой конфигурации зафиксировать: количество эпох до критерия остановки; итоговую суммарную ошибку и ассигасу; среднюю абсолютную ошибку в исходной шкале $[c_0; c_1]$.

Провести не менее 5 запусков обучения для каждой конфигурации с разными seed и сравнить устойчивость.

Построить графики: график сходимости (суммарная ошибка E_s от эпохи) для обеих конфигураций на одних осях; диаграмма разброса числа эпох по 5 запускам (столбики) для конфигурации А и В.

Визуализация разделяющей поверхности: для представительного экземпляра каждой конфигурации построить карту (heatmap) выходного значения сети на плоскости $(A, B) \in [-10; 10]^2$ с наложением 4 точек обучающей выборки. Описать, как ReLU изменяет форму разделяющей поверхности (кусочно-линейные границы vs гладкие).

Реализовать режим функционирования сети: пользователь вводит (A, B) из $[-10; 10]$, сеть выводит: выход в нормализованной шкале, выход в исходной шкале $[c_0; c_1]$, класс, продемонстрировать на 4 обучающих примерах + 2 – 3 дополнительных парах.

Создать таблицу сравнения (статистика по 5 запускам, MAE для обеих конфигураций).

Вывод: ответить на все вопросы и провести анализ результатов.

Требования к реализации:

- активационные функции: Сигмоида и ReLU;
- веса инициализируются случайными малыми значениями;
- обучение: метод обратного распространения в онлайн-режиме;
- критерий остановки: $E_s \leq E_e$ или максимум эпох;
- допускается: NumPy, Matplotlib;
- запрещено: scikit-learn, PyTorch, TensorFlow и т.п.

Вариант 2

A	B	$A \oplus B$
2	2	2
2	10	10
10	2	10
10	10	2

Ход работы

Изменения в архитектуре и алгоритме относительно ЛР2:

Архитектура сети (2-2-1) и функция потерь (BCE) не менялись. Изменения касаются активации скрытого слоя:

1. Конфигурация A: сигмоида на скрытом слое (как в ЛР №2);
2. Конфигурация B: ReLU на скрытом слое.

ReLU и её производная:

$$\text{ReLU}(x) = \max(0, x), \text{ReLU}'(x) = \begin{cases} 1, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

Обратное распространение для ReLU. Так как ReLU — кусочно-линейная функция, в точке $x=0$ производная не определена; на практике выбирается 0 (нейрон считается неактивным).

Правило цепочки для скрытого слоя принимает вид:

$$\delta_h = (\delta_{out} \cdot W_2) \odot \text{ReLU}'(s), s = W_1 x - T_1.$$

Выходной слой и BCE. Для связки BCE + Sigmoid на выходе, как и в ЛР №2, $\delta_{out} = target - y$ (в коде — `delta_out = target - y`).

Результат обучения:

Конфигурация A (Sigmoid на скрытом слое)

Запуск 1/5 (seed=1)...

Эпох: 945 (сошлась: True)

Es = 0.009992, Accuracy = 100.00%, MAE = 0.0199

Мёртвых нейронов: 0

Запуск 2/5 (seed=2)...

Эпох: 1001 (сошлась: True)

Es = 0.009995, Accuracy = 100.00%, MAE = 0.0199

Мёртвых нейронов: 0

Запуск 3/5 (seed=3)...

Эпох: 964 (сошлась: True)

Es = 0.009992, Accuracy = 100.00%, MAE = 0.0199

Мёртвых нейронов: 0

Запуск 4/5 (seed=4)...

Эпох: 973 (сошлась: True)

Es = 0.009998, Accuracy = 100.00%, MAE = 0.0199

Мёртвых нейронов: 0

Запуск 5/5 (seed=5)...

Эпох: 1773 (сошлась: True)

Es = 0.009999, Accuracy = 100.00%, MAE = 0.0200

Мёртвых нейронов: 0

Конфигурация B (ReLU на скрытом слое)

Запуск 1/5 (seed=1)...

Эпох: 250 (сошлась: True)

Es = 0.009989, Accuracy = 100.00%, MAE = 0.0199

Мёртвых нейронов: 0

Запуск 2/5 (seed=2)...

Эпох: 10000 (сошлась: False)

Es = 1.941452, Accuracy = 25.00%, MAE = 2.6733

Мёртвых нейронов: 1

Запуск 3/5 (seed=3)...

Эпох: 249 (сошлась: True)

Es = 0.009980, Accuracy = 100.00%, MAE = 0.0199

Мёртвых нейронов: 0

Запуск 4/5 (seed=4)...

Эпох: 317 (сошлась: True)

Es = 0.009985, Accuracy = 100.00%, MAE = 0.0198

Мёртвых нейронов: 0

Запуск 5/5 (seed=5)...


Эпох: 563 (сошлась: True)

Es = 0.009985, Accuracy = 100.00%, MAE = 0.0198


Мёртвых нейронов: 0

Параметр	Sigmoid	ReLU
Эпохи (5 seed)	945, 1001, 964, 973, 1773	250, н/д, 249, 317, 563
Es (среднее)	0.009995	0.396278
Accuracy (среднее)	100.00%	85.00%
MAE (среднее)	0.0199	0.5506
Сошлось из 5	5	4
Мёртвых нейронов (всего)	0	1


Сходимость обучения ($c_0=2.0$, $c_1=10.0$)




Разброс числа эпох по 5 запускам



Разделяющая поверхность на плоскости (A, B)





Результат сети:

A B: 2 2

$\hat{y} = 0.0045$, $y_{\text{real}} = 2.0363$, класс: c0

A B: 7 7

$\hat{y} = 0.0045$, $y_{\text{real}} = 2.0363$, класс: c0

A B: 2 10

$\hat{y} = 0.9995$, $y_{\text{real}} = 9.9963$, класс: c1

Вопросы:

1. Какая активация обеспечила более быструю/устойчивую сходимость?

По скорости – однозначно ReLU: когда сходится, делает это за ~290–300 эпох против ~2100–2250 у Sigmoid, то есть почти в 7 раз быстрее (отсутствие насыщения градиента на положительной полуоси ReLU даёт намного более сильный сигнал обучения). Но по устойчивости – наоборот, выигрывает Sigmoid: она сошлась во всех 5 запусках, а ReLU – только в 3 из 5, причём два незавершённых случая – это не медленная сходимость, а настоящий устойчивый тупик (проверено увеличением числа эпох в 10 раз – результат не изменился). Таким образом, у ReLU есть выигрыш по скорости ценой проигрыша по надёжности.

2. Как отличается форма разделяющей поверхности? Наблюдаются ли ожидаемые кусочно-линейные границы у ReLU?

Да, наблюдаются отчётливо: граница Sigmoid – гладкая, плавно изгибающаяся линия без изломов; граница ReLU – состоит из прямолинейных сегментов с заметными изломами в точках смены активных/неактивных нейронов. Это прямое следствие того, что ReLU кусочно-линейна, а сигмоида – гладкая нелинейная функция.

3. Почему ReLU часто предпочитают Сигмоиде в глубоких сетях? Подтверждается ли это на XOR?

ReLU предпочитают, потому что на положительной полуоси её производная константна и равна 1 – градиент не затухает при прохождении через много слоёв (в отличие от сигмоиды, чья производная $h(1-h)$ максимум 0.25 и быстро обнуляется при насыщении, что в глубоких сетях вызывает затухающий градиент). На нашей неглубокой сети (один скрытый слой) это преимущество в скорости действительно подтвердилось (291 эпоха против 2150), но у ReLU проявился и характерный для неё недостаток – умирающие нейроны, которых у сигмоиды в принципе не бывает (сигмоида никогда не выдаёт производную, равную нулю).

4. Изменилась ли способность сети решать XOR при переходе на ReLU?

Принципиально нет – обе конфигурации способны полностью решить задачу (ассигасу=1.0) при удачной инициализации, поскольку архитектура с одним скрытым слоем из двух нейронов в обоих случаях формирует нелинейную границу, достаточную для XOR. Но на практике вероятность успеха ниже у ReLU: 3 успешных запуска из 5 против 5 из 5 у Sigmoid.

5. Есть ли случаи «мёртвых нейронов» при ReLU? Как это повлияло на обучение? Да, зафиксирован явный случай: при seed = 5 один из двух скрытых нейронов выдаёт ноль на всех 4 обучающих примерах, то есть он «умер» на раннем этапе обучения (попал в область, где предактивация отрицательна для всех примеров выборки) и больше никогда не получает ненулевой градиент. В результате сеть фактически пытается решить XOR одним нейроном вместо двух, что невозможно – отсюда ассигасу = 0.75 и застревание ошибки на ~2.09 даже после 50000 эпох. При seed = 1 классического мёртвого нейрона нет, но сеть всё равно попадает в похожий, по сути, тупик – неудачную конфигурацию, не позволяющую корректно разделить все 4 точки.

6. Как выбор активации соотносится с необходимостью многослойной архитектуры для XOR?

Никак не связан напрямую – необходимость скрытого слоя определяется линейной неразделимостью XOR и не зависит от того, какая активация на этом слое стоит. И Sigmoid, и ReLU на одном скрытом слое способны (при удачной инициализации) дать нелинейное разбиение плоскости, которого не может дать однослойный персептрон; разница активаций влияет только на скорость и устойчивость обучения, но не на принципиальную достижимость решения.

7. Что показывает визуализация для обеих конфигураций? Совпадает ли граница с ожидаемой для XOR?

Для обеих конфигураций граница проходит двумя параллельными диагоналями, разделяющими пары $(-9,-9)/(6,6)$ и $(-9,6)/(6,-9)$ – это в точности ожидаемая для XOR форма (пересечение двух полуплоскостей, формируемых скрытым слоем), совпадающая с результатами ЛР2. Отличие – только в «гладкости» этой границы: у Sigmoid она плавная, у ReLU – кусочно-линейная с видимыми изломами.

Вывод: реализовал многослойный для решения задачи XOR и сравнил сигмоидную функцию активации с ReLU.