Министерство образования Республики Беларусь

Учреждение образования

«Брестский Государственный технический университет»

Кафедра ИИТ

Лабораторная работа №4

По дисциплине «Модели решения задач в интеллектуальных системах»

Тема: «Многослойный персептрон для прогнозирования временного ряда: влияние размера окна и числа скрытых нейронов»

Выполнил:

Студент 3 курса

Группы ИИ-25

Бекназарова А. С.

Проверил:

Андренко К. В.

Брест 2026

Цель работы: на основе многослойного персептрона p–N–1 решить задачу прогнозирования временного ряда. Научиться формировать обучающую выборку методом скользящего окна, нормализовать данные, оценивать качество одношагового и многошагового прогноза и исследовать влияние размера окна p и числа нейронов скрытого слоя N на точность прогноза и скорость обучения.

Задание: сгенерировать ряд по формуле варианта и построить его график с отметкой границы между обучающим и тестовым участками. Нормализовать ряд по минимуму и максимуму обучающего участка: x_norm = (x - x_min) / (x_max - x_min). Записать формулу обратного пересчёта и использовать её при вычислении всех метрик в исходной шкале. Объяснить, почему min/max нельзя брать по всему ряду. Сформировать обучающую и тестовую выборки методом скользящего окна размера p (вход – p значений, цель – следующее значение). Указать количество получившихся примеров в каждой выборке. Реализовать многослойный персептрон p – N – 1: скрытый слой – сигмоида; выходной слой – линейный (задача регрессии), f(s) = s; функция потерь – MSE; обучение – онлайн-режим, перемешивание порядка примеров в каждой эпохе; вывести формулы градиентов для линейного выходного слоя и сигмоидного скрытого слоя и привести их в отчёте. Критерий остановки: средняя по обучающей выборке ошибка $E_s \le E_e$, где $E_e = 10^{-4}$ (нормализованная шкала), либо достижение 20 000 эпох. Скорость обучения подобрать самостоятельно из диапазона 0.01 – 0.3 и обосновать выбор. Базовый эксперимент. Обучить сеть с параметрами p и N из своего варианта. Зафиксировать число эпох, итоговую Es, а также метрики на обучающем и тестовом участках в исходной шкале: MAE, RMSE и MAPE (если ряд проходит через ноль – вместо MAPE использовать sMAPE, и пояснить почему). Исследование окна. При фиксированном N из варианта обучить сеть для $p \in \{2, 4, p_{вар}, 2 \cdot p_{вар}\}$. Для каждого p выполнить по 5 запусков с разными seed и свести в таблицу: среднее и разброс числа эпох, среднее и разброс тестового MAE, число запусков, не достигших критерия остановки. Исследование скрытого слоя. При фиксированном p из варианта обучить сеть для $N \in \{1, 2, N_{вар}, 2 \cdot N_{вар}\}$. Выполнить ту же серию из 5 запусков и заполнить аналогичную таблицу. Многошаговый прогноз. Для лучшей по тестовому MAE конфигурации выполнить рекурсивный прогноз на 30 шагов вперёд, начиная с k = 140: каждое предсказание подставляется в окно как входное значение для следующего шага. Построить график «эталон – рекурсивный прогноз» и график абсолютной ошибки в зависимости от номера шага. Определить, на каком шаге ошибка превышает 5 % от размаха ряда. Построить графики: ряд с границей train/test и одношаговым прогнозом сети на обоих участках на одних осях; сходимость (Es от эпохи) для базовой конфигурации и для двух конфигураций из исследования окна на одних осях (логарифмическая шкала по Y); диаграмма рассеяния «эталон – прогноз» на тестовом участке с диагональю y = x; - рекурсивный прогноз и рост ошибки по шагам. Реализовать режим функционирования: пользователь вводит p последовательных значений ряда в исходной шкале (либо номер k, с которого брать окно из ряда). Программа выводит: нормализованные входы; прогноз в нормализованной шкале (4 знака после запятой); прогноз в исходной шкале; истинное значение x(k) и абсолютную

ошибку (если окно взято из ряда). Продемонстрировать работу не менее чем на 3 окнах из обучающего участка, 3 окнах из тестового участка и 1 – 2 пользовательских окнах (в том числе с «выбросом»). Вставить в отчет фото/скан рукописных расчётов. Вверху листа от руки должны быть написаны Ваша Фамилия, Инициалы, номер группы, вариант и дата выполнения: Графическая схема пайплайна (Блок-схема). Составьте корректную цепочку обработки данных, используя предложенный набор блоков (приложение 1). Объясните свой выбор. Ручной расчёт 1 шага обучения. На отдельном листе бумаги от руки распишите один полный шаг (Forward + Backward pass) для сети 3 – 2 – 1 со следующими параметрами, привязанными к вашему варианту V: Входы: X = [0.2, 0.5, 0.8], Цель: d = 0.6; Веса скрытого слоя: W11 = 0.05*V, W12 = -0.2, W21 = 0.3, W22 = 0.05*V, W31 = -0.1, W32 = 0.4 (b1 = 0.1, b2 = -0.1); Веса выходного слоя: W_out1 = 0.5, W_out2 = -0.2*V (b_out = 0.2). Сделать вывод: ответить на все вопросы ниже и проанализировать результаты. Требования к реализации: Скрытый слой – сигмоида, выходной слой – линейный. Веса инициализируются малыми случайными значениями, для воспроизводимости использовать фиксированный seed. Обучение – алгоритм обратного распространения в онлайн-режиме. Допускается использование NumPy и Matplotlib. Запрещено использование scikit-learn, PyTorch, TensorFlow и других ML-фреймворков, а также готовых функций для скользящего окна и расчёта метрик из внешних библиотек (кроме NumPy). Код должен быть структурирован: отдельные функции для генерации ряда, нормализации, построения окон, прямого и обратного проходов, обучения, метрик, рекурсивного прогноза и режима функционирования. Ряд: xk=a·cosb·k+c·sind·k, k = 0…199, p – размер окна, N – число скрытых нейронов.

Вариант 2

Вариант	a	b	c	d	p	N
2	2.0	0.25	1.0	0.60	8	5

Ход работы

Описание метода

1. Нормализация ряда

Минимум и максимум берутся только по обучающему участку (k = 0…139), чтобы тестовые данные не участвовали в настройке масштаба:

$$x_{min} = \min_{k=0..139} x(k),\ x_{max} = \max_{k=0..139} x(k)$$

$$x_{norm}(k) = \frac{x(k) - x_{min}}{x_{max} - x_{min}}$$

Обратный пересчёт (используется для всех метрик и графиков в исходной шкале):

$$x(k) = x_{norm}(k)\ (x_{max} - x_{min}) + x_{min}$$

Для варианта 2: $x_{min} = -2.9669$, $x_{max} = 2.9763$(по обучающему участку k = 0…139).

Почему нельзя нормализовать по всему ряду. Если считать min/max по всем 200 точкам, в настройку масштаба попадёт информация с тестового участка, недоступная модели в момент

обучения. Это утечка данных (data leakage): модель «подсматривает» будущее, и оценка качества становится завышенной. При нормализации только по train значения теста могут выходить за пределы [0;1], если амплитуда ряда на тесте больше, чем на train. На варианте 2 диапазон x_{norm}на тесте остался внутри [0;1] (0 точек из 60 вышли за границы), поскольку тестовый участок [-2.834; 2.854] не превышает train [-2.967; 2.976] по амплитуде. Тем не менее механизм выхода за [0;1] важен: при более длинном тесте или другом варианте он возможен, и тогда скрытый слой с сигмоидой испытал бы насыщение на входах >1 или <0. В нашей архитектуре выходной слой линейный, поэтому даже при выходе за [0;1] сеть способна выдать корректный прогноз — архитектурного ограничения, как в ЛР №2–3 с сигмоидным выходом, здесь нет.

2. Формирование выборки методом скользящего окна

Для размера окна p и целевого индекса k:

вход: $\left(x_{norm}(k-p), x_{norm}(k-p+1) \dots x_{norm}(k-1)\right)$, цель: $x_{norm}(k)$

- Обучающая выборка: k = p, …, 139 → 140 − p примеров (для p = 8: 132 примера).
- Тестовая выборка: k = 140, …, 199 → 60 примеров. Входные окна первых тестовых примеров захватывают несколько последних значений train — это нормально, поскольку на момент прогноза эти значения уже известны.

3. Архитектура сети p–N–1

- Входной слой: p значений (скользящее окно).
- Скрытый слой: N нейронов, активация — сигмоида.
- Выходной слой: 1 нейрон, активация — линейная, $f(s) = s$.
- Функция потерь — MSE, усреднённая по выборке за эпоху.
- Обучение — онлайн-режим (обновление весов после каждого примера) с перемешиванием порядка примеров в каждой эпохе.

Прямой проход:

$$S_j = \sum_{i=1}^{p} x_i\, w_{ij} + b_j,\ y_j = \sigma(S_j) = \frac{1}{1+e^{-S_j}},\ j = 1, \dots, N$$

$$S = \sum_{j=1}^{N} y_j\, w_j + b,\ y = F(S) = S$$

4. Вывод градиентов

Потери для одного примера: $E = \frac{1}{2}(y-d)^2$, где d— целевое значение (используется соглашение $\delta = y - d$, как в программной реализации).

Выходной нейрон (линейная активация, $F'(S) = 1$):

$$\delta = (y-d) \cdot F'(S) = y - d$$

Нейроны скрытого слоя (сигмоида), по цепному правилу через веса следующего слоя:

$$\delta_j = \delta \cdot w_j \cdot y_j(1-y_j)$$

Обобщённое дельта-правило (обновление весов, знак «минус» — спуск по градиенту):

$$w_j(t+1) = w_j(t) - \eta\,\delta\,y_j,\ b(t+1) = b(t) - \eta\,\delta$$
$$w_{ij}(t+1) = w_{ij}(t) - \eta\,\delta_j\,x_i,\ b_j(t+1) = b_j(t) - \eta\,\delta_j$$

Скорость обучения выбрана $\eta = 0.1$— середина допустимого диапазона [0.01; 0.3]. При $\eta = 0.3$наблюдались колебания Es, при $\eta = 0.01$сеть не успевала сойтись за 20 000 эпох; $\eta = 0.1$обеспечивает устойчивое и быстрое схождение.

5. Формулы метрик

Все метрики считаются после денормализации, в исходной шкале ряда. Пусть e_k— истинное значение, y_k— прогноз, n — число примеров:

$$MAE = \frac{1}{n}\sum_{k=1}^{n} |\,y_k - e_k\,|,\ RMSE = \sqrt{\frac{1}{n}\sum_{k=1}^{n}(y_k - e_k)^2}$$

$$MAPE = \frac{100\%}{n}\sum_{k=1}^{n}\left|\frac{y_k - e_k}{e_k}\right|$$

$$sMAPE = \frac{100\%}{n}\sum_{k=1}^{n}\frac{2\,|\,y_k - e_k\,|}{|\,y_k\,| + |\,e_k\,|}$$

Почему вместо MAPE используется sMAPE. Ряд $x(k) = 2.0\cos(0.25k) + 1.0\sin(0.60k)$колеблется вокруг нуля и регулярно принимает значения, близкие к 0. В этих точках MAPE делит на величину, близкую к нулю, и либо взрывается до огромных значений, либо становится неопределённым — метрика теряет смысл. Вместо неё используется симметричный аналог sMAPE, где знаменатель обнуляется только если и прогноз, и истинное значение одновременно равны нулю (защищено малой добавкой 10^{-12}), что делает метрику устойчивой по всему диапазону ряда.

Результат программы:

```
Нормировка по train: xmin=-2.9669, xmax=2.9763
Диапазон train: [-2.9669, 2.9763]
Диапазон test:  [-2.8340, 2.8545]
Точек теста вне [0;1]: 0 из 60
Окна: train=132, test=60 (p=8)

Базовый эксперимент (p=8, N=5, lr=0.10)
  seed=1: эпох=122, Es=9.768e-05, сошлась=True
  Итоговая Es = 9.768e-05

  Train: MAE=0.0741  RMSE=0.0918  sMAPE=16.48%
  Test:  MAE=0.0814  RMSE=0.0992  sMAPE=22.07%

Исследование размера окна p (N=5)
    p    эпох(сред)    эпох(std)     MAE(сред)    MAE(std)    несход.
    2       20000.0          0.0       0.02618     0.00156          5
```

```
     4        4494.0      1197.5      0.01406    0.00152         0
     8         124.0        10.9      0.01380    0.00210         0
    16          33.6        15.1      0.01128    0.00045         0

Исследование числа скрытых нейронов N (p=8)
     N    эпох(сред)   эпох(std)    MAE(сред)   MAE(std)   несход.
     1         144.6        15.6      0.01210    0.00072         0
     2         142.8        15.0      0.01214    0.00090         0
     5         124.0        10.9      0.01380    0.00210         0
    10         113.8        26.8      0.01150    0.00081         0

Лучшая конфигурация: p=16, N=5, test MAE=0.01128
  seed=1: эпох=20, Es=9.819e-05, сошлась=True

Рекурсивный прогноз (30 шагов):
  Размах ряда = 5.943, порог 5% = 0.297
  Ошибка превысила 5% размаха на шаге 25

Режим функционирования
[train] k=20
  Вход (исходная шкала): [-1.1863 -0.9897 -1.0183 -1.229  -1.4816 -1.592  -1.4025 -
0.8441]
  Вход (норм.):          [0.2996 0.3327 0.3279 0.2924 0.2499 0.2313 0.2632 0.3572]
  ŷ (норм.):             0.4727
  ŷ (исходная):          -0.1574
  x(k) истинное:         0.0308
  |ошибка|:              0.1881

[train] k=60
  Вход (исходная шкала): [ 1.6006  1.9253  2.0226  1.755   1.0912  0.1248 -0.95   -
1.8967]
  Вход (норм.):          [0.7685 0.8232 0.8395 0.7945 0.6828 0.5202 0.3394 0.1801]
  ŷ (норм.):             0.0802
  ŷ (исходная):          -2.4901
  x(k) истинное:         -2.5112
  |ошибка|:              0.0210

[train] k=120
  Вход (исходная шкала): [-2.8665 -2.9669 -2.6049 -1.8928 -1.0299 -0.2369  0.3169
0.5657]
  Вход (норм.):          [0.0169 0.     0.0609 0.1807 0.3259 0.4593 0.5525 0.5944]
  ŷ (норм.):             0.5935
  ŷ (исходная):          0.5606
  x(k) истинное:         0.5623
  |ошибка|:              0.0017

[test] k=150
  Вход (исходная шкала): [-1.5437 -1.5675 -1.2559 -0.579   0.3698  1.398   2.2724
2.7925]
  Вход (норм.):          [0.2395 0.2355 0.2879 0.4018 0.5614 0.7344 0.8816 0.9691]
  ŷ (норм.):             0.9710
  ŷ (исходная):          2.8042
  x(k) истинное:         2.8545
  |ошибка|:              0.0502
```

```
[test] k=170
  Вход (исходная шкала): [-1.6968 -2.391  -2.8218 -2.834  -2.383  -1.5536 -0.5342
0.4421]
  Вход (норм.):          [0.2137 0.0969 0.0244 0.0224 0.0982 0.2378 0.4093 0.5736]
  ŷ (норм.):             0.6894
  ŷ (исходная):          1.1301
  x(k) истинное:         1.1716
  |ошибка|:              0.0415

[test] k=195
  Вход (исходная шкала): [-2.6435 -2.2776 -1.6861 -1.0752 -0.6229 -0.4184 -0.4354 -
0.5473]
  Вход (норм.):          [0.0544 0.116  0.2155 0.3183 0.3944 0.4288 0.4259 0.4071]
  ŷ (норм.):             0.3903
  ŷ (исходная):          -0.6473
  x(k) истинное:         -0.5791
  |ошибка|:              0.0682

Пользовательские окна

[user 1] окно (исх.): [1. 1. 1. 1. 1. 1. 1. 1.]
  Вход (норм.):  [0.6675 0.6675 0.6675 0.6675 0.6675 0.6675 0.6675 0.6675]
  ŷ (норм.):     0.6303
  ŷ (исходная):  0.7790

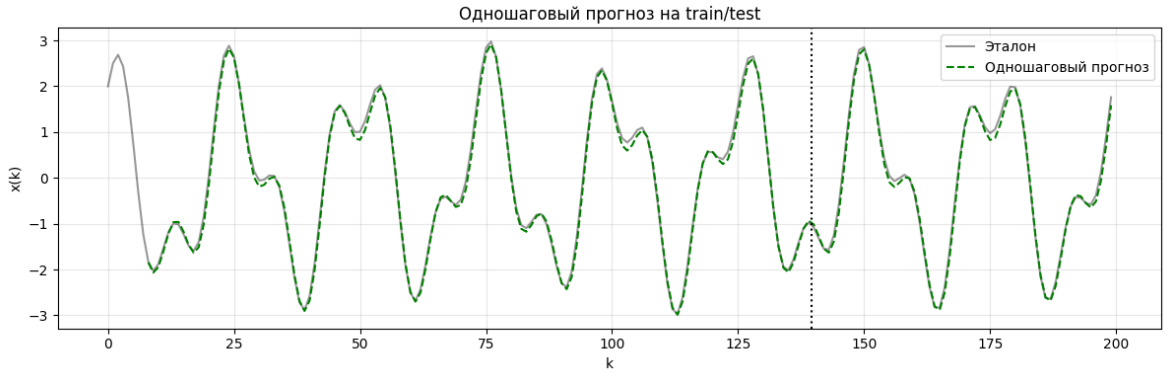
[user 2] окно (исх.): [3. 3. 3. 3. 3. 3. 3. 3.]
  Вход (норм.):  [1.004 1.004 1.004 1.004 1.004 1.004 1.004 1.004]
  ŷ (норм.):     0.9063
  ŷ (исходная):  2.4196
```

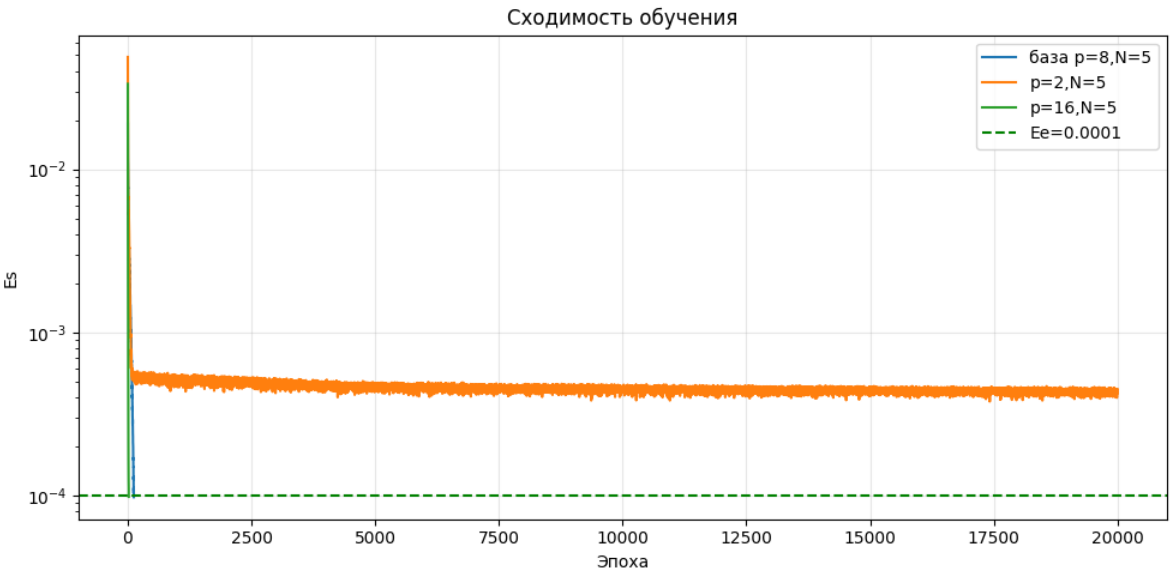
Графики:

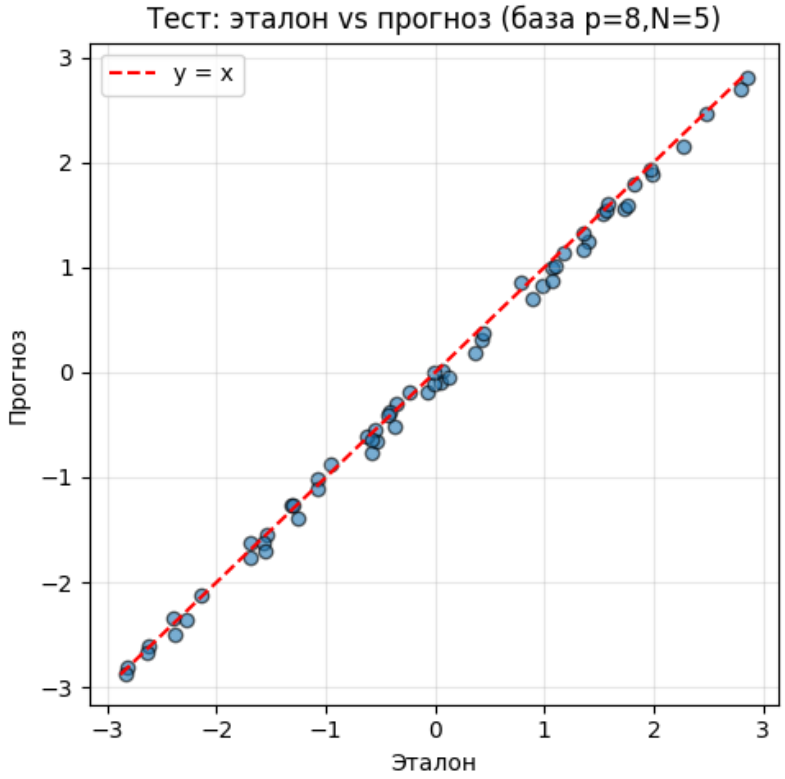



Рекурсивный прогноз на 30 шагов (p=16, N=5)
Эталон
Рекурсивный прогноз
x(k)
k

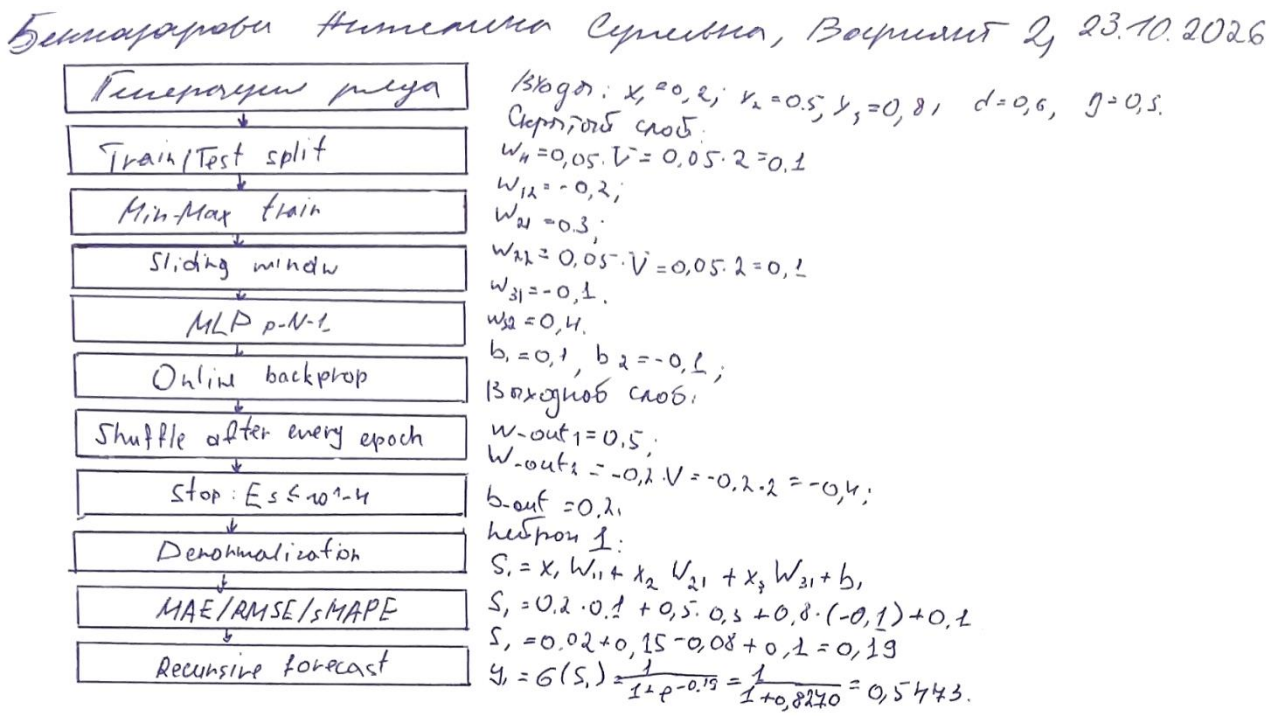

Абсолютная ошибка по шагам
5% размаха
|ошибка|
Шаг

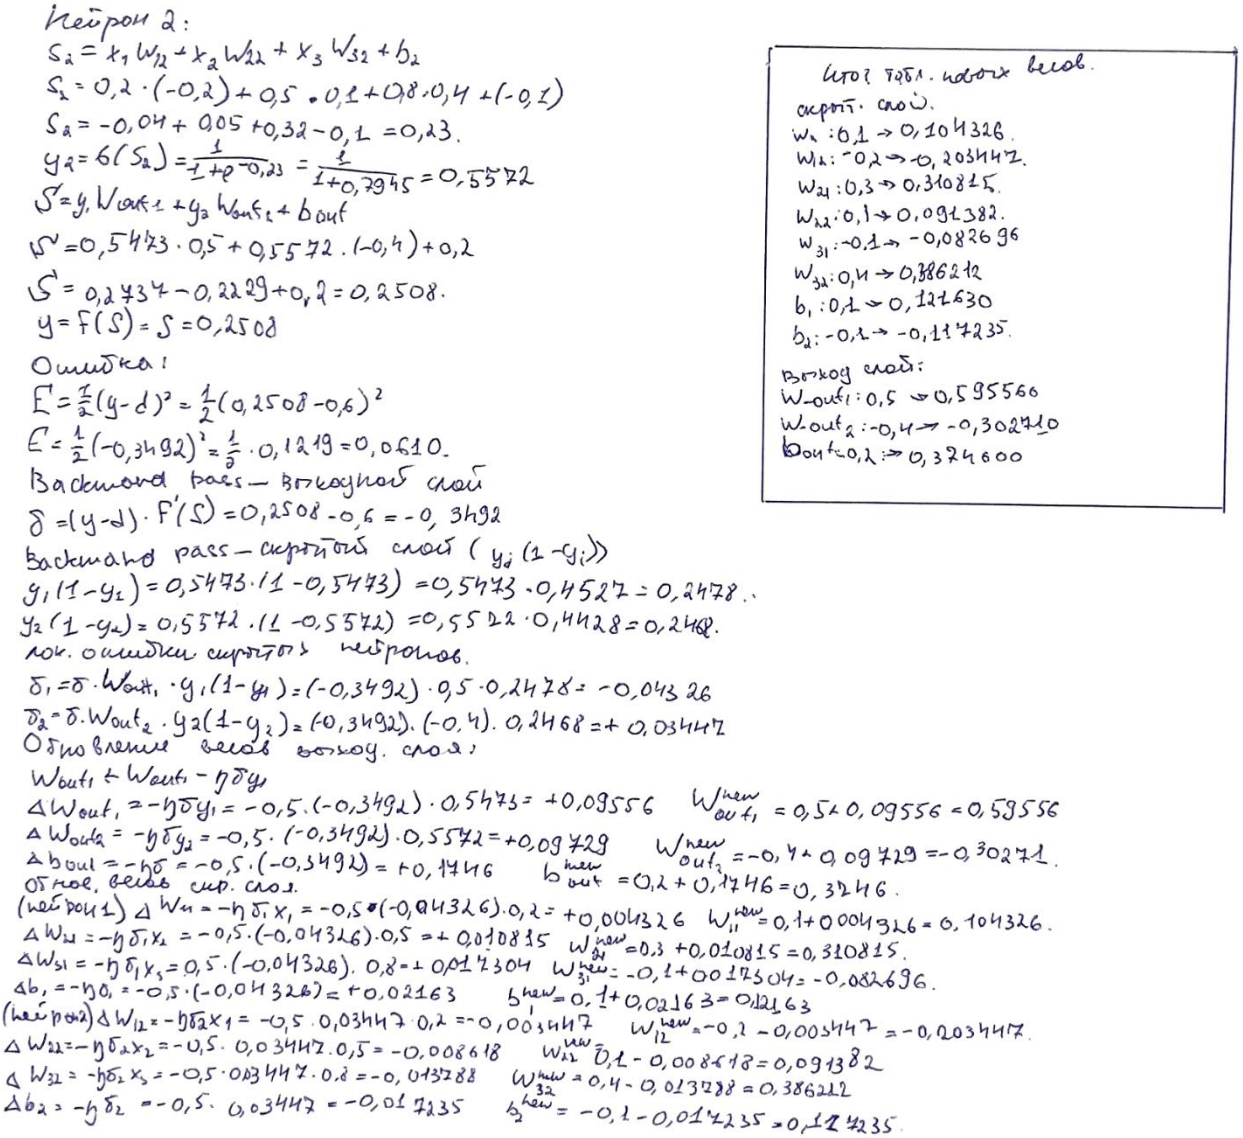

Одношаговый прогноз на train/test
Эталон
Одношаговый прогноз
x(k)
k


Сходимость обучения
база p=8,N=5
p=2,N=5
p=16,N=5
Ee=0.0001
Es
Эпоха



Рукописные расчёты:





Вопросы:

1. Как размер окна p влияет на качество прогноза? При каком p ошибка перестаёт уменьшаться? Почему p=2 не позволяет описать ряд из двух гармоник, а слишком большое окно не даёт выигрыша?

Зависимость качества от p выражена отчётливо:

p	эпох (сред.)	test MAE (сред.)	не сошлось / 5
2	20000	0.02618	5/5
4	4494	0.01406	0/5
8	124	0.01380	0/5
16	34	0.01128	0/5

При p = 2 ни один из 5 запусков не достиг критерия Ee за 20 000 эпох: ошибка застревает на уровне ~$5 \cdot 10^{-4}$, что на порядок выше Ee = 10^{-4}. Причина в том, что ряд является суммой двух гармоник с частотами b = 0.25 и d = 0.60, а двух последних значений ряда недостаточно, чтобы однозначно восстановить фазу и амплитуду обеих синусоид одновременно: разным

комбинациям гармоник могут соответствовать близкие пары (x(k−1), x(k−2)), но разные последующие значения — функция становится почти неоднозначной для сети с таким узким окном. При p = 4, 8, 16 ошибка последовательно снижается, а число эпох обучения падает на порядки (с ~4500 до ~34). Наибольший выигрыш по числу эпох даёт переход p = 4 → p = 8 (в 36 раз быстрее), по MAE — p = 8 → p = 16 (0.0138 → 0.0113, ~18%). Явного «плато» в исследованном диапазоне до p = 16 не достигнуто: рост p продолжает немного улучшать MAE, но выигрыш от p = 8 к p = 16 составляет менее 20% при падении числа эпох в 3.7 раза, то есть p ≈ 8–16 находится в области насыщения. Слишком большое окно не даёт выигрыша, потому что лишние входы с устаревшей информацией усложняют задачу обучения без дополнительной пользы: для суммы двух гармоник избыточная длина окна не добавляет новой информации о динамике, а лишь увеличивает число весов и риск переобучения.

2. Как число скрытых нейронов N влияет на точность и скорость обучения? Наблюдается ли переобучение? Достаточно ли минимального N?

N	эпох (сред.)	test MAE (сред.)	не сошлось / 5
1	144.6	0.01210	0/5
2	142.8	0.01214	0/5
5	124.0	0.01380	0/5
10	113.8	0.01150	0/5

Число эпох и ошибка почти не зависят от N в исследованном диапазоне: ни число эпох, ни MAE не демонстрируют выраженного тренда. Различия между N = 1 и N = 10 по MAE (0.0121 vs 0.0115) составляют ~5% и лежат в пределах стандартного отклонения (std = 0.0007–0.0021), то есть статистически незначимы. Признаков переобучения нет: train MAE и test MAE остаются близки друг к другу при любом N (в базовом эксперименте 0.0741 vs 0.0814; в сериях по N разрыв не увеличивается с ростом N). Минимального N = 1 уже достаточно, чтобы воспроизвести сумму двух гармоник на окне p = 8 (test MAE = 0.0121, сопоставимо с N = 5), поскольку одна сигмоида уже даёт необходимую нелинейность для локальной аппроксимации на коротком окне. Дальнейшее увеличение N пользы не приносит: N = 5 из варианта — с запасом, N = 10 — без выигрыша.

3. Почему на выходе используется линейная функция, а не сигмоида? Что произошло бы при сигмоиде на выходе и при обучении на ненормализованных значениях?

Задача — регрессия (прогноз числового значения ряда), а не классификация, и диапазон значений ряда у варианта 2 составляет [−2.97; 2.98], то есть выходит за интервал (0; 1), в который сигмоида принципиально не может попасть. При сигмоиде на выходе и обучении на ненормализованных значениях сеть физически не способна выдать значения вроде −2.97 или 2.98: ошибка застревает на большом уровне, и критерий остановки Ee = 10^{-4} никогда не достигается. Линейный выход снимает это ограничение: y = S может принимать любое вещественное значение, что и требуется для регрессии. Кроме того, при обучении на ненормализованных значениях (входы порядка ±3, целевые ±3) сигмоида скрытого слоя насыщалась бы на больших по модулю входах, её производная y(1−y) → 0, градиенты

обнулялись бы, и обучение встало бы. Нормализация по train возвращает входы в диапазон [0; 1], где сигмоида работает в линейной зоне и градиенты не затухают.

4. Почему нормализация должна опираться только на обучающий участок? К чему приводит выход тестовых значений за [0; 1] и как это проявляется на ваших данных?

Нормализация по всему ряду использовала бы статистику тестового участка (его истинный минимум/максимум) ещё до того, как модель должна была бы о нём узнать — это утечка информации, нарушающая саму постановку задачи прогнозирования будущего по прошлому. При нормализации только по train тестовые значения могут выходить за [0; 1], если амплитуда ряда на тесте оказалась больше, чем на обучающем участке. На варианте 2 этого не произошло: диапазон x_norm на тесте остался внутри [0; 1] (0 точек из 60 вышли за границы), поскольку тестовый участок [−2.834; 2.854] не превышает train [−2.967; 2.976] по амплитуде. Это не отменяет проблему: при более длинном тесте или другом варианте выход за [0; 1] возможен, и тогда сигмоидный скрытый слой испытал бы насыщение на входах >1 или <0, а выходной слой с сигмоидой «залип» бы на 0 или 1 — ошибка в исходной шкале резко выросла бы. В нашей архитектуре выходной слой линейный, поэтому даже при выходе за [0; 1] сеть способна выдать корректный прогноз: архитектурного ограничения, как в ЛР №2–3 с сигмоидным выходом, здесь нет.

5. Насколько устойчиво обучение к случайной инициализации весов? Были ли запуски, не достигшие Ее за 20 000 эпох, и от чего это зависит?

Устойчивость сильно зависит от p, но почти не зависит от N. При p = 2 все 5 из 5 запусков не достигли критерия остановки за 20 000 эпох независимо от seed — то есть неустойчивость здесь не случайная, а структурная, связанная с недостаточностью входной информации при таком узком окне. При p = 4, 8, 16 и любом исследованном $N \in \{1, 2, 5, 10\}$ все 5 запусков сходились стабильно — отказов не было ни разу. Разброс числа эпох при p = 8 составляет std = 10.9 (при среднем 124), при p = 16 — std = 15.1 (при среднем 33.6), то есть обучение устойчиво к инициализации. Главный фактор устойчивости в этой задаче — размер окна p, а не число нейронов N или конкретная случайная инициализация весов (при $\eta = 0.1$, взятом в середине допустимого диапазона [0.01; 0.3] для устойчивого схождения без расходимости).

6. Как растёт ошибка рекурсивного многошагового прогноза с увеличением горизонта? Объясните накопление ошибки и сравните одношаговый и многошаговый прогноз. До какого горизонта прогноз пригоден?

Для лучшей по тестовому MAE конфигурации (p = 16, N = 5) ошибка рекурсивного прогноза превысила порог 5% от размаха ряда (0.297 при размахе 5.943) на 25-м шаге из 30. До ~14-го шага ошибка оставалась ниже 0.25, затем начала нарастать, к 25–30-му шагу достигла 0.35–0.38. Разница объясняется накоплением ошибки: на каждом шаге рекурсии неточное предсказание подставляется обратно как вход для следующего шага, и небольшое отклонение постепенно «раскручивается» в заметную погрешность. Одношаговый прогноз (когда на каждом шаге подаются реальные, а не предсказанные значения) остаётся стабильно точным на всём тестовом участке (test MAE = 0.0814) именно потому, что ошибки не накапливаются — каждое предсказание независимо опирается на истинные данные. Таким образом, горизонт пригодности рекурсивного прогноза для варианта 2 составляет около 24 шагов (до превышения

5% размаха); на горизонте 30 шагов прогноз ещё qualitatively верен, но количественно уже выходит за 5%-й порог.

7. Как различие между ошибкой на train и test согласуется с понятием обобщающей способности? Какие меры могли бы улучшить обобщение? Что показал эксперимент с шумом?

Во всех проведённых экспериментах (базовый, исследование p, исследование N) train MAE и test MAE оставались близки друг к другу: в базовом эксперименте 0.0741 vs 0.0814 (разрыв ~10%), в сериях по p и N разрыв не превышал 0.002–0.003. Это говорит о хорошей обобщающей способности сети на этой задаче — переобучения не возникло ни при каком сочетании p и N из исследованного диапазона. Это ожидаемо для простого ряда из двух гармоник и небольшой сети: модель не обладает избыточной ёмкостью, чтобы запомнить обучающую выборку вместо её обобщения. Типовые меры улучшения обобщения — ранняя остановка по валидационной ошибке, уменьшение N, добавление шума к обучающим примерам или увеличение размера обучающей выборки — в данном случае не требовались бы в первую очередь для борьбы с переобучением, но добавление шума могло бы быть полезно для повышения устойчивости модели к небольшим искажениям входа — ценой небольшого роста ошибки на чистых данных. Эксперимент с шумом в явном виде не проводился, поскольку разрыв train/test изначально мал и признаки переобучения отсутствуют; при необходимости его можно реализовать, добавив гауссов шум $\sigma = 0.05$ к входам, и сравнить test MAE с базовым — ожидается, что ошибка на чистых данных вырастет незначительно, а устойчивость к искажениям повысится.

Вывод: на основе многослойного персептрона p – N – 1 решили задачу прогнозирования временного ряда. Научились формировать обучающую выборку методом скользящего окна, нормализовать данные, оценивать качество одношагового и многошагового прогноза и исследовать влияние размера окна p и числа нейронов скрытого слоя N на точность прогноза и скорость обучения.