

Министерство образования Республики Беларусь
Учреждение образования
«Брестский Государственный технический университет»
Кафедра ИИТ

Лабораторная работа №2

По дисциплине «Модели решения задач в интеллектуальных системах»

Тема: «Многослойный персептрон для задачи «исключающее ИЛИ» с числовыми классами: сравнение функций потерь MSE и Binary Cross-Entropy»

Выполнил:
Студент 4 курса
Группы ИИ-25
Кулик Я. А.
Проверил:
Андренко К.В.

Цель работы: На основе многослойного персептрона архитектуры 2-2-1, реализованного в Лабораторной работе №1 для задачи XOR с числовыми классами c_0 и c_1 из диапазона $[-10; 10]$, реализовать альтернативную функцию потерь – бинарную кросс-энтропию (Binary Cross-Entropy, BCE) – и провести сравнительный анализ обучения сети с MSE (Лабораторная работа №1) и с BCE по скорости сходимости, качеству обучения и устойчивости к выбору начальных весов.

Задачи лабораторной работы:

1. Взять за основу код многослойного персептрона 2-2-1 из Лабораторной работы №1;
 2. Поскольку BCE определена для выходов в диапазоне $(0; 1)$, а целевые значения в вашем варианте – произвольные числа c_0 и c_1 из диапазона $[-10; 10]$, реализовать нормализацию (масштабирование) целевых значений перед обучением и обратное преобразование выхода сети после обучения:
 - привести c_0 и c_1 к бинарным меткам 0 и 1;
 - обучать сеть на нормализованных целевых значениях с функцией потерь BCE;
 - при выводе результата преобразовывать выход сети $\hat{y} \in (0; 1)$ обратно в шкалу $[c_0; c_1]$.
 3. Реализовать корректный градиент для связки BCE + сигмоида на выходном слое; для скрытого слоя градиент передаётся по стандартному правилу цепочки.
 4. Обучить сеть на полной таблице истинности своего варианта (4 примера) в двух конфигурациях:
 - конфигурация А (базовая, из ЛР №1): MLP 2-2-1, функция потерь MSE, целевые значения – исходные c_0/c_1 , выходной слой – сигмоида. Результаты можно взять из отчёта по ЛР №1 или, при необходимости, повторить обучение с фиксацией всех метрик.
 - конфигурация Б (новая): MLP 2-2-1, функция потерь BCE, целевые значения – нормализованные (0/1), с последующим пересчётом выхода в шкалу $[c_0; c_1]$.
- Критерий остановки для обеих конфигураций одинаков – суммарная ошибка $E_s \leq E_e$ (используйте то же значение E_e , что и в ЛР №1, либо согласуйте новое

значение отдельно для MSE и для BCE, поскольку это разные по своей природе величины – обоснуйте выбор в отчёте);

5. Для каждой конфигурации зафиксировать:

- количество эпох до достижения критерия остановки (либо факт недостижения за максимально допустимое число эпох);
- итоговую суммарную ошибку;
- ассигасу на всех 4 примерах таблицы истинности;
- среднюю абсолютную ошибку в исходной шкале $[c_0; c_1]$.

6. Провести не менее 5 запусков обучения для каждой конфигурации с разной случайной инициализацией весов (менять seed) и сравнить устойчивость сходимости: в скольких из 5 запусков сеть достигла критерия остановки, и какой разброс по числу эпох наблюдается;

7. Построить общий график зависимости суммарной ошибки от номера эпохи для конфигурации А (MSE) и конфигурации Б (BCE) на одних осях (для представительного запуска каждой конфигурации);

8. Реализовать блок визуализации результатов, включающий:

- график сходимости – суммарная ошибка E_s от номера эпохи, конфигурации А и Б на одних осях, разными цветами/стилями линий, с обозначением порога E_e ;
- диаграмму разброса числа эпох по 5 запускам (bar chart или scatter) для конфигурации А и конфигурации Б – наглядно показывающую устойчивость сходимости из п. 6 (например, столбики числа эпох для каждого из 5 seed, сгруппированные по конфигурации; запуски, не достигшие критерия остановки, отметить отдельно, например штриховкой или отдельным цветом);
- визуализацию разделяющей поверхности скрытого слоя – для представительного обученного экземпляра каждой конфигурации построить на плоскости (А, В) карту выходного значения сети (heatmap или contour plot) с наложенными точками обучающей выборки (4 примера таблицы истинности), закрашенными по истинному классу. Диапазон осей А и В – $[-10; 10]$ (весь допустимый диапазон входных значений). Для конфигурации Б цветовую шкалу можно строить как по нормализованному $\hat{y} \in (0; 1)$, так и по пересчитанному значению в шкале $[c_0; c_1]$ – выбрать более наглядный вариант и обосновать выбор;

- диаграмму сравнения точности восстановления шкалы – столбчатую диаграмму средней абсолютной ошибки для конфигурации А и конфигурации Б, чтобы наглядно сопоставить точность регрессии к исходной шкале $[c_0; c_1]$. Каждый график должен иметь подписанные оси, заголовок и легенду (где применимо). Разделяющую поверхность и графики точности рекомендуется разместить рядом (например, subplot 2×2 или отдельными рисунками) для удобства сравнения в отчёте;

9. Реализовать режим функционирования сети: пользователь вводит пару чисел (А, В) из диапазона $[-10; 10]$ (не обязательно совпадающих с c_0 и c_1). Сеть должна выводить:

- выход в нормализованной шкале $\hat{y} \in (0; 1)$ (с точностью до 4 знаков);
- выход, пересчитанный в исходную шкалу $[c_0; c_1]$ по формуле из п. 2;
- к какому классу (c_0 или c_1) ближе полученное значение.

Продемонстрировать работу режима функционирования на всех 4 примерах исходной таблицы истинности и не менее чем на 2–3 дополнительных парах (А, В), не входящих в обучающую выборку.

Вариант 7

($c_0 = -4$, $c_1 = -9$)

А	В	$A \oplus B$
-4	-4	-4
-4	-9	-9
-9	-4	-9
-9	-9	-4

Изменения в архитектуре и алгоритме относительно ЛР1:

Архитектура сети 2-2-1 (сигмоида на всех слоях) не менялась. Изменения произошли только в целевой функции и во входной нормализации.

Нормализация значений:

$$y_{norm} = \frac{y - c_0}{c_1 - c_0}$$

Обратный пересчёт после обучения:

$$y = y_{norm} \cdot (c_1 - c_0) + c_0$$

Вывод градиента ВСЕ + сигмоида (выходной слой):

Потери для одного примера:

$$L = -y \ln p - (1 - y) \ln(1 - p), \quad p = \sigma(z) = out$$

Цепное правило:

$$\frac{\partial L}{\partial z} = \frac{\partial L}{\partial p} \cdot \frac{\partial p}{\partial z}$$

После преобразования получается:

$$\delta_{out} = out - y$$

Градиент для скрытого слоя:

$$\delta_h = (\delta_{out} W_2^T) \odot h(1 - h)$$

Результаты обучения:

--- Конфигурация А (MSE) ---

seed=1: эпох=10000, ошибка=0.696542, accuracy=0.75, MAE=1.7521

seed=2: эпох=8711, ошибка=0.009995, accuracy=1.00, MAE=0.2448

seed=3: эпох=9014, ошибка=0.009994, accuracy=1.00, MAE=0.2445

seed=4: эпох=9207, ошибка=0.009998, accuracy=1.00, MAE=0.2443

seed=5: эпох=7546, ошибка=0.009998, accuracy=1.00, MAE=0.2458

--- Конфигурация Б (BCE) ---

seed=1: эпох=10000, ошибка=2.093529, accuracy=0.75, MAE=1.7203

seed=2: эпох=6142, ошибка=0.010000, accuracy=1.00, MAE=0.0124

seed=3: эпох=8824, ошибка=0.009998, accuracy=1.00, MAE=0.0124

seed=4: эпох=10000, ошибка=2.092428, accuracy=0.75, MAE=1.7197

seed=5: эпох=6114, ошибка=0.009997, accuracy=1.00, MAE=0.0124

=== Сравнение на seed = 3 ===

MSE: эпох = 9014 | ошибка = 0.009994 | accuracy = 1.0 | MAE = 0.244509

ВСЕ: эпох = 8824 | ошибка = 0.009998 | accuracy = 1.0 | MAE = 0.012411

График сходимости:





Диаграмма числа эпох по 5 запускам:



Разделяющая поверхность:






Диаграмма MAE:



Режим функционирования:

=== Режим функционирования (BCE) ===

Введите A B из диапазона [-10; 10].

Для выхода введите: q

A B: -4 -4

Нормализованный выход: 0.0016

Выход в шкале [c0; c1]: -4.0078

Ближайший класс: -4

A B: -4 -9

Нормализованный выход: 0.9978

Выход в шкале [c0; c1]: -8.9890

Ближайший класс: -9

A B: -9 -9

Нормализованный выход: 0.0039

Выход в шкале [c0; c1]: -4.0196

Ближайший класс: -4

A B: 0 0

Нормализованный выход: 0.0008

Выход в шкале [c0; c1]: -4.0040

Ближайший класс: -4

A B: 6 -6

Нормализованный выход: 0.0008

Выход в шкале [c0; c1]: -4.0040

Ближайший класс: -4

A B: q

Вопросы:

1.Какая функция потерь дала более быструю/устойчивую сходимость?

На сошедшихся запусках BCE показала меньше эпох (8824 против 9014 на seed=3) и в 20 раз меньшую MAE (0.0124 против 0.2445). Это согласуется с теорией: у BCE градиент на выходе равен ($out - y$) и не гаснет при насыщении сигмоиды, а логарифмический штраф тянет выходы к 0 и 1. У MSE в градиенте есть множитель $out \cdot (1-out)$, который стремится к нулю при насыщении — это и есть теоретическая слабость MSE. Но по устойчивости MSE оказалась лучше: 4/5 запусков сошлись (кроме seed=1), а BCE — только 3/5 (seed=1 и seed=4 застряли в локальном минимуме с ошибкой ≈ 2.09 и accuracy = 0.75).

2. Как нормализация целевых значений (приведение c0/c1 к 0/1) повлияла на процесс обучения по сравнению с обучением напрямую на числах из диапазона [-10; 10] (как в ЛР №1 с MSE)? Изменилась ли скорость и стабильность сходимости?

Без нормализации обучать с сигмоидой нельзя: она выдаёт значения от 0 до 1, а не -4 или -9. Поэтому порог $E_e = 0.01$ был бы недостижим. Нормализация — это не улучшение, а обязательное условие для работы BCE. Дополнительно она выровняла масштаб входов и целей и дала точное восстановление шкалы (MAE ≈ 0.012).

3. Какова точность восстановления исходной числовой шкалы [c0; c1] (средняя абсолютная ошибка) при использовании BCE с последующим пересчётом $\hat{y} \rightarrow y_{real}$, по сравнению с прямым обучением на MSE, где сеть сразу выдаёт значение в нужной шкале? Есть ли здесь компромисс между удобством классификации (BCE) и точностью регрессии к исходной шкале?

На seed=3: у BCE MAE = 0.0124, у MSE MAE = 0.2445. По всем сошедшимся запускам у BCE MAE стабильно ≈ 0.0124 , у MSE ≈ 0.244 . BCE восстановила шкалу примерно в 20 раз точнее. Компромисса здесь нет — BCE выиграла и по классификации, и по точности восстановления. Предсказания BCE почти

идеальны: $\hat{y} = 0.0016$ и 0.9978 , то есть $y = -4.008$ и -8.989 , тогда как MSE даёт «размазанные» 0.037 и $0.952 \rightarrow y = -4.19$ и -8.76 .

4. Насколько устойчивы обе конфигурации к случайной инициализации весов (по результатам серии из 5 запусков)? Наблюдались ли случаи недостижения критерия остановки или попадания в локальный минимум?

MSE устойчивее: 4/5 запусков сошлись к $E_e = 0.01$ (seed=2, 3, 4, 5), один запуск (seed=1) не достиг порога за 10000 эпох. BCE — 3/5 (seed=2, 3, 5), два запуска (seed=1 и seed=4) попали в локальный минимум с ошибкой ≈ 2.09 и accuracy = 0.75. Разброс по числу эпох у BCE тоже больше: от 6114 до 8824 (и два запуска по 10000 без сходимости).

5. Подтвердилось ли на данном варианте (со своими c_0 и c_1) сделанное в ЛР №1 наблюдение о принципиальной линейной неразделимости задачи XOR независимо от того, какие конкретно числовые значения используются для кодирования классов 0 и 1?

Да, для $c_0 = -4$ и $c_1 = -9$ сеть 2-2-1 со скрытым слоем решает XOR так же, как и для 0/1. На сошедшихся запусках обе конфигурации дают accuracy = 1.00 на всех 4 примерах. Линейная неразделимость зависит от структуры XOR, а не от того, какими числами закодированы классы.

6. Как соотносится выбор функции потерь (MSE vs BCE) с общим выводом из предыдущей лабораторной о необходимости многослойной архитектуры для XOR – влияет ли тип функции потерь на этот вывод, или он определяется исключительно архитектурой сети?

Нет, не влияет. Скрытый слой нужен из-за самой задачи XOR — это определяется архитектурой. MSE и BCE обучались на одной и той же сети 2-2-1. Функция потерь меняет только скорость и устойчивость сходимости, но не принципиальную способность разделить нелинейные данные. Даже когда сеть «застревает» в локальном минимуме, она выучивает линейную границу, которая XOR не решает — это подтверждает вывод ЛР1.

7. Что показывает визуализация разделяющей поверхности на плоскости (А, В) для обеих конфигураций? Совпадает ли форма границы между классами с ожидаемой для XOR (пересечение двух полуплоскостей,

формируемых скрытым слоем), и отличается ли она визуально между конфигурацией А (MSE) и конфигурацией Б (BCE)?

Поверхность показывает, как пространство делится на две области — для двух классов. На сошедшихся запусках (MSE seed=3, BCE seed=3) видны две диагональные линии, которые отделяют точки $(-4, -4)$ и $(-9, -9)$ от $(-4, -9)$ и $(-9, -4)$ — это и есть XOR-структура. У MSE и BCE границы выглядят почти одинаково, разница только в резкости: у BCE выходы ближе к 0 и 1, поэтому переход из одной области в другую резче, а у MSE — плавнее. На неудачных запусках BCE (seed=4) граница вырождается в линейную — визуальное подтверждение локального минимума.

Вывод: в данной лабораторной работе я реализовала альтернативную функцию потерь (бинарную кросс-энтропию) и провела сравнительный анализ обучения сети с MSE и с BCE по скорости сходимости, качеству обучения и устойчивости к выбору начальных весов.