Министерство образования Республики Беларусь

Учреждение образования

«Брестский Государственный технический университет»

Кафедра ИИТ

Лабораторная работа №4

По дисциплине «Модели решения задач в интеллектуальных системах»

Тема: «Многослойный персептрон для прогнозирования временного ряда: влияние размера окна и числа скрытых нейронов»

Выполнил:

Студент 4 курса

Группы ИИ-25

Кулик Я. А.

Проверил:

Андренко К.В.

Брест 2026

Цель работы: на основе многослойного персептрона p–N–1 решить задачу прогнозирования временного ряда. Научиться формировать обучающую выборку методом скользящего окна, нормализовать данные, оценивать качество одношагового и многошагового прогноза и исследовать влияние размера окна p и числа нейронов скрытого слоя N на точность прогноза и скорость обучения.

Задачи лабораторной работы:

1. Сгенерировать ряд по формуле варианта и построить его график с отметкой границы между обучающим и тестовым участками.
2. Нормализовать ряд по минимуму и максимуму обучающего участка: x_norm = (x - x_min) / (x_max - x_min). Записать формулу обратного пересчёта и использовать её при вычислении всех метрик в исходной шкале. Объяснить, почему min/max нельзя брать по всему ряду.
3. Сформировать обучающую и тестовую выборки методом скользящего окна размера p (вход – p значений, цель – следующее значение). Указать количество получившихся примеров в каждой выборке.
4. Реализовать многослойный персептрон p–N–1:
   - скрытый слой – сигмоида;
   - выходной слой – линейный (задача регрессии), f(s) = s;
   - функция потерь – MSE;
   - обучение – онлайн-режим, перемешивание порядка примеров в каждой эпохе;
   - вывести формулы градиентов для линейного выходного слоя и сигмоидного скрытого слоя и привести их в отчёте.
5. Критерий остановки: средняя по обучающей выборке ошибка $E_s \le E_e$, где $E_e = 10^{-4}$ (нормализованная шкала), либо достижение 20 000 эпох. Скорость обучения подобрать самостоятельно из диапазона 0.01–0.3 и обосновать выбор.
6. **Базовый эксперимент.** Обучить сеть с параметрами p и N из своего варианта. Зафиксировать число эпох, итоговую E_s, а также метрики на обучающем и тестовом участках **в исходной шкале**: MAE, RMSE и MAPE (если ряд проходит через ноль – вместо MAPE использовать sMAPE, и пояснить почему).
7. **Исследование окна.** При фиксированном N из варианта обучить сеть для $p \in \{2, 4, p_{вар}, 2 \cdot p_{вар}\}$. Для каждого p выполнить по 5 запусков с разными seed и свести в таблицу: среднее и разброс числа эпох, среднее и разброс тестового MAE, число запусков, не достигших критерия остановки.
8. **Исследование скрытого слоя.** При фиксированном p из варианта обучить сеть для $N \in \{1, 2, N_{вар}, 2 \cdot N_{вар}\}$. Выполнить ту же серию из 5 запусков и заполнить аналогичную таблицу.
9. **Многошаговый прогноз.** Для лучшей по тестовому MAE конфигурации выполнить рекурсивный прогноз на 30 шагов вперёд, начиная с k = 140: каждое предсказание подставляется в окно как входное значение для следующего шага. Построить график «эталон – рекурсивный прогноз» и график абсолютной ошибки в зависимости от номера шага. Определить, на каком шаге ошибка превышает 5 % от размаха ряда.
10. Построить графики:
    - ряд с границей train/test и одношаговым прогнозом сети на обоих участках на одних осях;
    - сходимость (E_s от эпохи) для базовой конфигурации и для двух конфигураций из исследования окна на одних осях (логарифмическая шкала по Y);
    - диаграмма рассеяния «эталон – прогноз» на тестовом участке с диагональю y = x;
    - рекурсивный прогноз и рост ошибки по шагам (п. 9).

11. Реализовать режим функционирования: пользователь вводит p последовательных значений ряда в исходной шкале (либо номер k, с которого брать окно из ряда). Программа выводит:
    - нормализованные входы;
    - прогноз в нормализованной шкале (4 знака после запятой);
    - прогноз в исходной шкале;
    - истинное значение x(k) и абсолютную ошибку (если окно взято из ряда).

Продемонстрировать работу не менее чем на 3 окнах из обучающего участка, 3 окнах из тестового участка и 1–2 пользовательских окнах (в том числе с «выбросом»).

12. Вставить в отчет фото/скан рукописных расчётов. Вверху листа от руки должны быть написаны Ваша Фамилия, Инициалы, номер группы, вариант и дата выполнения:
    - Графическая схема пайплайна (Блок-схема). Составьте корректную цепочку обработки данных, используя предложенный набор блоков (приложение 1). Объясните свой выбор.
    - Ручной расчёт 1 шага обучения. На отдельном листе бумаги от руки распишите один полный шаг (Forward + Backward pass) для сети 3–2–1 со следующими параметрами, привязанными к вашему варианту V:
    - - Входы: X = [0.2, 0.5, 0.8], Цель: d = 0.6
    - - Веса скрытого слоя: W11 = 0.05*V, W12 = -0.2, W21 = 0.3, W22 = 0.05*V, W31 = -0.1, W32 = 0.4 (b1=0.1, b2=-0.1)
    - - Веса выходного слоя: W_out1 = 0.5, W_out2 = -0.2*V (b_out = 0.2)
13. Сделать вывод: ответить на все вопросы ниже и проанализировать результаты

Вариант 7

Вариант	a	b	c	d	p	N
7	3.0	0.22	1.5	0.55	8	6

Ряд: xk=a·cosb·k+c·sind·k, k = 0…199, p – размер окна, N – число скрытых нейронов

Описание метода:

1. Нормализация:

Min/max считаются только по обучающему участку (k = 0…139), чтобы тест не участвовал в настройке масштаба

$$x_{min} = \min_{k=0..139} x(k), \qquad x_{max} = \max_{k=0..139} x(k)$$

$$x_{norm}(k) = \frac{x(k) - x_{min}}{x_{max} - x_{min}}$$

Обратный пересчёт (для всех метрик и графиков в исходной шкале):

$$x(k) = x_{norm}(k) \cdot (x_{max} - x_{min}) + x_{min}$$

Почему нельзя по всему ряду. Тестовая часть не должна участвовать в подготовке данных, иначе модель получает подсказку о том, какими будут значения, которые она должна предсказывать. При нормировке по train тестовые точки иногда выходят за пределы [0; 1] (амплитуда тестового отрезка может слегка отличаться от обучающего).

2. Формирование выборки методом скользящего окна

Для размера окна *p* и целевого индекса *k*:

вход: $\left(x_{norm}(k-p),\ x_{norm}(k-p+1),\ \ldots,\ x_{norm}(k-1)\right)$, цель: $x_{norm}(k)$

Разбиение на участки:

- Обучающий: k = p…139. Для p = 8 это 132 примера.
- Тестовый: k = 140…199 – 60 примеров. Окна теста могут начинаться в конце обучающего отрезка – это допустимо, поскольку эти значения на момент прогноза уже

известны.

3. Архитектура MLP p–N–1

- Входной слой: p значений (скользящее окно).
- Скрытый слой: N нейронов с сигмоидной активацией.
- Выходной слой: один нейрон с линейной активацией.
- Функция потерь: MSE, усреднённая по всем примерам эпохи.
- Обучение: онлайн-режим, порядок примеров перемешивается в начале каждой эпохи.

Прямой проход:

$$S_j = \sum_{i=1}^{p} x_i w_{ij} + b_j, \qquad y_j = F(S_j) = \sigma(S_j) = \frac{1}{1+e^{-S_j}}, \qquad j = 1, \ldots, N$$

$$S = \sum_{j=1}^{N} y_j\, w_j + b, \qquad y = F(S) = S$$

4. Вывод градиентов

Функция потерь для одного примера: $E=1/2(e-y)^2$, где e – целевое значение.

Выходной нейрон (линейная активация, производная равна 1):

$$\delta = (e - y) \cdot F'(S) = (e - y) \cdot 1 = e - y$$

Скрытый слой (сигмоида; ошибка передаётся обратно через веса следующего слоя):

$$\delta_j = \left(\delta \cdot w_j\right) \cdot y_j(1 - y_j)$$

Обобщённое дельта-правило (обновление весов):

$$w_j(t+1) = w_j(t) + \eta\, \delta\, y_j, \qquad b(t+1) = b(t) + \eta\, \delta$$

$$w_{ij}(t+1) = w_{ij}(t) + \eta\, \delta_j\, x_i, \qquad b_j(t+1) = b_j(t) + \eta\, \delta_j$$

5. Формулы метрик

Все метрики вычисляются в исходной шкале, после обратного преобразования прогнозов.

Пусть ek– истинное значение, yk – прогноз, n – количество примеров.

$$MAE = \frac{1}{n}\sum_{k=1}^{n} |y_k - e_k|, \qquad RMSE = \sqrt{\frac{1}{n}\sum_{k=1}^{n} (y_k - e_k)^2}$$

$$MAPE = \frac{100\%}{n}\sum_{k=1}^{n} \left|\frac{y_k - e_k}{e_k}\right|$$

Почему вместо MAPE применяется sMAPE. Ряд 3.0cos(0.22k) + 1.5sin(0.55k) периодически проходит через ноль. В таких точках знаменатель MAPE близок к нулю, и метрика либо резко возрастает, либо становится неопределённой. Чтобы избежать этого, применяется симметричная версия:

$$sMAPE = \frac{100\%}{n}\sum_{k=1}^{n} \frac{2\,|y_k - e_k|}{|y_k| + |e_k|}$$

Небольшая добавка 10^{-12} в знаменателе защищает от деления на ноль, когда и прогноз, и истинное значение одновременно равны нулю. Благодаря этому метрика остаётся корректной на всём диапазоне ряда.

Результат:

train: k=0..139 (140 точек); test: k=140..199 (60 точек)
min по train: -4.4995, max по train: 4.0511
Окон train: 132, окон test: 60

Базовый эксперимент: p=8, N=6, seed=0
эпохи=183 Es=9.445597e-05 сошлось=True
train: MAE=0.0690 RMSE=0.0831 sMAPE=8.58%
test: MAE=0.0667 RMSE=0.0814 sMAPE=7.48%

Исследование p: N=6, 5 seed
p= 2 эпохи 20000±0 тест. MAE 0.1889±0.0117 не сошлось 5/5
p= 4 эпохи 8872±262 тест. MAE 0.0664±0.0008 не сошлось 0/5
p= 8 эпохи 187±6 тест. MAE 0.0672±0.0012 не сошлось 0/5
p=16 эпохи 26±6 тест. MAE 0.0546±0.0025 не сошлось 0/5

Исследование N: p=8, 5 seed
N= 1 эпохи 212±6 тест. MAE 0.0679±0.0013 не сошлось 0/5
N= 2 эпохи 213±17 тест. MAE 0.0672±0.0007 не сошлось 0/5
N= 6 эпохи 187±6 тест. MAE 0.0672±0.0012 не сошлось 0/5
N=12 эпохи 191±3 тест. MAE 0.0674±0.0018 не сошлось 0/5

Лучшая по среднему тест. MAE: p=16, N=6, MAE=0.0546

Рекурсивный прогноз (p=16, N=6, steps=30): MAE=0.1117
размах train=8.5506, порог 5%=0.4275, первый шаг превышения: не превышен

Режим функционирования:
k=11 (train)
нормализованные входы: [0.9783, 0.8916, 0.7523, 0.5856, 0.4229, 0.2933, 0.2161, 0.1960]
нормализованный прогноз: 0.2202
прогноз (ряд): -2.6169
истинный x(k): -2.5989
абсолютная ошибка: 0.0180

k=47 (train)
нормализованные входы: [0.3837, 0.2401, 0.1107, 0.0243, 0.0008, 0.0458, 0.1487, 0.2860]
нормализованный прогноз: 0.4249
прогноз (ряд): -0.8667
истинный x(k): -0.8429
абсолютная ошибка: 0.0238

k=121 (train)
нормализованные входы: [0.7535, 0.8535, 0.9434, 0.9956, 0.9895, 0.9179, 0.7893, 0.6264]
нормализованный прогноз: 0.4644
прогноз (ряд): -0.5287
истинный x(k): -0.5674
абсолютная ошибка: 0.0387

k=148 (test)
нормализованные входы: [0.9879, 0.9966, 0.9464, 0.8574, 0.7573, 0.6726, 0.6214, 0.6080]
нормализованный прогноз: 0.6151
прогноз (ряд): 0.7602
истинный x(k): 0.8251
абсолютная ошибка: 0.0649

k=163 (test)
нормализованные входы: [0.1388, 0.0398, 0.0002, 0.0291, 0.1199, 0.2515, 0.3949, 0.5207]
нормализованный прогноз: 0.6153

прогноз (ряд): 0.7614
истинный x(k): 0.6948
абсолютная ошибка: 0.0666

k=192 (test)
нормализованные входы: [0.3068, 0.3435, 0.3485, 0.3195, 0.2688, 0.2189, 0.1956, 0.2202]
нормализованный прогноз: 0.2850
прогноз (ряд): -2.0626
истинный x(k): -1.9176
абсолютная ошибка: 0.1450

окно 1 (с выбросом в середине +3)
нормализованные входы: [0.6401, 0.8013, 0.9260, 0.9925, 1.3442, 0.9372, 0.8455, 0.7459]
нормализованный прогноз: 0.4612
прогноз (ряд): -0.5557

окно 2 (без выброса)
нормализованные входы: [0.3000, 0.3000, 0.3000, 0.3000, 0.3000, 0.3000, 0.3000, 0.3000]
нормализованный прогноз: 0.3209
прогноз (ряд): -1.7553

Введите номер k (8..199) или 8 чисел в исходной шкале: 47
  k=47 (train)
нормализованные входы: [0.3837, 0.2401, 0.1107, 0.0243, 0.0008, 0.0458, 0.1487, 0.2860]
нормализованный прогноз: 0.4249
прогноз (ряд): -0.8667
истинный x(k): -0.8429
абсолютная ошибка: 0.0238

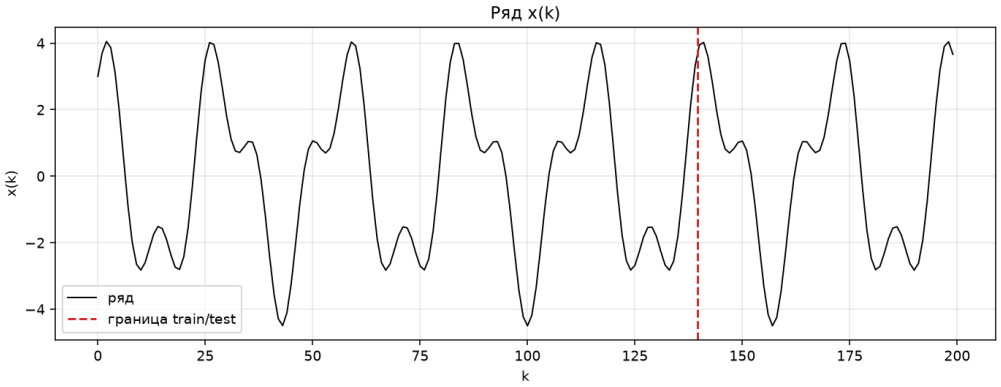
Введите номер k (8..199) или 8 чисел в исходной шкале: 148
  k=148 (test)
нормализованные входы: [0.9879, 0.9966, 0.9464, 0.8574, 0.7573, 0.6726, 0.6214, 0.6080]
нормализованный прогноз: 0.6151
прогноз (ряд): 0.7602
истинный x(k): 0.8251
абсолютная ошибка: 0.0649

Введите номер k (8..199) или 8 чисел в исходной шкале: -2.6 -2.4 -2.1 -1.8 5.0 -1.2 -0.9 -0.7
нормализованные входы: [0.2222, 0.2455, 0.2806, 0.3157, 1.1110, 0.3859, 0.4210, 0.4444]
нормализованный прогноз: 0.0678
прогноз (ряд): -3.9202

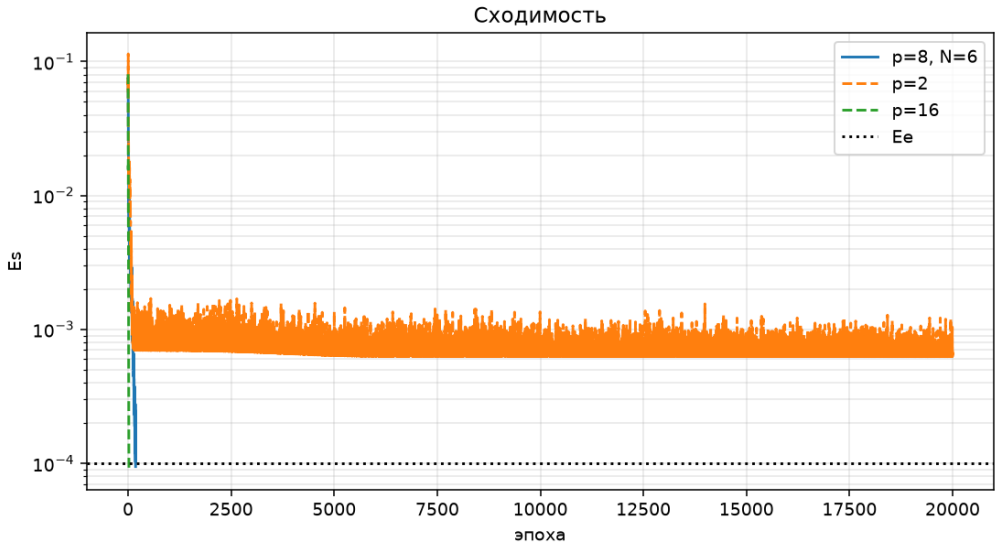
Введите номер k (8..199) или 8 чисел в исходной шкале: q

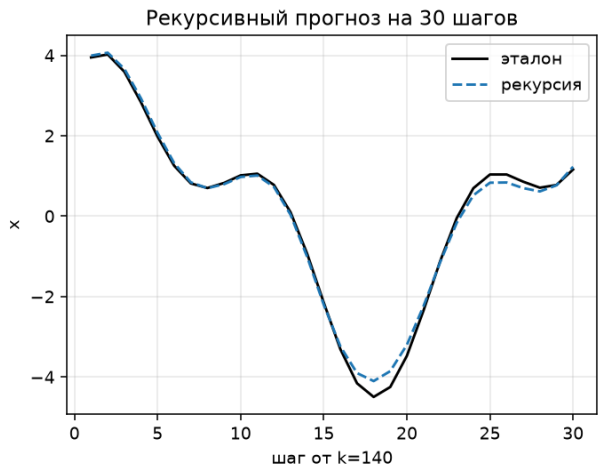
графики сохранены в: d:\python\M__pycache__\3kurs\мрзвис\figures

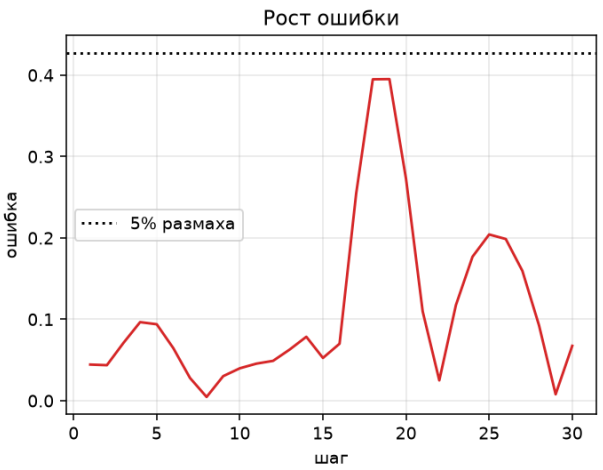
Графики:

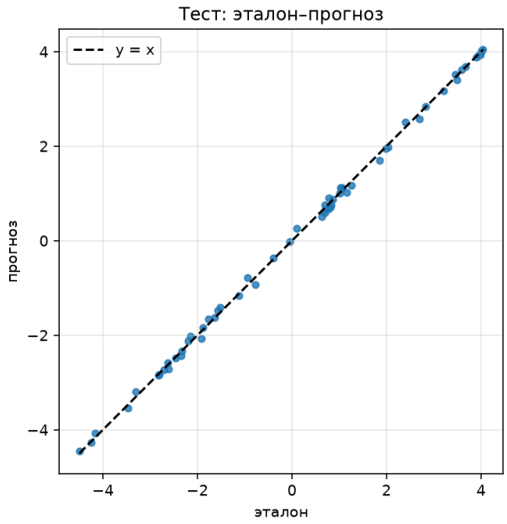

Ряд x(k)
x(k)
k
ряд
граница train/test


Ряд и одношаговый прогноз
x(k)
k
ряд
одношаговый прогноз
train/test

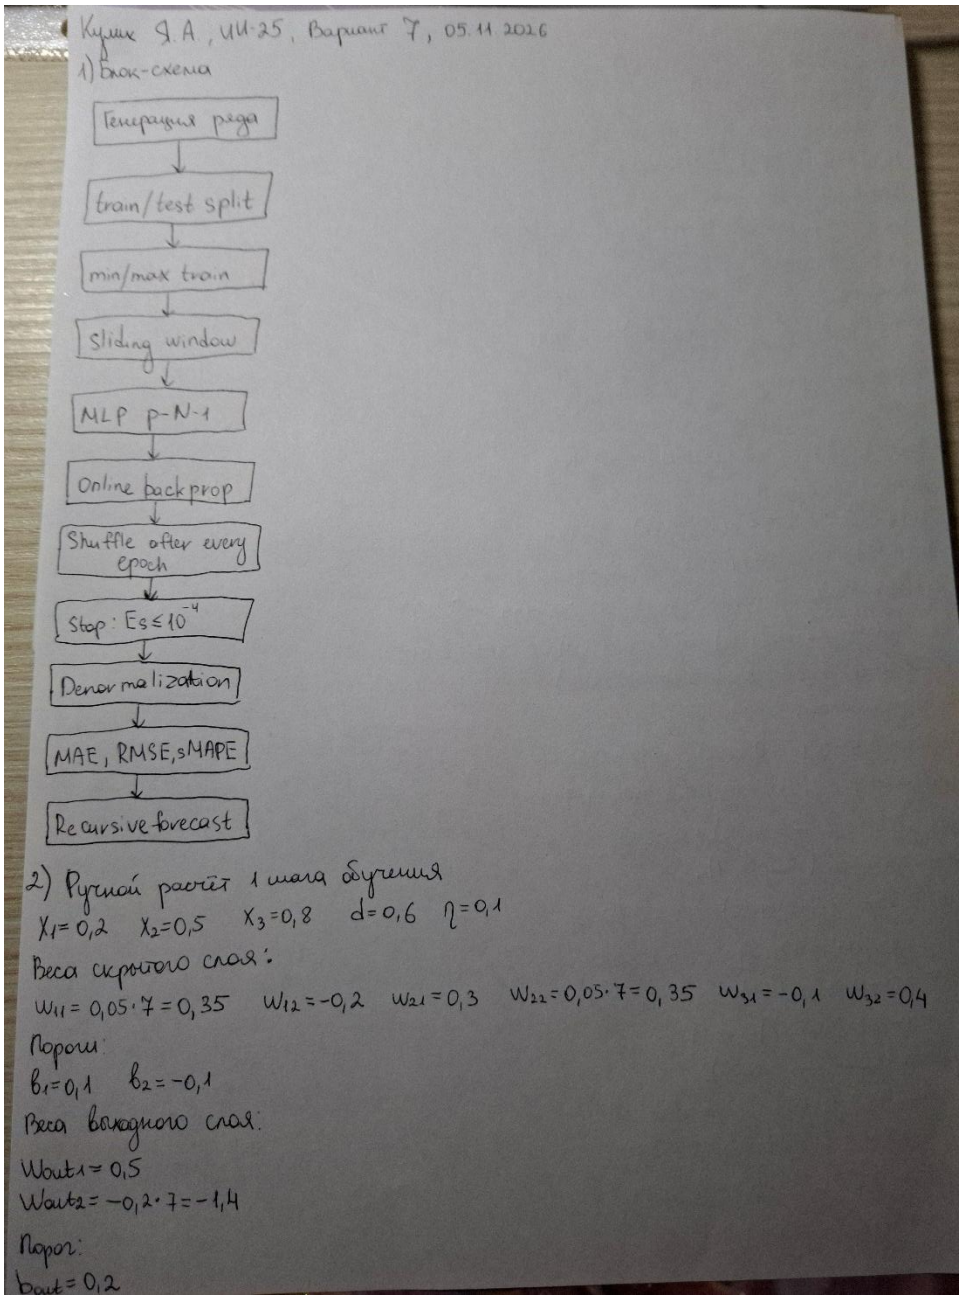

Сходимость
Es
эпоха
p=8, N=6
p=2
p=16
Ee

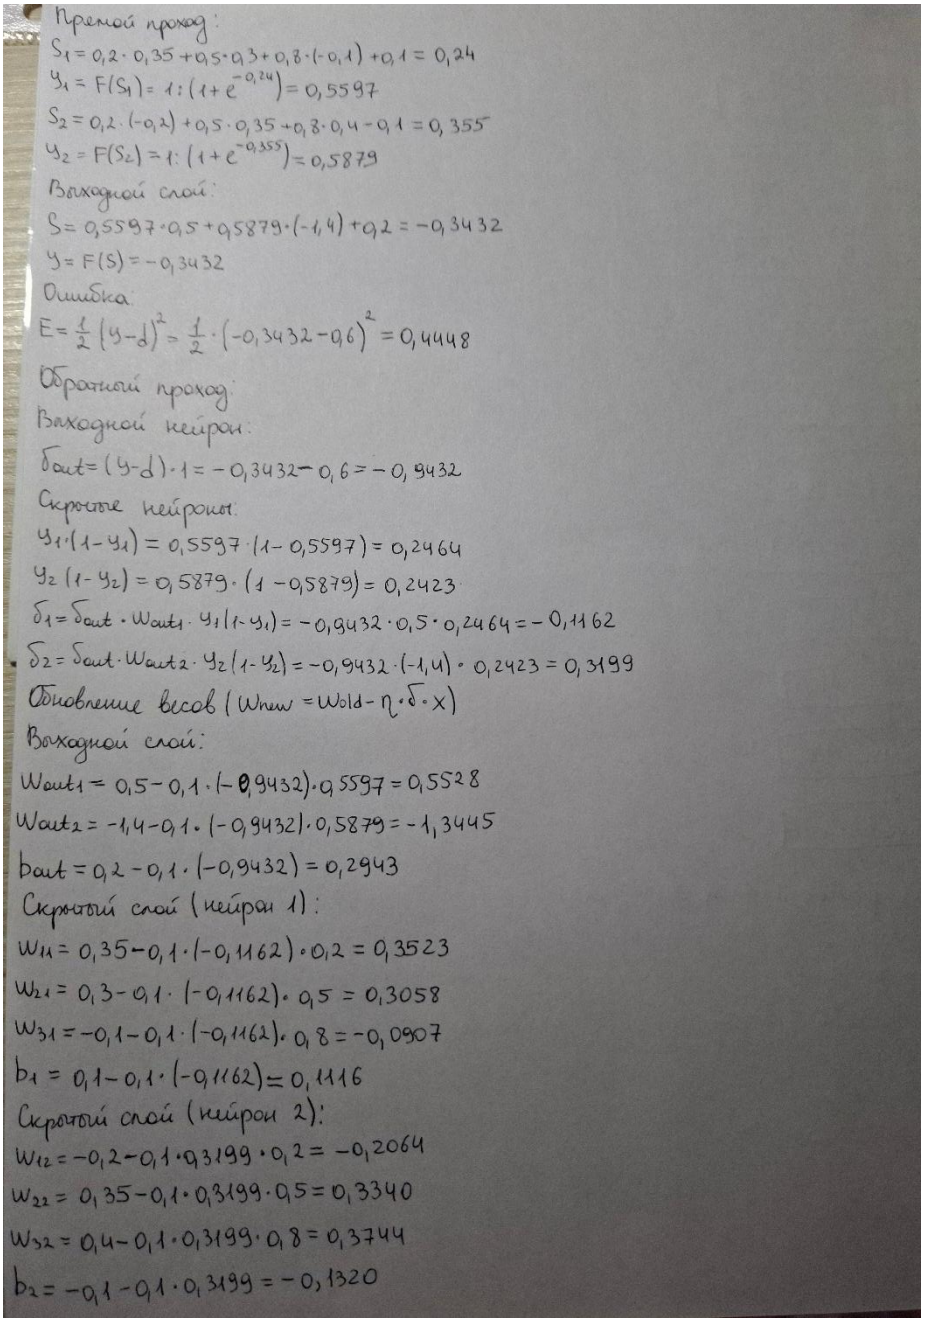

Рекурсивный прогноз на 30 шагов
x
шаг от k=140
эталон
рекурсия


Рост ошибки
ошибка
шаг
5% размаха


Тест: эталон–прогноз
y = x
прогноз
эталон
4
2
0
−2
−4
−4
−2
0
2
4

Рукописи:


Кулик Я.А., ИИ-25, Вариант 7, 05.11.2026
1) Блок-схема
Генерация ряда
train/test split
min/max train
Sliding window
MLP p-N-1
Online backprop
Shuffle after every epoch
Stop: Es ≤ 10^-4
Denormalization
MAE, RMSE, sMAPE
Recursive forecast
2) Ручной расчёт 1 шага обучения
X1 = 0,2 X2 = 0,5 X3 = 0,8 d = 0,6 η = 0,1
Веса скрытого слоя:
w11 = 0,05·7 = 0,35 w12 = −0,2 w21 = 0,3 w22 = 0,05·7 = 0,35 w31 = −0,1 w32 = 0,4
Пороги:
b1 = 0,1 b2 = −0,1
Веса выходного слоя:
Wout1 = 0,5
Wout2 = −0,2·7 = −1,4
Порог:
bout = 0,2



Вопросы:

1. Как размер окна p влияет на качество прогноза? При каком p ошибка перестаёт уменьшаться? Почему слишком маленькое окно (p = 2) не позволяет точно описать ряд из двух гармоник, а слишком большое не даёт выигрыша?

С увеличением p точность растёт лишь до определённого момента. При p=2 модель ни разу не достигла критерия остановки (5 из 5 запусков провалились, MAE 0.1889), по двум точкам нельзя восстановить сумму двух гармоник. На p=4 ошибка уже 0.0664, но сходимость долгая (около 8872 эпох). Дальше p=8 даёт 0.0672, а p=16 — 0.0546. Существенного улучшения после p=8 не происходит, при этом параметров становится вдвое больше. Избыточно большое окно не помогает, потому что соседние входы сильно коррелируют и только усложняют обучение.

2. Как число скрытых нейронов N влияет на точность и скорость обучения? Наблюдается ли переобучение (малая ошибка на обучении при заметно большей на тесте)? Достаточно ли минимального N, чтобы воспроизвести сумму двух гармоник?

Минимального N=1 уже достаточно (MAE 0.0679), чтобы описать сумму двух гармоник. Оптимальным оказался N=6 (0.0672), а N=12 дал почти то же (0.0674). Признаков

переобучения не видно: ошибки на train и test практически совпадают (0.0690 против 0.0667 в базовом эксперименте). Число эпох обучения от N почти не зависит (187–213).

3 Почему на выходе для задачи прогнозирования используется линейная функция, а не сигмоида (как в ЛР №3)? Что произошло бы при сигмоиде на выходе и при обучении на ненормализованных значениях?

Решаемая задача — это регрессия, и значения ряда лежат в [−4.4995; 4.0511], то есть вне интервала (0; 1). Сигмоида на выходе ограничила бы прогноз этим интервалом и не смогла бы выдать ни отрицательные значения, ни значения больше единицы. На ненормализованных данных она быстро насыщалась бы, градиент стремился к нулю и обучение остановилось, не достигнув критерия остановки.

4. Почему нормализация должна опираться только на обучающий участок? К чему приводит выход тестовых значений за диапазон [0; 1] и как это проявляется на ваших данных?

Считать min/max по всему ряду нельзя, так как тест «подсказывает» свои границы, это утечка данных. При нормировке по train тест может выйти за [0; 1], если его амплитуда больше. В данном варианте этого не случилось, но даже если бы вышло, то линейный выход спокойно бы это обработал (он экстраполирует), а сигмоида упёрлась бы в 0/1 и дала бы ошибку. На самом тестовом участке значения остались внутри [0; 1], поэтому метрики не пострадали.

5. Насколько устойчиво обучение к случайной инициализации весов (по сериям из 5 запусков)? Были ли запуски, не достигшие Ee за 20 000 эпох, и от чего это зависит (η, N, p)?

Все конфигурации, кроме p=2, сошлись во всех 5 запусках (0 провалов), а разброс test MAE не превышает 0.0025. Единственные провалы (5 из 5) относятся к p=2, и причина не в инициализации, а в недостатке информации во входе: двух отсчётов мало для двух гармоник. От N и конкретных весов устойчивость почти не зависит, при η=0.1 обучение стабильно во всех остальных случаях.

6. Как растёт ошибка рекурсивного многошагового прогноза с увеличением горизонта? Объясните накопление ошибки и сравните одношаговый прогноз с многошаговым. До какого горизонта прогноз можно считать пригодным?

Одношаговый прогноз (MAE = 0.0546 для лучшей конфигурации p=16, N=6) точен, потому что на каждом шаге подаются реальные значения. В рекурсивном (MAE = 0.1117) каждое предсказание подставляется обратно в окно, и его ошибка накапливается. Порог 5% размаха (0.4275) за 30 шагов не превышен, ошибка колеблется в пределах 0.00–0.39. На данном ряде прогноз пригоден на всём горизонте 30 шагов.

7. Как согласуется различие между ошибкой на обучающем и тестовом участках с понятием обобщающей способности? Какие меры (ранняя остановка, уменьшение N, добавление шума, увеличение обучающей выборки) могли бы улучшить обобщение? Что показал эксперимент с шумом?

Разрыв между train и test MAE мал (0.0690 против 0.0667), поэтому обобщающая способность хорошая, переобучения нет. Меры для улучшения: ранняя остановка (уже реализована через критерий Es ≤ 1e-4), уменьшение N (N=6 близко к оптимальному, N=1 даёт почти тот же результат), добавление шума (в работе не ставился) или увеличение выборки (140 точек маловато для p=16). Эксперимент с шумом не проводился, но теоретически он снизил бы разрыв train/test, но немного увеличил бы MAE на чистых данных.

Вывод: на основе персептрона p–N–1 решена задача прогнозирования ряда: освоены скользящее окно, нормализация, оценка одношагового и многошагового прогноза, исследовано влияние p и N на точность и скорость обучения.