Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №3

По дисциплине «Модели решения задач в интеллектуальных системах»

Тема: «Многослойный персептрон для XOR с ReLU на скрытых слоях: сравнение активационных функций»

Выполнила:
Студентка 4 курса
Группы ИИ-25
Мархель А.Д.
Проверила:
Андренко К.В.

Брест 2026

Цель работы: На основе многослойного персептрона архитектуры 2-2-1 из ЛР №2 исследовать влияние активационной функции ReLU (Rectified Linear Unit) на скрытом слое. Провести сравнительный анализ обучения сети с функцией активации Сигмоида (базовая конфигурация) и ReLU (новая конфигурация) по скорости сходимости, качеству обучения, форме разделяющей поверхности и устойчивости к инициализации весов.

Ход работы:

1. Взять за основу код многослойного персептрона 2-2-1 с функцией потерь BCE из ЛР №2.
2. Реализовать активационную функцию ReLU на скрытом слое и корректное обратное распространение ошибки для ReLU; на выходном слое оставить сигмоиду.
3. Обучить сеть на полной таблице истинности в двух конфигурациях: A (базовая) — сигмоида на всех слоях, BCE, цели 0/1; B (новая) — ReLU на скрытом слое, сигмоида на выходном, BCE, цели 0/1.
4. Критерий остановки для обеих конфигураций: суммарная ошибка $Es \le Ee$ (как в ЛР №2).
5. Для каждой конфигурации зафиксировать число эпох, итоговую суммарную ошибку, accuracy и среднюю абсолютную ошибку в шкале [c0; c1].
6. Провести не менее 5 запусков для каждой конфигурации с разными seed и сравнить устойчивость.
7. Построить график сходимости Es(эпоха) для обеих конфигураций на одних осях и диаграмму разброса числа эпох по запускам.
8. Построить карты выхода сети на плоскости $(A, B) \in [-10; 10]^2$ с обучающими точками и описать, как ReLU изменяет форму разделяющей поверхности.
9. Реализовать режим функционирования: ввод (A, B) из [−10; 10], вывод $\hat{y}$, значения в шкале [c0; c1] и класса; продемонстрировать на 4 обучающих и 3 дополнительных парах.
10. Составить таблицу сравнения (статистика по запускам, MAE для обеих конфигураций).
11. Ответить на вопросы и сформулировать вывод.

Вариант 6 (c0 = −9, c1 = 6)

A	B	A ⊕ B
−9	−9	−9
−9	6	6
6	−9	6
6	6	−9

Изменения по сравнению с ЛР №2

Без изменений остались: архитектура 2-2-1, функция потерь BCE с нормализацией целей $t = (y - c0)/(c1 - c0)$ ($c0 \to 0$, $c1 \to 1$) и обратным пересчётом $y = c0 + \hat{y}\cdot(c1 - c0)$, сигмоида на выходном нейроне, нормировка входов $(x + 10)/20$, начальные веса и пороги из $U[-0.5; 0.5]$, скорость обучения $\eta = 0.5$, онлайн-обучение с перемешиванием примеров в каждой эпохе, порог $Ee = 0.0852$ (эквивалентный по точности порогу MSE 0.001 из ЛР №1), максимум 50000 эпох. Конфигурация А — это конфигурация Б из ЛР №2 (при seed = 1…5 получены те же 953, 695, 797, 772, 961 эпох).

1) Активационная функция ReLU. На скрытом слое сигмоида заменена на ReLU:

$$\mathrm{ReLU}(z) = \max(0, z), \qquad \mathrm{ReLU}'(z) = 1 \text{ при } z > 0,\ 0 \text{ при } z \le 0$$

Производная в точке излома $z = 0$ принята равной 0 (так же поступают в стандартных библиотеках; на обучение это не влияет, так как точное попадание в 0 практически не происходит). Для сравнения: $\sigma'(z) = \sigma(z)(1 - \sigma(z)) \le 0.25$.

2) Обратное распространение для ReLU. Дельта выходного слоя для связки BCE + сигмоида не меняется (ЛР №2), меняется только множитель производной в дельте скрытого слоя:

$$\delta_out = t - \hat{y}$$

$$\delta_hid = (\delta_out \cdot W2^{T}) \odot f'(z_h)$$

$$\text{сигмоида: } f' = h(1 - h); \qquad \text{ReLU: } f' = 1 \text{ при } z_h > 0, \text{ иначе } 0$$

$$W2 \mathrel{+}= \eta \cdot h \otimes \delta_out,\ b2 \mathrel{+}= \eta \cdot \delta_out,\ W1 \mathrel{+}= \eta \cdot x \otimes \delta_hid,\ b1 \mathrel{+}= \eta \cdot \delta_hid$$

Для ReLU производная берётся по сумме z_h (до активации), а не по выходу h, как у сигмоиды. Корректность реализации проверена сравнением аналитического градиента (backprop) с численным (центральная разность по всем 9 параметрам на 4 примерах): максимальное расхождение $2.1\cdot10^{-10}$ для сигмоиды и $1.8\cdot10^{-10}$ для ReLU.

3) Мёртвые нейроны. Для каждого запуска программа считает, на скольких обучающих примерах скрытый нейрон активен ($z > 0$) в начале и в конце

обучения. Нейрон, у которого $z \leq 0$ на всех 4 примерах, считается мёртвым: его выход и градиент равны нулю, и его веса больше не меняются.

4) Число запусков. Так как ReLU-сеть сходится лишь в части запусков, основная серия увеличена до 10 запусков (seed 1…10), чтобы получить сошедшиеся экземпляры для анализа. Дополнительно (python xor_lab3.py --extra) для каждой активации выполнено по 50 запусков (seed 100…149) при $\eta \in \{0.5; 0.2; 0.1; 0.05\}$ и весах из $U[-0.5; 0.5]$ и $U[-1; 1]$, а также для LeakyReLU ($k = 0.01$). Эти серии обучаются векторизованно (все 50 сетей одновременно тем же онлайн-алгоритмом); совпадение с основной реализацией проверено: расхождение в числе эпох и Es равно 0.

Результат:

Запуск программы: представительные запуски обеих конфигураций (медиана по числу эпох среди сошедшихся запусков серии; для A — seed 1, для B — seed 9):

```
(.venv) PS C:\Users\user\Desktop\4 курс 1\MRZVS\3labPC> .venv\Scripts\python xor_lab3.py
Цели (BCE): c0 = -9 -> 0, c1 = 6 -> 1;  порог Ee = 0.0852;  η = 0.5;  веса из U[-0.5; 0.5]
Проверка backprop (аналитический градиент vs численный): сигмоида 2.1e-10, ReLU 1.8e-10

=== A: Сигмоида (seed = 1) ===
Критерий остановки Ee = 0.0852, максимум эпох = 50000
Эпох затрачено: 953  |  Сходимость достигнута: да
Итоговая суммарная ошибка Es = 0.085005
     A     B  A xor B (цель)         ŷ    выход сети   класс
    -9    -9              -9    0.0144        -8.783      -9
    -9     6               6    0.9815         5.723       6
     6    -9               6    0.9815         5.722       6
     6     6              -9    0.0309        -8.536      -9
Accuracy = 100.0%
Средняя абсолютная ошибка в шкале [c0; c1] = 0.3089
Активных примеров у скрытых нейронов (z > 0): в начале [0, 3], в конце [1, 3]

=== B: ReLU (seed = 9) ===
Критерий остановки Ee = 0.0852, максимум эпох = 50000
Эпох затрачено: 93  |  Сходимость достигнута: да
Итоговая суммарная ошибка Es = 0.081922
     A     B  A xor B (цель)         ŷ    выход сети   класс
    -9    -9              -9    0.0324        -8.514      -9
    -9     6               6    0.9922         5.882       6
     6    -9               6    0.9918         5.877       6
     6     6              -9    0.0361        -8.459      -9
Accuracy = 100.0%
Средняя абсолютная ошибка в шкале [c0; c1] = 0.3171
Активных примеров у скрытых нейронов (z > 0): в начале [4, 4], в конце [3, 2]
```

Пример неудачного запуска ReLU (seed 1): один нейрон мёртв с начала, второй в конце активен только на одном примере:

```
Пример неудачного запуска ReLU:
=== B: ReLU (seed = 1) ===
Критерий остановки Ee = 0.0852, максимум эпох = 50000
Эпох затрачено: 50000  |  Сходимость достигнута: нет
Итоговая суммарная ошибка Es = 2.089220
     A     B  A xor B (цель)         ŷ    выход сети   класс
    -9    -9              -9    0.6655         0.983       6
    -9     6               6    0.6655         0.983       6
     6    -9               6    0.6655         0.983       6
     6     6              -9    0.0000        -9.000      -9
Accuracy = 75.0%
Средняя абсолютная ошибка в шкале [c0; c1] = 5.0043
Активных примеров у скрытых нейронов (z > 0): в начале [0, 3], в конце [0, 1]
```

Серия из 10 запусков с разной инициализацией весов и таблица сравнения:

```
=== Серия запусков: конфигурация A: Сигмоида (Ee = 0.0852) ===
 seed    эпох  сошлась         Es  accuracy      MAE   мёртвые нейроны
    1     953       да   0.085005      100%   0.3089   -
    2     695       да   0.084973      100%   0.3088   -
    3     797       да   0.084955      100%   0.3088   -
    4     772       да   0.085149      100%   0.3094   -
    5     961       да   0.085147      100%   0.3094   -
    6     989       да   0.085174      100%   0.3094   -
    7    2446       да   0.085068      100%   0.3078   -
    8     820       да   0.084923      100%   0.3087   -
    9    1030       да   0.085084      100%   0.3092   -
   10     891       да   0.084891      100%   0.3084   -
Сошлось 10 из 10; эпох: min=695, max=2446, среднее=1035, медиана=922, std=481; MAE (сошедшиеся) = 0.3089

=== Серия запусков: конфигурация B: ReLU (Ee = 0.0852) ===
 seed    эпох  сошлась         Es  accuracy      MAE   мёртвые нейроны
    1   50000      нет   2.089220       75%   5.0043   1 (1 с начала)
    2   50000      нет   1.519018       75%   3.7500   нет
    3   50000      нет   3.038664       50%   7.5000   2 (2 с начала)
    4   50000      нет   2.089091       75%   4.9806   1 (1 с начала)
    5   50000      нет   3.038026       50%   7.5000   2 (1 с начала, 1 умер при обучении)
    6   50000      нет   2.081090       75%   4.9101   нет
    7   50000      нет   2.080529       75%   5.0887   1 (1 умер при обучении)
    8      91       да   0.084446      100%   0.3047   нет
    9      93       да   0.081922      100%   0.3171   нет
   10   50000      нет   2.077919       75%   4.9544   1 (1 с начала)
Сошлось 2 из 10; эпох: min=91, max=93, среднее=92, медиана=92, std=1; MAE (сошедшиеся) = 0.3109

Представительные запуски (медиана по эпохам среди сошедшихся): A - seed 1, B - seed 9

=== Таблица сравнения (статистика по серии) ===
показатель                          A: Сигмоида         B: ReLU
Сошлось                                10 из 10         2 из 10
Эпох: мин - макс                     695 - 2446         91 - 93
Эпох: среднее / медиана              1035 / 922         92 / 92
Эпох: std                                   481               1
Accuracy: среднее по запускам            100.0%           75.0%
MAE (сошедшиеся)                         0.3089          0.3109
```

Таблица 1 – Результаты представительных запусков

Показатель	**A: Сигмоида**	**B: ReLU**
seed	1	9
Порог Ee	0.0852	0.0852
Эпох до остановки	953	93
Критерий остановки достигнут	да	да
Итоговая суммарная ошибка Es	0.085005	0.081922
Accuracy (4 примера)	100%	100%
Средняя абсолютная ошибка в шкале [c0; c1]	0.3089	0.3171
Активных примеров у скрытых нейронов: начало → конец	[0, 3] → [1, 3]	[4, 4] → [3, 2]

Таблица 2 – Серия из 10 запусков (MAE — средняя абсолютная ошибка в шкале [c0; c1])

seed	A: эпох	A: Es	A: MAE	B: эпох	B: сошлась	B: Es	B: acc.	B: MAE	B: мёртвые нейроны
1	953	0.0850	0.3089	50000	нет	2.0892	75%	5.0043	1 (1 с начала)
2	695	0.0850	0.3088	50000	нет	1.5190	75%	3.7500	нет
3	797	0.0850	0.3088	50000	нет	3.0387	50%	7.5000	2 (2 с начала)
4	772	0.0851	0.3094	50000	нет	2.0891	75%	4.9806	1 (1 с начала)
5	961	0.0851	0.3094	50000	нет	3.0380	50%	7.5000	2 (1 с начала, 1 умер)
6	989	0.0852	0.3094	50000	нет	2.0811	75%	4.9101	нет
7	2446	0.0851	0.3078	50000	нет	2.0805	75%	5.0887	1 (1 умер)
8	820	0.0849	0.3087	91	да	0.0844	100%	0.3047	нет
9	1030	0.0851	0.3092	93	да	0.0819	100%	0.3171	нет
10	891	0.0849	0.3084	50000	нет	2.0779	75%	4.9544	1 (1 с начала)

Конфигурация A сошлась во всех 10 запусках (accuracy 100%). В последнем столбце указано число мёртвых нейронов в конце обучения: «с начала» — нейрон был мёртв уже при инициализации, «умер» — стал мёртвым в процессе обучения.

Таблица 3 – Таблица сравнения конфигураций по серии из 10 запусков

Статистика по 10 запускам	A: Сигмоида	B: ReLU
Сошлось из 10	10	2
Эпох: минимум – максимум	695 – 2446	91 – 93
Эпох: среднее / медиана	1035 / 922	92 / 92
Эпох: стандартное отклонение	481	1
Accuracy: среднее по всем запускам	100%	75%
Accuracy сошедшихся запусков	100%	100%
MAE: среднее по сошедшимся запускам	0.3089	0.3109
Запуски с мёртвыми нейронами	—	6 из 10

Дополнительное исследование устойчивости (по 50 запусков на каждую строку):

```
=== Дополнительное исследование: по 50 запусков (seed 100-149) ===
Проверка: векторизованное обучение совпадает с MLP221 (макс. расхождение 0.0e+00)
активация                η    веса  сошлось    мин  медиана  среднее   макс    std   неудачи: мёртв. с начала / умер / без мёртвых
Сигмоида               0.5    ±0.5    46/50    675      879     1389  11189   2062   -
Сигмоида               0.5    ±1.0    34/50    465      758      796   1358    191   -
Сигмоида               0.2    ±0.5    42/50   1654     2252     2660  16865   2256   -
Сигмоида               0.2    ±1.0    41/50   1150     1709     2107  13789   1899   -
Сигмоида               0.1    ±0.5    38/50   3375     4714     4888   8501   1102   -
Сигмоида               0.1    ±1.0    42/50   2322     3395     3706   8606   1191   -
Сигмоида              0.05    ±0.5    46/50   6843    11000    11069  19543   2742   -
Сигмоида              0.05    ±1.0    43/50   4645     6376     7680  28541   3961   -
ReLU                   0.5    ±0.5     8/50     79       96       98    116     13   27 / 7 / 8
ReLU                   0.5    ±1.0    10/50     72       96       95    117     15   27 / 7 / 6
ReLU                   0.2    ±0.5    15/50    192      276      280    369     49   27 / 4 / 4
ReLU                   0.2    ±1.0    13/50    178      247      254    356     47   27 / 5 / 5
ReLU                   0.1    ±0.5    17/50    379      565      605   1021    148   27 / 4 / 2
ReLU                   0.1    ±1.0    14/50    353      508      542   1064    165   27 / 5 / 4
ReLU                  0.05    ±0.5    19/50    760     1119     1351   3389    572   27 / 3 / 1
ReLU                  0.05    ±1.0    16/50    709     1044     1243   3731    681   27 / 4 / 3
LeakyReLU k=0.01       0.5    ±0.5    38/50     80     4366     5121  35304   7176   -
LeakyReLU k=0.01       0.2    ±0.5    40/50    192     2696     5722  19144   6232   -
LeakyReLU k=0.01       0.1    ±0.5    42/50    383     5153    10730  38479  12016   -
LeakyReLU k=0.01      0.05    ±0.5    35/50    765     1857    11940  49570  16120   -
```

Таблица 4 – Доля сходящихся запусков и число эпох (по сошедшимся) из 50 запусков, seed 100–149

Активация	**η**	**Веса**	**Сошлось**	**Медиана эпох**	**Макс. эпох**	**Неудачи ReLU: мёртв. с начала / умер / без мёртвых**
Сигмоида	0.5	±0.5	46/50	879	11189	—
Сигмоида	0.2	±0.5	42/50	2252	16865	—
Сигмоида	0.1	±0.5	38/50	4714	8501	—
Сигмоида	0.05	±0.5	46/50	11000	19543	—
Сигмоида	0.5	±1.0	34/50	758	1358	—
ReLU	0.5	±0.5	8/50	96	116	27 / 7 / 8
ReLU	0.2	±0.5	15/50	276	369	27 / 4 / 4
ReLU	0.1	±0.5	17/50	565	1021	27 / 4 / 2
ReLU	0.05	±0.5	19/50	1119	3389	27 / 3 / 1
ReLU	0.5	±1.0	10/50	96	117	27 / 7 / 6
LeakyReLU, k = 0.01	0.5	±0.5	38/50	4366	35304	—
LeakyReLU, k = 0.01	0.1	±0.5	42/50	5153	38479	—

Неудачные запуски сигмоиды (4 из 50 при $\eta = 0.5$ — те же seed 111, 112, 115, 127, что и в ЛР №2) — это локальные минимумы с accuracy 75%. У ReLU 27 из 50 сетей уже при инициализации имеют хотя бы один мёртвый нейрон: входы нормированы в [0.05; 0.8], т.е. положительны, и при весах из U[−0.5; 0.5] сумма $z \leq 0$ во всех четырёх точках получается примерно у каждого третьего нейрона. Такие сети не могут сойтись ни при каком η; уменьшение η уменьшает лишь число нейронов, умерших в процессе обучения.

Блок визуализации.

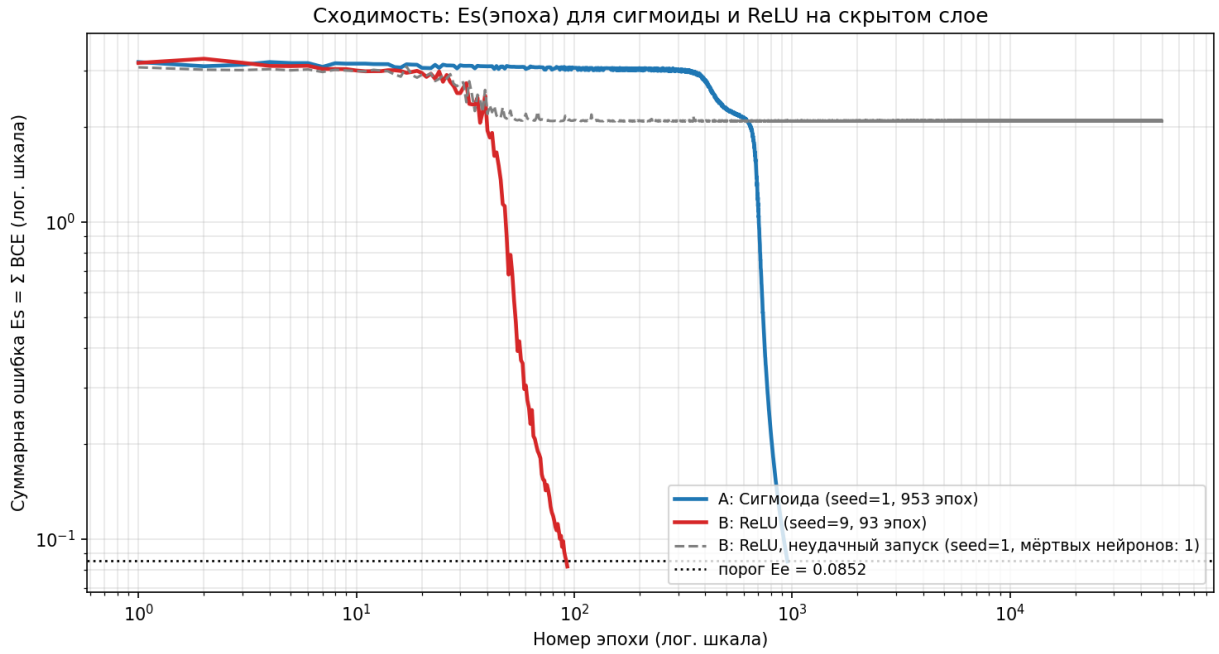


Рисунок 1 – График сходимости: суммарная ошибка Es от номера эпохи для представительных запусков A (seed 1) и B (seed 9); серым — неудачный запуск ReLU (seed 1); пунктир — порог Ee = 0.0852

Обе успешные кривые имеют форму «плато — обрыв». Начальная ошибка одинакова (Es ≈ 3.1–3.2, около $4 \cdot \ln 2 \approx 2.77$ — выходы ≈ 0.5). ReLU-сеть уходит с плато уже к 33-й эпохе (Es < 2.5) и достигает Ee на 93-й, сигмоида держится на плато до 441-й эпохи и достигает Ee на 953-й, т.е. в ≈ 10 раз позже. Неудачный запуск ReLU быстро опускается до Es ≈ 2.09 и дальше не меняется до лимита 50000 эпох: один нейрон мёртв, и сеть застревает в стационарном состоянии с правильной классификацией 3 из 4 примеров.

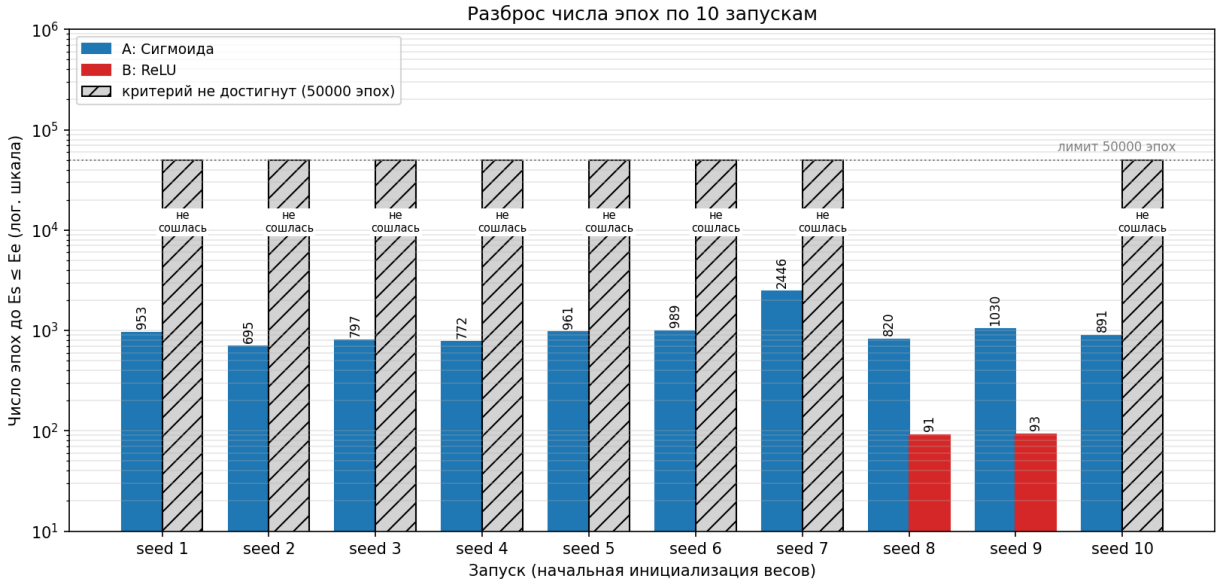


Рисунок 2 – Число эпох до достижения критерия остановки по 10 запускам (серая штриховка — критерий не достигнут за 50000 эпох)

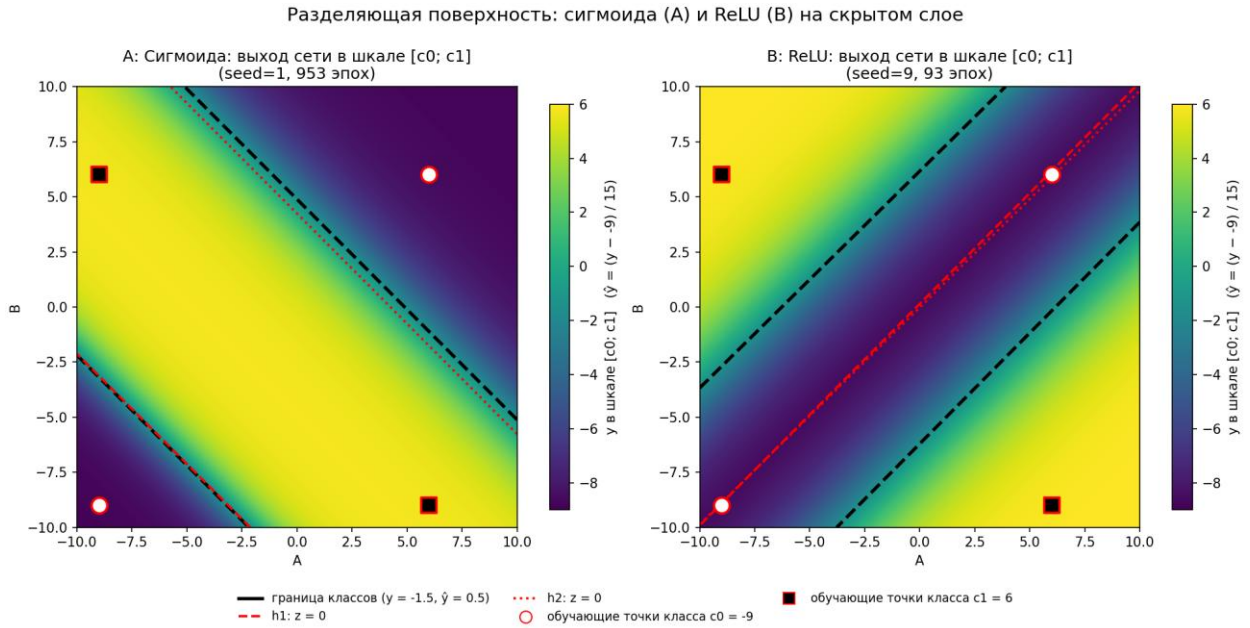


Рисунок 3 – Разделяющая поверхность для A (слева) и B (справа) на плоскости (A, B) ∈ [−10; 10]²: цвет — выход сети в шкале [c0; c1], чёрная линия — граница классов (ŷ = 0.5), красные — нулевые уровни скрытых нейронов (для ReLU — линии излома), точки — обучающая выборка

Таблица 5 – Линии скрытых нейронов (в координатах A, B) и характеристики поверхностей

Конфигурация	**Нейрон h1: z = 0**	**Нейрон h2: z = 0**	**Площадь класса c1 / переходной зоны**	**max |вес|**
A: Сигмоида	−0.414·A − 0.415·B − 5.027	−0.277·A − 0.277·B + 1.174	63.6% / 35.3%	10.41
B: ReLU	0.150·A − 0.150·B + 0.021	−0.153·A + 0.155·B + 0.003	47.7% / 55.2%	3.63

Переходная зона — доля площади квадрата, где $0.1 < \hat{y} < 0.9$. У сигмоидной сети обе линии скрытых нейронов параллельны прямой A + B = const, и класс c1 = 6 занимает диагональную полосу между ними (A + B ≈ −12 … 5), а точки класса c0 (−9, −9) и (6, 6) лежат в противоположных углах. ReLU-сеть нашла решение другого вида: обе линии излома практически совпадают с диагональю B = A, нейроны вычисляют h1 ≈ 3·max(0, A − B)/20 и h2 ≈ 3·max(0, B − A)/20, а логит выхода равен z_out ≈ 0.54·|A − B| − 3.4. Класс c0 — полоса |A − B| < 6.2 вдоль главной диагонали, класс c1 — два угла, где лежат (−9, 6) и (6, −9). На точках класса c0 оба нейрона почти выключены (h ≈ 0.01–0.03), на точках класса c1 включён ровно один (h ≈ 2.3).

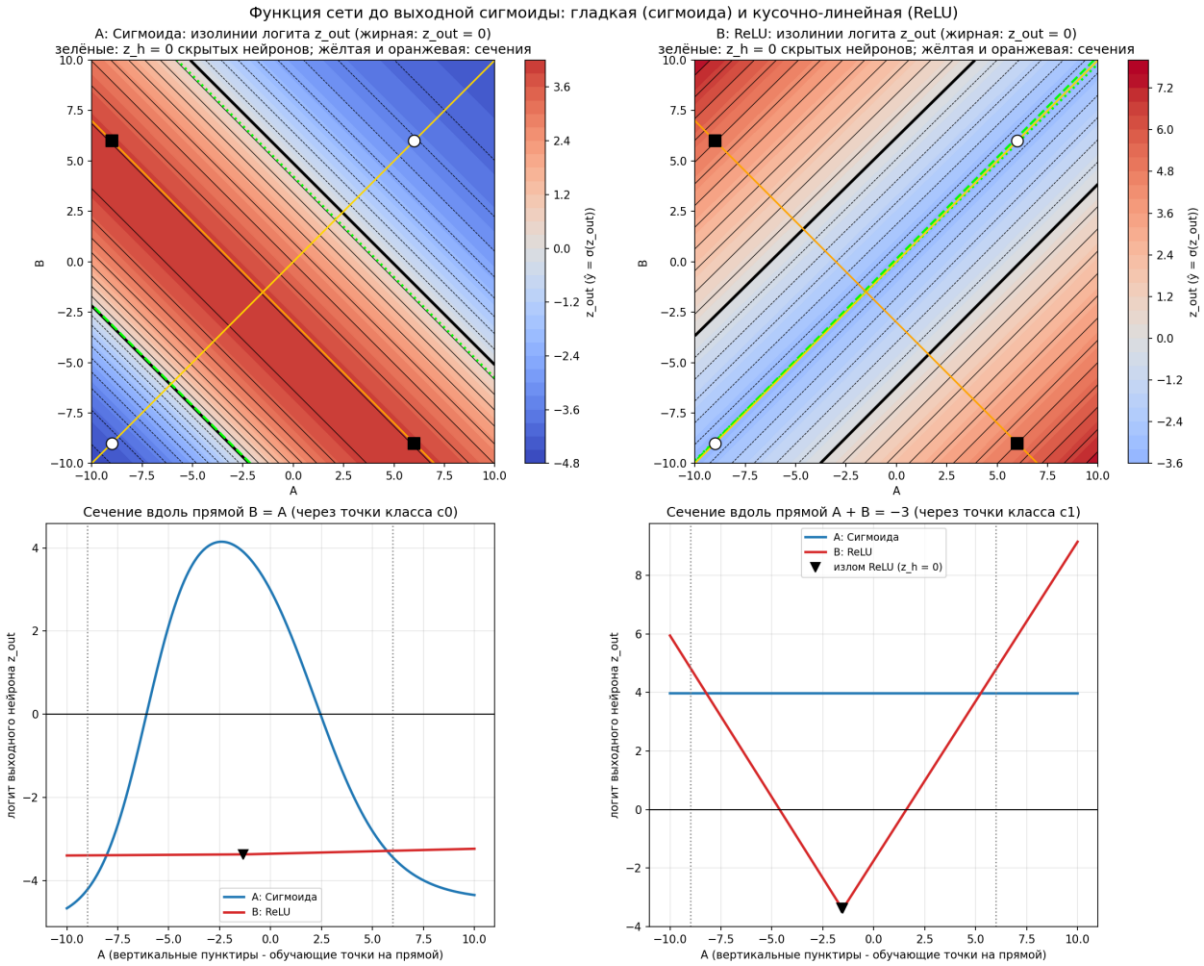


Рисунок 4 – Логит выходного нейрона z_out(A, B) (до выходной сигмоиды): изолинии (вверху) и сечения вдоль прямой B = A через точки класса c0 и вдоль прямой A + B = −3 через точки класса c1 (внизу)

Рисунок 4 показывает форму функции сети без «сглаживающей» выходной сигмоиды. У ReLU изолинии — строго прямые параллельные линии, а сечение поперёк линии излома (вдоль A + B = −3) — ломаная в форме буквы V из двух прямолинейных участков с изломом при A = B (чёрный треугольник). Поверхность z_out — две плоские грани, сходящиеся вдоль линии излома. Вдоль самой линии излома (сечение B = A) логит ReLU-сети почти постоянен. У сигмоидной сети сечение поперёк полосы (вдоль B = A) — гладкий колокол без изломов, а вдоль полосы — константа.

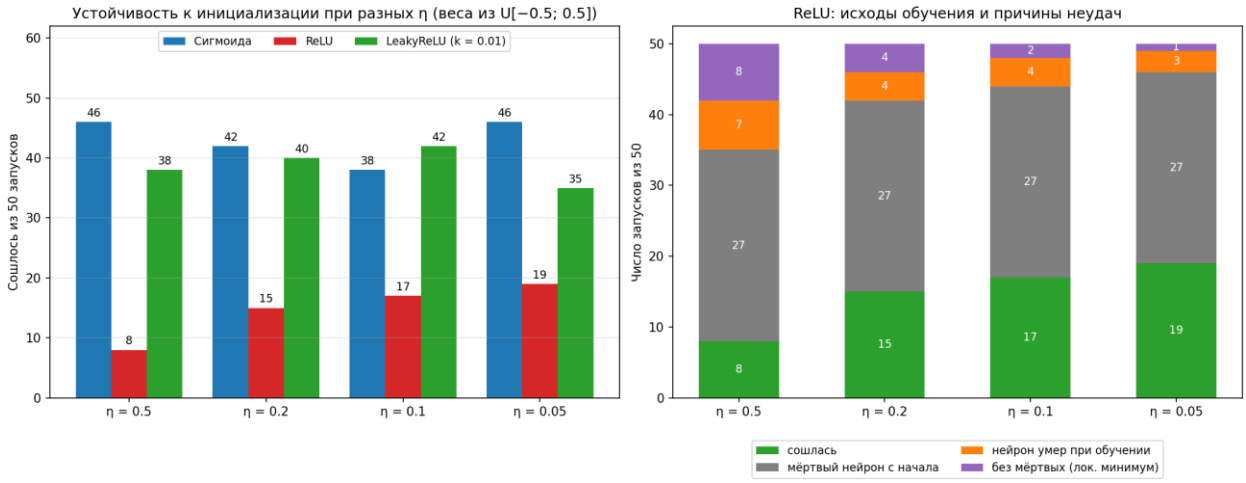


Рисунок 5 – Число сошедшихся запусков из 50 при разных η (слева) и исходы обучения ReLU-сети с причинами неудач (справа)

Сигмоида при всех η сходится в 38–46 запусках из 50, ReLU — только в 8–19, причём во всех случаях 27 неудач из 50 приходятся на сети, у которых нейрон мёртв с самого начала. Уменьшение η с 0.5 до 0.05 почти устраняет гибель нейронов в процессе обучения (7 → 3) и локальные минимумы (8 → 1), но удлиняет обучение (медиана 96 → 1119 эпох). LeakyReLU с $k = 0.01$ сохраняет ненулевой градиент при $z \leq 0$ и сходится в 35–42 запусках из 50, но медленнее (медиана 1857–5153 эпох): «оживление» нейрона через малый градиент k занимает много эпох.

Режим функционирования обученных сетей (представительные запуски; три последние строки проверочной таблицы и пары из интерактивного режима — вне обучающей выборки):

```
=== Режим функционирования (проверочные примеры) ===
     A     B     A: ŷ     A: y  A: класс     B: ŷ     B: y  B: класс
  -9.0  -9.0   0.0144   -8.783        -9   0.0324   -8.514        -9
  -9.0   6.0   0.9815    5.723         6   0.9922    5.882         6
   6.0  -9.0   0.9815    5.722         6   0.9918    5.877         6
   6.0   6.0   0.0309   -8.536        -9   0.0361   -8.459        -9
   0.0   0.0   0.9516    5.274         6   0.0337   -8.495        -9
   3.0  -7.0   0.9839    5.758         6   0.8880    4.320         6
  -5.0   8.0   0.7805    2.707         6   0.9773    5.659         6

=== Интерактивный режим ===
Введите пару чисел A, B из диапазона [-10; 10] через пробел
(например: 3 -5). Для выхода введите 'q'.
A B > 0 0
  A: Сигмоида : ŷ = 0.9516  y = 5.274  -> класс 6 (c1)
  B: ReLU     : ŷ = 0.0337  y = -8.495  -> класс -9 (c0)
A B > -10 10
  A: Сигмоида : ŷ = 0.9517  y = 5.275  -> класс 6 (c1)
  B: ReLU     : ŷ = 0.9995  y = 5.993  -> класс 6 (c1)
A B > 2.5 -4
  A: Сигмоида : ŷ = 0.9728  y = 5.592  -> класс 6 (c1)
  B: ReLU     : ŷ = 0.5420  y = -0.870  -> класс 6 (c1)
A B > q
```

Таблица 6 – Режим функционирования (A — сигмоида, B — ReLU)

A	B	A: ŷ	A: y ∈ [c0; c1]	A: класс	B: ŷ	B: y ∈ [c0; c1]	B: класс
−9	−9	0.0144	−8.783	−9	0.0324	−8.514	−9
−9	6	0.9815	5.723	6	0.9922	5.882	6
6	−9	0.9815	5.722	6	0.9918	5.877	6
6	6	0.0309	−8.536	−9	0.0361	−8.459	−9
0	0	0.9516	5.274	6	0.0337	−8.495	−9
3	−7	0.9839	5.758	6	0.8880	4.320	6
−5	8	0.7805	2.707	6	0.9773	5.659	6

На обучающих примерах обе сети дают верные классы. Вне обучающей выборки ответы определяются геометрией найденного решения: точка (0, 0) лежит в полосе класса c1 у сигмоидной сети (A + B = 0) и в полосе класса c0 у ReLU-сети (|A − B| = 0), поэтому сети отвечают по-разному. Таблица истинности задана только в четырёх вершинах и ответ в центре не определяет — оба решения корректны. Точки (3, −7), (−5, 8), (−10, 10) у обеих сетей относятся к c1. Для (2.5, −4) у ReLU-сети ŷ = 0.542 (|A − B| = 6.5 — у самой границы |A − B| ≈ 6.2), у сигмоидной — 0.973.

Вопросы для вывода:

1. Какая из активационных функций (Сигмоида или ReLU) обеспечила более быструю сходимость? Более устойчива?
2. Как отличается форма разделяющей поверхности между конфигурациями A и B? Наблюдаются ли ожидаемые кусочно-линейные границы для ReLU?
3. Почему ReLU часто предпочитают Сигмоиде в глубоких сетях? Подтверждается ли это на XOR?
4. Изменилась ли способность сети решать XOR при переходе на ReLU, или оба варианта успешно справляются благодаря архитектуре?
5. Есть ли случаи «мёртвых нейронов» при ReLU (нейронов, выдающих 0)? Как это повлияло на обучение?
6. Как выбор активационной функции соотносится с необходимостью многослойной архитектуры для XOR?
7. Что показывает визуализация разделяющей поверхности для обеих конфигураций? Совпадает ли граница между классами с ожидаемой для XOR?

1. Какая из активационных функций (Сигмоида или ReLU) обеспечила более быструю сходимость? Более устойчива?

Быстрее сходится ReLU: оба сошедшихся запуска основной серии достигли Ее за 91 и 93 эпохи против 695–2446 эпох (медиана 922) у сигмоиды, т.е. примерно в 10 раз быстрее. Серия из 50 запусков это подтверждает: медиана 96 эпох у ReLU против 879 у сигмоиды при одинаковых $\eta = 0.5$ и инициализации. Причина видна на графике сходимости: ReLU-сеть покидает плато к 33-й эпохе, сигмоидная — к 441-й. Производная ReLU активного нейрона равна 1, а у сигмоиды ≤ 0.25, поэтому шаги по весам скрытого слоя у ReLU крупнее и не гасятся насыщением.

Более устойчива сигмоида: 10 из 10 запусков основной серии против 2 из 10 у ReLU, в серии из 50 — 46 против 8 (при $\eta = 0.05$ у ReLU — 19 из 50). Неудачи сигмоиды редки и связаны с локальными минимумами (accuracy 75%). Неудачи ReLU массовые и в основном вызваны мёртвыми нейронами: 27 из 50 сетей имеют мёртвый нейрон уже при инициализации, ещё 3–7 теряют нейрон в процессе обучения. Итог: ReLU — быстрее, сигмоида — надёжнее; по качеству сошедшихся запусков конфигурации одинаковы (accuracy 100%, MAE 0.3109 против 0.3089).

2. Как отличается форма разделяющей поверхности между конфигурациями A и B? Наблюдаются ли ожидаемые кусочно-линейные границы для ReLU?

У сигмоидной сети (A) выход — гладкая функция координат. Класс c1 = 6 занимает диагональную полосу вдоль A + B = const между двумя линиями скрытых нейронов, переход между классами плавный (сечение логита поперёк полосы — гладкий колокол), выход быстро насыщается (переходная зона 35% площади).

У ReLU-сети (B) функция до выходной сигмоиды кусочно-линейная: логит $z_out \approx 0.54 \cdot |A - B| - 3.4$ состоит из двух плоских граней, сходящихся вдоль линии излома A = B. Это ожидаемая кусочно-линейная форма: изолинии логита — прямые, сечение поперёк излома — ломаная в форме V (рисунок 4). Граница классов — две прямые $|A - B| \approx 6.2$: так как линии излома обоих нейронов почти совпали, каждая ветвь границы целиком лежит в одной грани, и ломаная вырождается в два прямых отрезка. Выход ReLU-сети меняется медленнее и линейно по логиту (переходная зона 55% площади, max |вес| = 3.6 против 10.4 у сигмоиды).

Кроме формы отличается и тип решения: сигмоидная сеть выделила полосой класс c1, а ReLU-сеть — класс c0 (функция $|A - B|$). Поэтому на точке (0, 0), не входящей в обучающую выборку, сети отвечают по-разному.

3. Почему ReLU часто предпочитают Сигмоиде в глубоких сетях? Подтверждается ли это на XOR?

В глубоких сетях ReLU предпочитают потому, что её производная в активной области равна 1. Градиент не затухает при обратном распространении через много слоёв (у сигмоиды он умножается на $\sigma' \leq 0.25$ на каждом слое), нет насыщения при больших суммах, вычисление дешёвое, активации разреженные. Мёртвые нейроны в широких сетях не критичны: нейронов много, и гибель части из них компенсируется остальными; к тому же используют He-инициализацию и центрированные входы.

На XOR это подтверждается частично. Преимущество в скорости подтверждено даже для одного скрытого слоя: ≈ 10 раз меньше эпох. Но в сети 2-2-1 нет избыточности: для решения XOR нужны оба скрытых нейрона, и потеря одного делает задачу нерешаемой. Поэтому главный недостаток ReLU — мёртвые нейроны — здесь проявляется в полной мере, и по надёжности ReLU сильно уступает сигмоиде (8 из 50 против 46 из 50). Проблема затухания градиента, ради которой и выбирают ReLU, в сети с одним скрытым слоем практически отсутствует.

4. Изменилась ли способность сети решать XOR при переходе на ReLU, или оба варианта успешно справляются благодаря архитектуре?

Способность представить решение не изменилась: архитектура 2-2-1 с нелинейной активацией скрытого слоя решает XOR при обеих функциях. Сошедшиеся ReLU-сети классифицируют все 4 примера верно (accuracy 100%, MAE 0.31, как у сигмоиды). Двух ReLU-нейронов достаточно, чтобы построить функцию $|A - B|$, отделяющую диагональ от антидиагонали.

Изменилась вероятность найти это решение градиентным обучением. Неудачные запуски ReLU — не ограничение архитектуры, а проблема оптимизации: при мёртвом нейроне сеть фактически становится 2-1-1. Её выход — монотонная функция одной линейной комбинации входов, т.е. однослойная модель, которая XOR решить не может (accuracy 75%). С двумя мёртвыми нейронами выход почти постоянен (accuracy 50%). То есть обе конфигурации решают XOR благодаря архитектуре, но только пока оба скрытых нейрона работают.

5. Есть ли случаи «мёртвых нейронов» при ReLU (нейронов, выдающих 0)? Как это повлияло на обучение?

Да. В основной серии мёртвые нейроны есть в 6 из 10 запусков. В 5 запусках нейрон мёртв с самой инициализации (seed 1, 3, 4, 5, 10; в seed 3 — оба нейрона). В 2 запусках нейрон умер в процессе обучения: в seed 7 нейрон, активный вначале на 2 примерах, к концу выключился на всех, а в seed 5 так погиб второй нейрон, и выход стал постоянным ($\hat{y} \approx 0.504$). Ещё 2 неудачных запуска (seed 2, 6) — без мёртвых нейронов, но один из нейронов активен только на части примеров, и сеть застряла в локальном минимуме. В серии из 50 запусков при $\eta = 0.5$: 27 сетей с мёртвым нейроном с начала, 7 — с умершим при обучении, 8 — без мёртвых, но не сошлись, 8 — сошлись.

Влияние на обучение решающее. Градиент мёртвого нейрона равен нулю, его веса не меняются, и до лимита 50000 эпох ошибка стоит на одном уровне: $E_s \approx 2.08$–2.09 при одном мёртвом нейроне (верны 3 из 4 примеров) и $E_s \approx 3.04$ при двух (выход почти постоянный, верны 2 из 4). Пример seed 1: нейрон h1 мёртв с начала ($z \leq 0$ на всех примерах), h2 к концу активен только на (6, 6). В итоге выход $\hat{y} = 0.6655$ одинаков для трёх остальных точек.

Причина частой гибели — положительные входы (0.05…0.8) и маленькая сеть: нейрон мёртв, если его линия излома не пересекает квадрат с обучающими точками. Помогают меньший шаг обучения (19 из 50 при $\eta = 0.05$), LeakyReLU (38–42 из 50), а также центрирование входов, небольшие положительные начальные пороги и больше нейронов в скрытом слое.

6. Как выбор активационной функции соотносится с необходимостью многослойной архитектуры для XOR?

Необходимость скрытого слоя определяется задачей, а не активацией: XOR линейно неразделима (ЛР №1, №2). Любой одиночный нейрон, выход которого — монотонная функция одной линейной комбинации входов, строит одну прямую и XOR не решает — ни с сигмоидой, ни с ReLU. Требование к активации скрытого слоя одно — она должна быть нелинейной: с линейной активацией многослойная сеть сводится к однослойной. ReLU хоть и кусочно-линейна, но нелинейна благодаря излому, поэтому её достаточно: два ReLU-нейрона дают $|A - B|$.

Выбор активации влияет на скорость, надёжность обучения и форму границы, но не на сам вывод о необходимости многослойной архитектуры. Эксперимент с ReLU даже подчёркивает этот вывод: как только один из двух скрытых нейронов умирает, сеть фактически теряет скрытый слой и XOR больше не решается (accuracy 75%).

7. Что показывает визуализация разделяющей поверхности для обеих конфигураций? Совпадает ли граница между классами с ожидаемой для XOR?

Обе карты правильно разделяют обучающую выборку: точки (−9, −9) и (6, 6) класса c0 лежат в одной области, (−9, 6) и (6, −9) класса c1 — в другой, и граница проходит между диагональю и антидиагональю квадрата. Граница сформирована скрытым слоем: каждый нейрон задаёт свою прямую (красные линии), а выходной нейрон комбинирует полуплоскости. У сигмоидной сети класс c1 — пересечение двух полуплоскостей (полоса вдоль $A + B = \text{const}$). У ReLU-сети класс c1 — объединение двух полуплоскостей $A - B > 6.2$ и $B - A > 6.2$, а класс c0 — полоса между ними. Оба варианта соответствуют ожидаемой для XOR структуре: два разделяющих отрезка, выделяющих диагональную полосу одного класса.

Визуально конфигурации различаются ориентацией полосы (у сигмоиды — вдоль антидиагонали, у ReLU — вдоль главной диагонали), шириной переходной зоны (35% против 55%) и характером функции: у сигмоиды гладкий профиль, у ReLU — плоские грани с изломом (рисунки 3 и 4). Границы ReLU-сети прямолинейные, как и следует для кусочно-линейной функции.

Вывод: Замена сигмоиды на ReLU в скрытом слое многослойного персептрона 2-2-1 для XOR с числовыми классами $c0 = -9$ и $c1 = 6$ (BCE, сигмоида на выходе, $\eta = 0.5$, веса из $U[-0.5; 0.5]$) ускорила обучение примерно

в 10 раз: сошедшиеся ReLU-сети достигли Ee за 91–93 эпохи против 695–2446 у сигмоиды (медиана по 50 запускам — 96 против 879). Качество сошедшихся сетей одинаково: accuracy 100%, MAE в шкале [c0; c1] ≈ 0.31. Однако устойчивость к инициализации у ReLU значительно хуже: сошлись 2 из 10 запусков (8 из 50) против 10 из 10 (46 из 50) у сигмоиды. Основная причина — мёртвые нейроны, которые при положительных нормированных входах возникают уже при инициализации у половины сетей. Меньший шаг обучения и LeakyReLU частично устраняют проблему. Разделяющая поверхность ReLU-сети кусочно-линейная (две плоские грани логита с изломом по линии A = B, граница — прямые |A − B| ≈ 6.2), у сигмоиды — гладкая полоса. Обе конфигурации решают XOR благодаря скрытому слою, а выбор активации влияет на скорость, надёжность обучения и форму границы.