Министерство образования Республики Беларусь
Учреждение образования
«Брестский Государственный технический университет»
Кафедра ИИТ

Лабораторная работа №4

По дисциплине «Модели решения задач в ИС»

Тема: «Многослойный персептрон для прогнозирования временного ряда: влияние размера окна и числа скрытых нейронов»

Выполнил:
Студент 4 курса
Группы ИИ-25
Редькович С. В.
Проверила:
Андренко К. В.

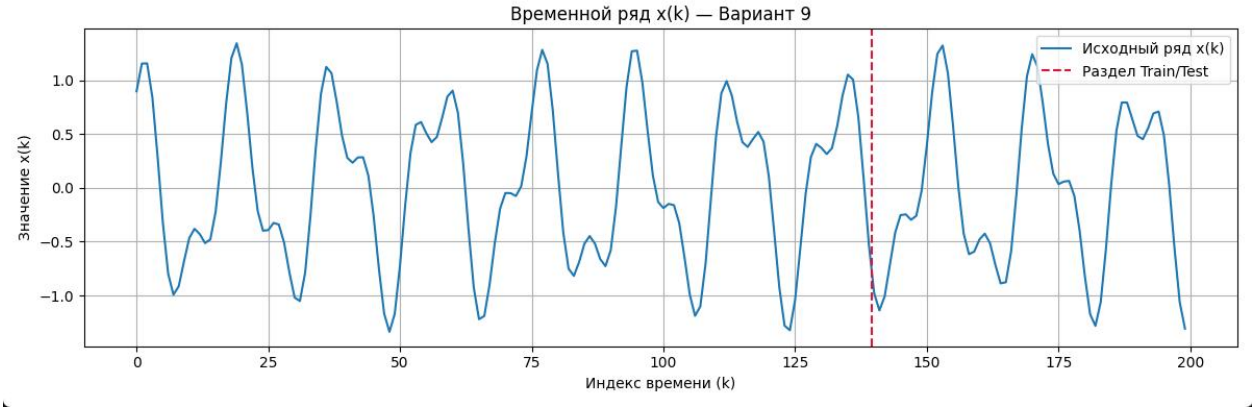
Брест 2026

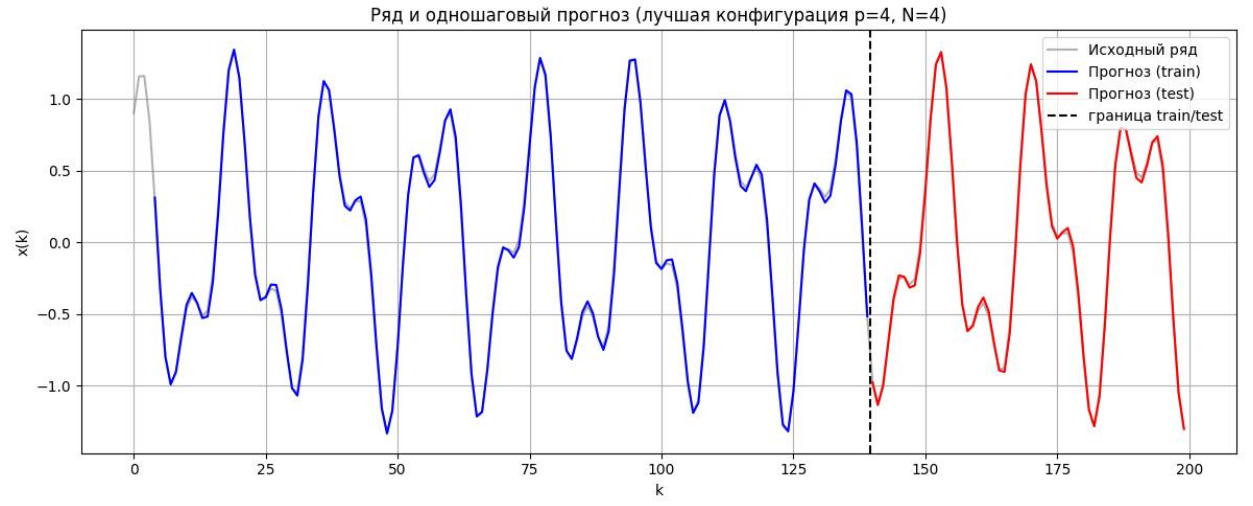
Цель работы: на основе многослойного персептрона p–N–1 решить задачу прогнозирования временного ряда. Научиться формировать обучающую выборку методом скользящего окна, нормализовать данные, оценивать качество одношагового и многошагового прогноза и исследовать влияние размера окна p и числа нейронов скрытого слоя N на точность прогноза и скорость обучения.

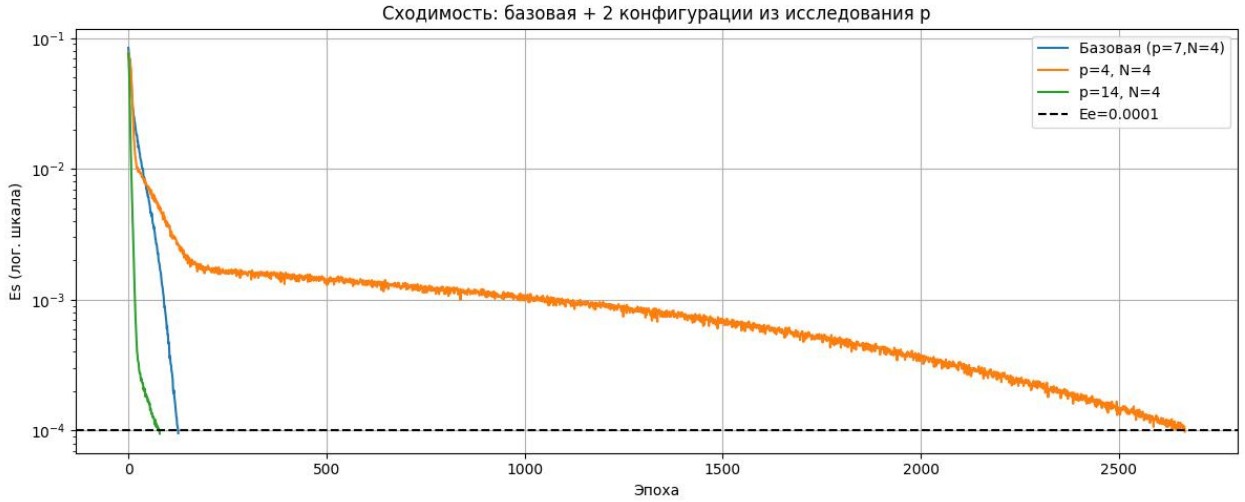
Вариант: 9

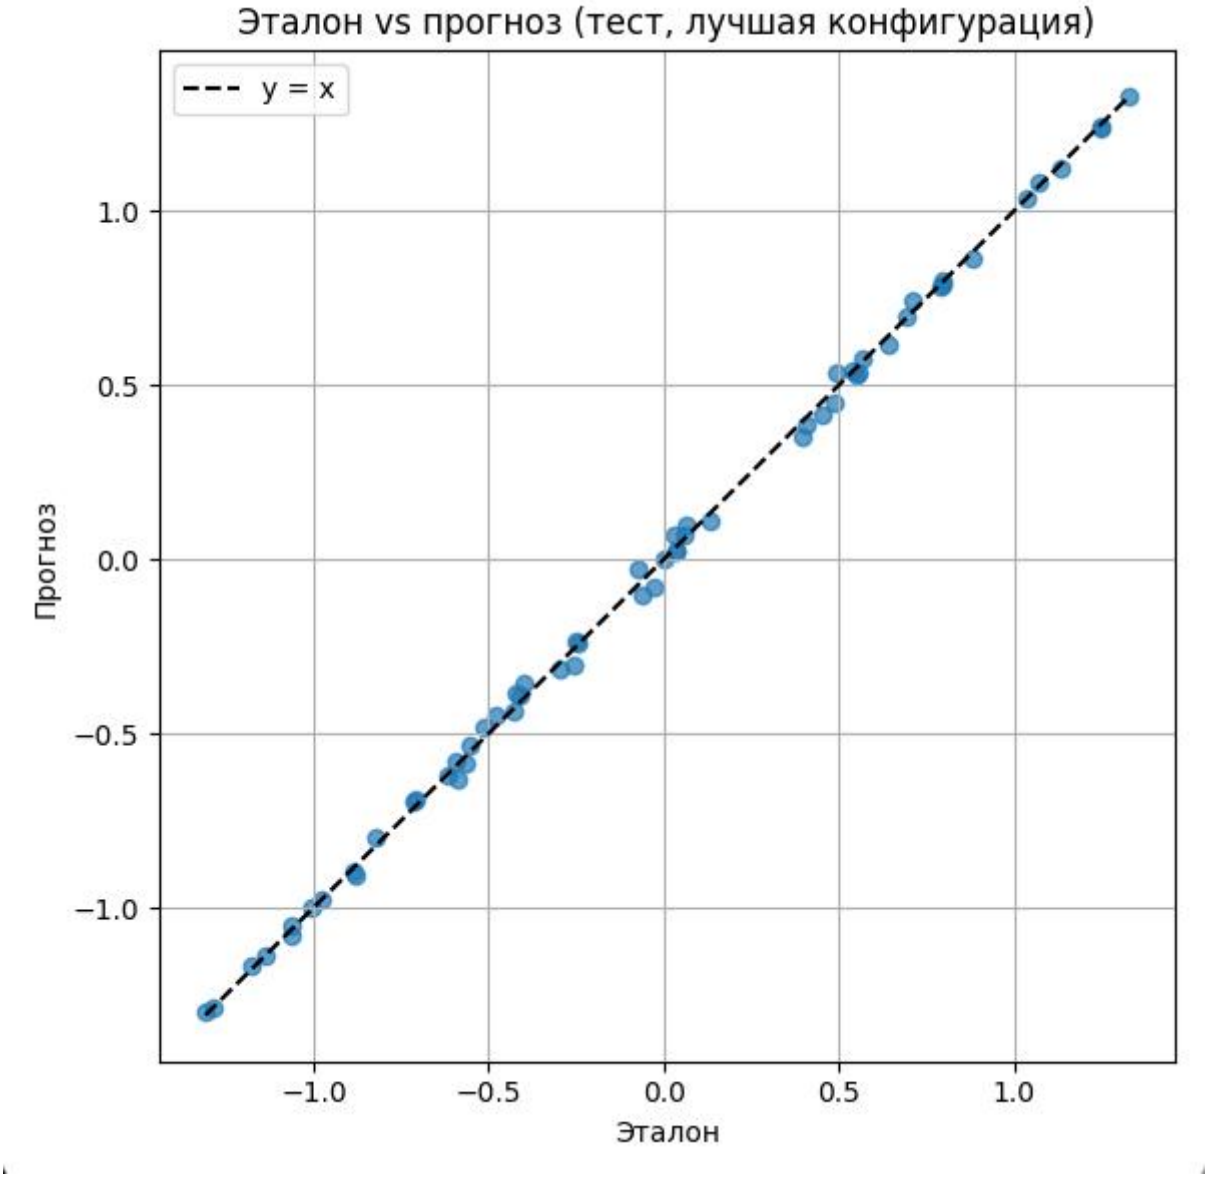
9	0.9	0.33	0.45	0.75	7	4

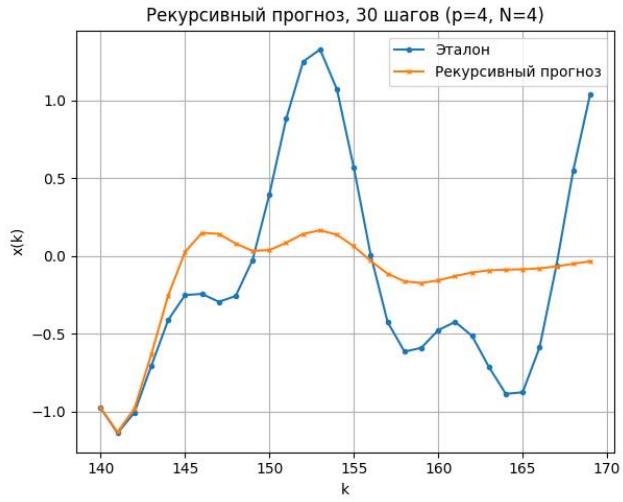
Результат:

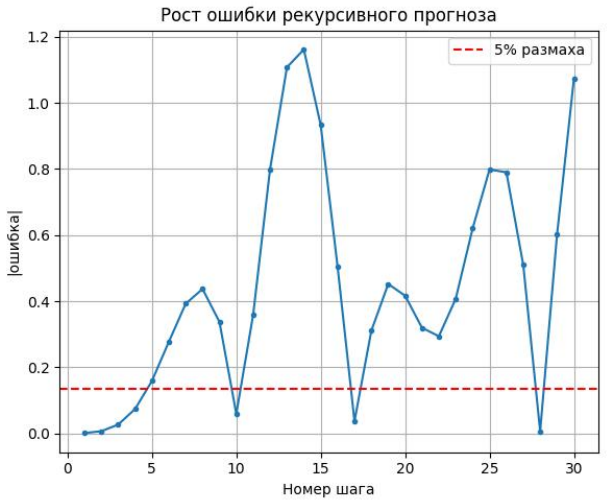





Сходимость: базовая + 2 конфигурации из исследования p
Базовая (p=7,N=4)
p=4, N=4
p=14, N=4
Ee=0.0001
Es (лог. шкала)
Эпоха


Эталон vs прогноз (тест, лучшая конфигурация)
y = x
Прогноз
Эталон





Вопросы:

1. Размер окна p. При p=2 качество плохое: тестовый MAE 0,182, и ни один из пяти запусков не достиг Ee за 20 000 эпох. Уже при p=4 тестовый MAE падает до 0,041, а при p=7 и p=14 остаётся около 0,039, так что ошибка перестаёт уменьшаться на p=4. Меняется только скорость обучения: 1220 эпох при p=4, около 140 при p=7 и около 28 при p=14. Окно в 2 значения не годится потому, что каждая гармоника подчиняется правилу «следующее значение = 2cos(ω)·предыдущее − то, что было перед ним», для которого нужны два прошлых значения. У ряда две гармоники, поэтому нужно минимум четыре значения. По двум сеть не может отделить одну гармонику от другой, и ошибка застревает на плато около 1,5·10^-3. Слишком большое окно точность не повышает, потому что всё нужное уже содержится в четырёх значениях, а остальные только повторяют информацию. Лишние входы ускоряют обучение, но все запуски всё равно останавливаются на одном уровне Es≈10^-4, поэтому и MAE получается почти одинаковым.

2. Число скрытых нейронов N. На точность N влияет слабо: тестовый MAE равен 0,0448 при N=1, 0,0412 при N=2, 0,0392 при N=4 и 0,0390 при N=8, то есть выигрыш заканчивается на N=4. На скорость обучения N почти не влияет (145, 140, 142 и 138 эпох). Переобучения нет: ошибки на обучении и на тесте практически совпадают, например при N=8 они равны 0,0380 и 0,0390. Минимального N=1 для заданной точности достаточно: все пять запусков сошлись. Вероятная причина в том, что следующее значение ряда линейно выражается через предыдущие, а сигмоида при малых весах работает почти как линейная функция, поэтому одного нейрона с линейным выходом хватает. При более строгом Ee или более сложном ряде нейронов понадобилось бы больше.

3. Линейный выход вместо сигмоиды. В ЛР №3 нужно было получить класс 0 или 1, то есть число между 0 и 1, и сигмоида для этого подходит. В регрессии выход может быть любым числом, и сигмоида создаёт проблемы. Она не может выдать значение за пределами диапазона обучающих данных, например новый пик выше прежних. У неё почти нулевая производная около 0 и 1, поэтому обучение замедляется как раз на пиках и впадинах. На ненормализованных данных, у нас от −1,35 до 1,35, сигмоида не могла бы выдавать ни отрицательные числа, ни числа больше 1, и ошибка осталась бы большой. Кроме того, крупные ненормализованные входы загоняют скрытые сигмоиды в насыщение. У линейного выхода градиент простой: $\delta = y - e$.

4. Нормализация только по обучающему участку. Тестовый участок моделирует будущее, которого на момент обучения нет. Если взять минимум и максимум по всему ряду, в обучение просочится информация о тесте (утечка данных), и метрики станут оптимистичными. В реальном прогнозе будущих значений просто нет. Если тестовые значения выходят за диапазон от 0 до 1, сеть получает входы вне того диапазона, на котором училась, и ошибается сильнее. На наших данных этого не произошло: нормализованный тестовый участок лежит в пределах от 0,0000 до 1,0000, потому что обучающая часть уже содержит полный размах колебаний. Выход за диапазон виден только на пользовательском окне с выбросом: нормализованный вход равен 1,85, прогноз получается −0,48 в нормализованной шкале при настоящем значении вне обучающего диапазона.

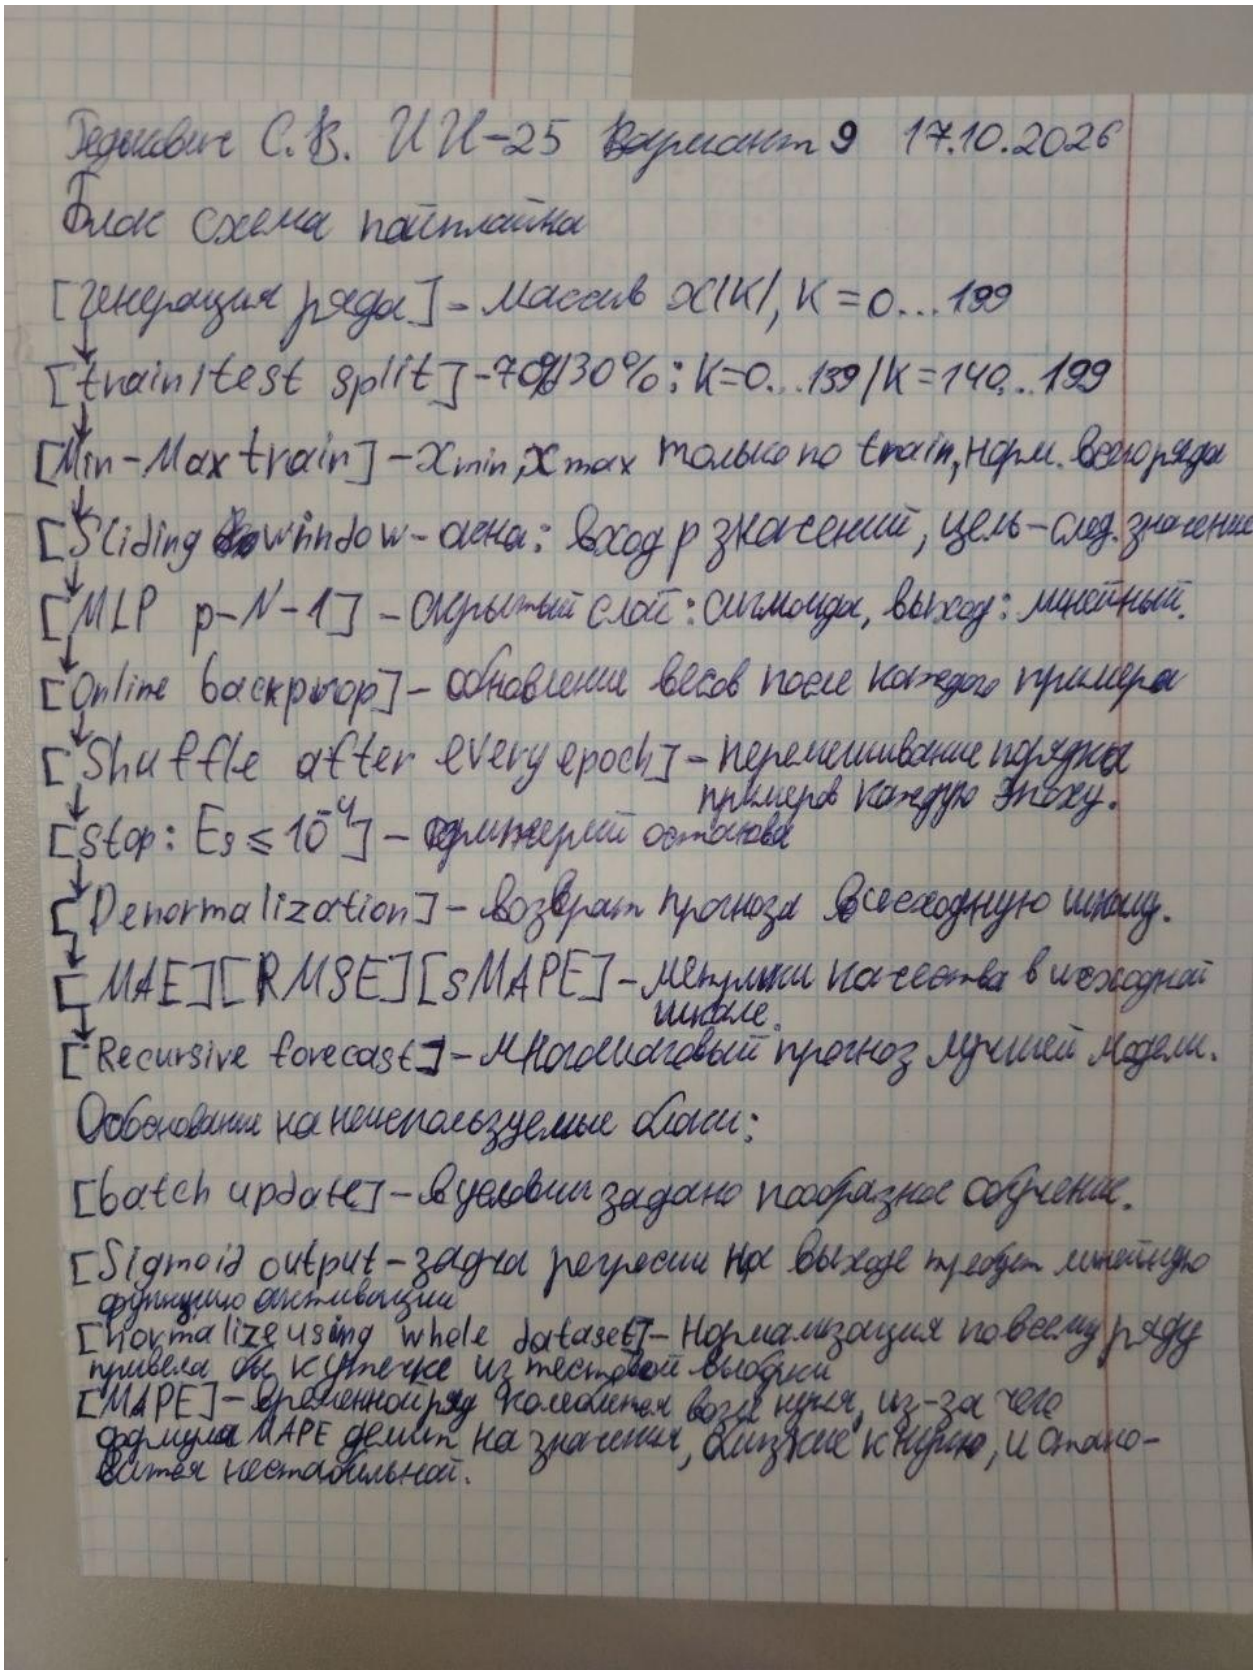
5. Устойчивость к инициализации. Обучение очень устойчиво. При $p \geq 4$ и любом N сошлись все пять запусков, разброс небольшой: у базовой конфигурации 142 ± 15 эпохи и тестовый MAE 0,0392 ± 0,0020. Единственные провалы — при p=2: там не сошлись все пять запусков за 20 000 эпох. Причина в размере окна, то есть в нехватке информации, а не в случайной инициализации. При η от 0,01 до 0,3 и p=7 сошлись все запуски, а η влияет только на скорость: около 1400 эпох при 0,01 и около 45 при 0,3. От N сходимость тоже не зависит.

6. Рекурсивный прогноз. Каждое предсказание содержит небольшую ошибку, а затем подставляется в окно, и следующий прогноз строится уже на неточных данных, поэтому ошибки накапливаются. В нашем запуске (p=7, N=4) средняя ошибка на 30 шагах около 0,078 против 0,039 у одношагового прогноза, то есть примерно вдвое выше. Растёт она не

монотонно, а волнами, сильней всего на крутых участках ряда. В первые 16 шагов она не превышает 0,11, затем порог 5% размаха (0,135) впервые превышается на шаге 17 (0,141), после чего ошибка колеблется около этого уровня. По критерию 5% прогноз можно считать пригодным примерно на 16 шагов, это около одного периода быстрой гармоники.

7. Эксперимент не проводился

Рукопись:


Федяевич С.В. ИИ-25 Вариант 9 17.10.2026
Блок схема пайплайна
[Генерация ряда] - Массив x[k], k = 0...199
[train/test split] - 70%/30%: k=0...139 / k=140...199
[Min-Max train] - x_min, x_max только по train, норм. всего ряда
[Sliding window - окна: вход p значений, цель - след. значение
[MLP p-N-1] - скрытый слой: сигмоида, выход: линейный.
[Online backprop] - обновление весов после каждого примера
[Shuffle after every epoch] - перемешивание порядка примеров каждую эпоху.
[stop: Es ≤ 10^-4] - критерий остановки
[Denormalization] - возврат прогноза в исходную шкалу.
[MAE][RMSE][sMAPE] - метрики качества в исходной шкале.
[Recursive forecast] - многошаговый прогноз лучшей модели.
Обоснования на неиспользуемые блоки:
[batch update] - в условии задано пообразное обучение.
[Sigmoid output - задача регрессии на выходе требует линейную функцию активации
[Normalize using whole dataset] - Нормализация по всему ряду привела бы к утечке из тестовой выборки
[MAPE] - временной ряд колеблется вокруг нуля, из-за чего формула MAPE делит на значения, близкие к нулю, и ошибка становится нестабильной.

2) Ручной расчёт одного шага обучения [Сеть 3-2-1, Вариант 9]

$x_1 = 0,2$; $x_2 = 0,5$; $x_3 = 0,8$; $d = 0,8$; $\eta = 0,1$.

$w_{11} = 0,85$; $w_{12} = -0,2$; $w_{21} = 0,3$; $w_{22} = 0,45$; $w_{31} = -0,1$; $w_{32} = 0,4$.

$b_1 = 0,1$; $b_2 = -0,11$ ~~$w_{out1} = 0,8$~~; $w_{out1} = 0,5$; $w_{out2} = -1,8$; $b_{out} = 0,2$

Прямой проход

Скрытый слой:

$S_1 = x_1 w_{11} + x_2 w_{21} + x_3 w_{31} + b_1 = 0,26$

$S_2 = x_1 w_{12} + x_2 w_{22} + x_3 w_{32} + b_2 = 0,405$

$y_1 = F(S_1) = \frac{1}{1+e^{-0,26}} = 0,564642$

$y_2 = F(S_2) = 0,599871$

Выходной слой:

$S = y_1 w_{out1} + y_2 w_{out2} + b_{out} = -0,597447$

$y = F(S) = S = -0,597447$

Ошибка:

$E = \frac{1}{2}(d - y)^2 = 0,716939$

Обратный проход:

$\delta = (d - y) \cdot F'(S) = (d - y) \cdot 1 = 1,197447$

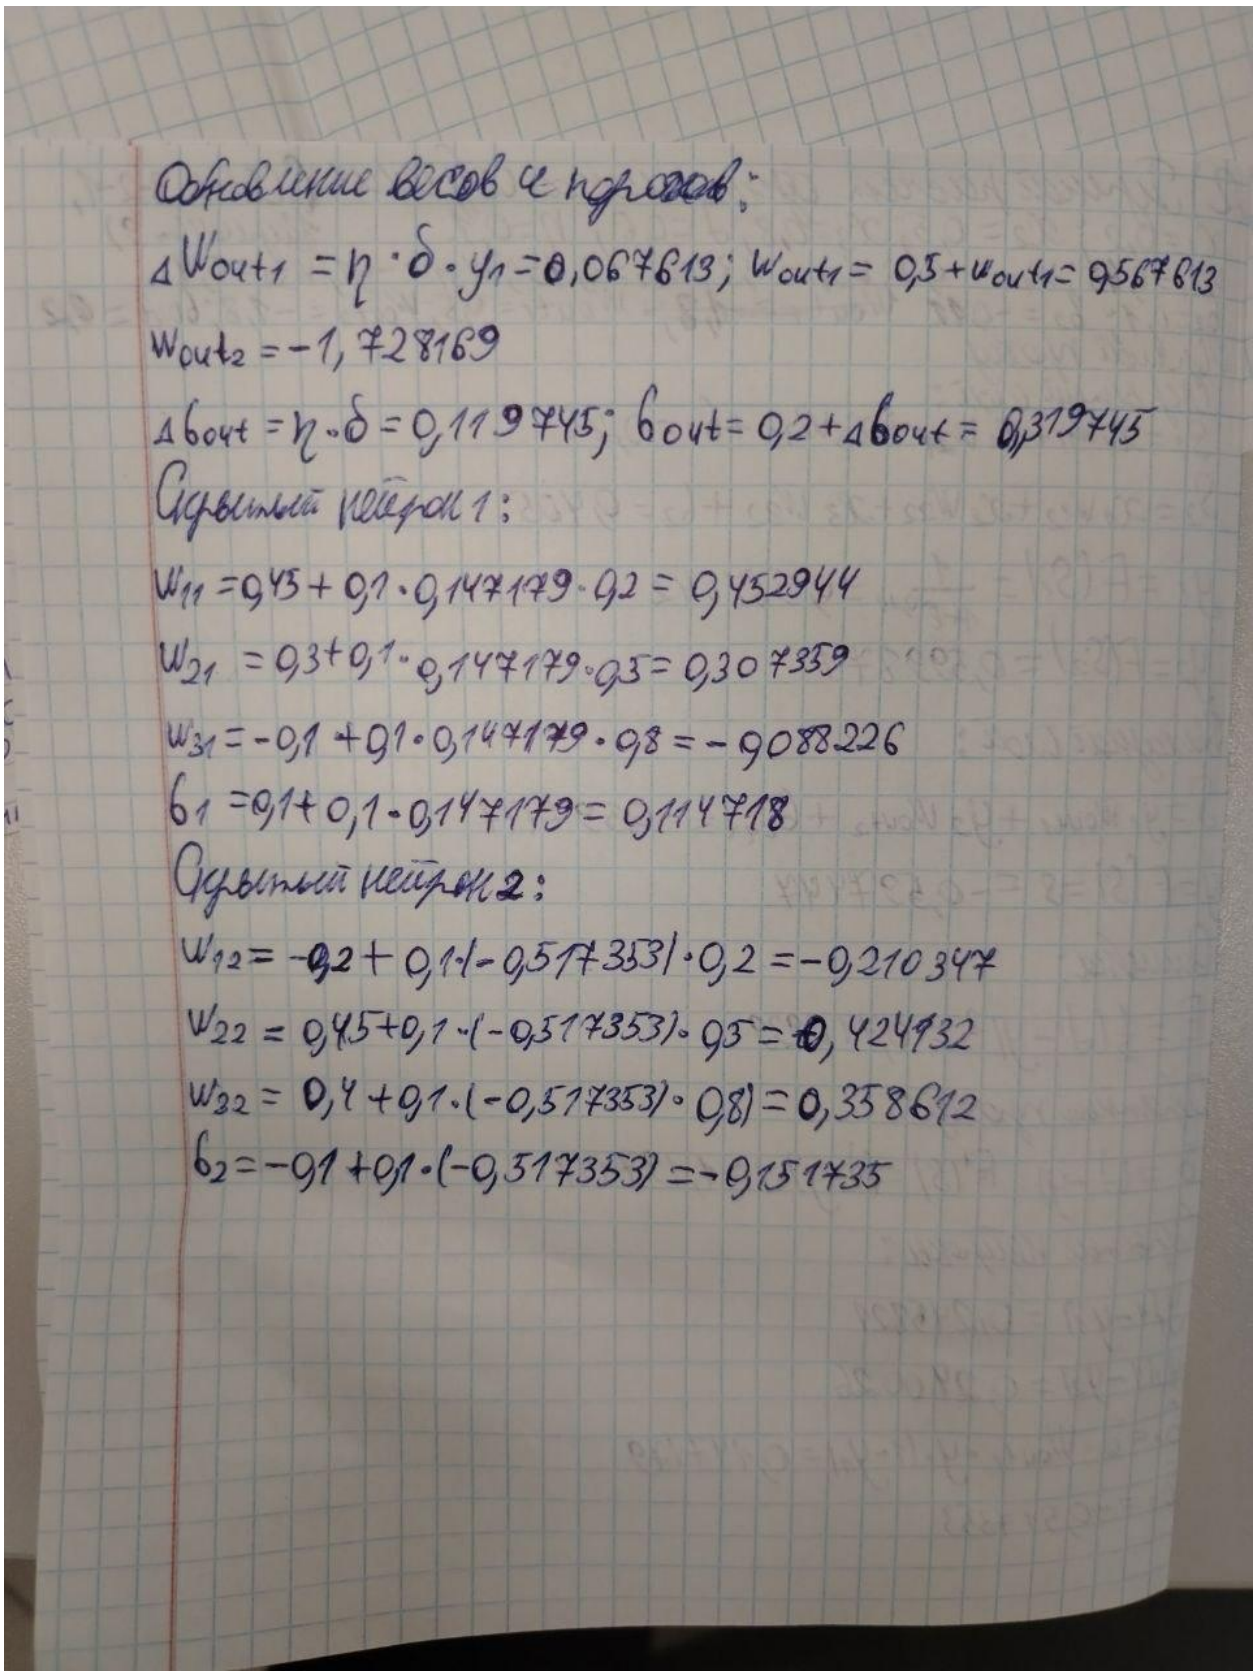
Скрытые нейроны:

$y_1(1 - y_1) = 0,245821$

$y_2(1 - y_2) = 0,240026$

$\delta_1 = \delta \cdot w_{out1} \cdot y_1(1 - y_1) = 0,147179$

$\delta_2 = -0,517353$



Вывод: на основе многослойного персептрона p–N–1 решил задачу прогнозирования временного ряда. Научился формировать обучающую выборку методом скользящего окна, нормализовать данные, оценивать качество одношагового и многошагового прогноза и исследовал влияние

размера окна p и числа нейронов скрытого слоя N на точность прогноза и скорость обучения.