

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №2

По дисциплине: «Модели решения задач в интеллектуальных системах»
Тема: «Многослойный персептрон для задачи «исключающее ИЛИ» с числовыми классами: сравнение функций потерь MSE и Binary Cross-Entropy»

Выполнил:
Студент 4 курса
Группы ИИ-25
Скачков Е.В.
Проверила:
Андренко К.В.

Цель работы: на основе многослойного персептрона архитектуры 2-2-1, реализованного в Лабораторной работе №1 для задачи XOR с числовыми классами c_0 и c_1 из диапазона $[-10; 10]$, реализовать альтернативную функцию потерь – бинарную кросс-энтропию (Binary Cross-Entropy, BCE) – и провести сравнительный анализ обучения сети с MSE (Лабораторная работа №1) и с BCE по скорости сходимости, качеству обучения и устойчивости к выбору начальных весов.

Задание:

- взять за основу код многослойного персептрона 2-2-1 из Лабораторной работы №1;
 - поскольку BCE определена для выходов в диапазоне $(0; 1)$, а целевые значения в вашем варианте – произвольные числа c_0 и c_1 из диапазона $[-10; 10]$, реализовать нормализацию (масштабирование) целевых значений перед обучением и обратное преобразование выхода сети после обучения:
 - привести c_0 и c_1 к бинарным меткам 0 и 1;
 - обучать сеть на нормализованных целевых значениях с функцией потерь BCE;
 - при выводе результата преобразовывать выход сети $\hat{y} \in (0; 1)$ обратно в шкалу $[c_0; c_1]$.
 - реализовать корректный градиент для связки BCE + сигмоида на выходном слое; для скрытого слоя градиент передаётся по стандартному правилу цепочки.
 - обучить сеть на полной таблице истинности своего варианта (4 примера) в двух конфигурациях:
 - **конфигурация А (базовая, из ЛР №1):** MLP 2-2-1, функция потерь MSE, целевые значения – исходные c_0/c_1 , выходной слой – сигмоида. Результаты можно взять из отчёта по ЛР №1 или, при необходимости, повторить обучение с фиксацией всех метрик.
 - **конфигурация Б (новая):** MLP 2-2-1, функция потерь BCE, целевые значения – нормализованные $(0/1)$, с последующим пересчётом выхода в шкалу $[c_0; c_1]$.
- Критерий остановки для обеих конфигураций одинаков – суммарная ошибка $E_s \leq E_e$ (используйте то же значение E_e , что и в ЛР №1, либо согласуйте новое значение отдельно для MSE и для BCE, поскольку это разные по своей природе величины – обоснуйте выбор в отчёте);
- для каждой конфигурации зафиксировать:
 - количество эпох до достижения критерия остановки (либо факт недостижения за максимально допустимое число эпох);
 - итоговую суммарную ошибку;
 - ассигасу на всех 4 примерах таблицы истинности;
 - среднюю абсолютную ошибку в исходной шкале $[c_0; c_1]$.
 - провести не менее 5 запусков обучения для каждой конфигурации с разной случайной инициализацией весов (менять seed) и сравнить устойчивость сходимости: в скольких из 5 запусков сеть достигла критерия остановки, и какой разброс по числу эпох наблюдается;

- построить общий график зависимости суммарной ошибки от номера эпохи для конфигурации А (MSE) и конфигурации Б (BCE) на одних осях (для представительного запуска каждой конфигурации);
- реализовать блок визуализации результатов, включающий:
 - **график сходимости**– суммарная ошибка E_s от номера эпохи, конфигурации А и Б на одних осях, разными цветами/стилями линий, с обозначением порога E_e ;
 - **диаграмму разброса числа эпох по 5 запускам**(bar chart или scatter) для конфигурации А и конфигурации Б – наглядно показывающую устойчивость сходимости из п. 6 (например, столбики числа эпох для каждого из 5 seed, сгруппированные по конфигурации; запуски, не достигшие критерия остановки, отметить отдельно, например штриховкой или отдельным цветом);
 - **визуализацию разделяющей поверхности скрытого слоя** – для представительного обученного экземпляра каждой конфигурации построить на плоскости (А, В) карту выходного значения сети (heatmap или contour plot) с наложенными точками обучающей выборки (4 примера таблицы истинности), закрашенными по истинному классу. Диапазон осей А и В – $[-10; 10]$ (весь допустимый диапазон входных значений). Для конфигурации Б цветовую шкалу можно строить как по нормализованному $\hat{y} \in (0; 1)$, так и по пересчитанному значению в шкале $[c0; c1]$ – выбрать более наглядный вариант и обосновать выбор;
 - **диаграмму сравнения точности восстановления шкалы**– столбчатую диаграмму средней абсолютной ошибки для конфигурации А и конфигурации Б, чтобы наглядно сопоставить точность регрессии к исходной шкале $[c0; c1]$.

Каждый график должен иметь подписанные оси, заголовок и легенду (где применимо). Разделяющую поверхность и графики точности рекомендуется разместить рядом (например, subplot 2×2 или отдельными рисунками) для удобства сравнения в отчёте;

- реализовать режим функционирования сети: пользователь вводит пару чисел (А, В) из диапазона $[-10; 10]$ (не обязательно совпадающих с $c0$ и $c1$). Сеть должна выводить:
 - выход в нормализованной шкале $\hat{y} \in (0; 1)$ (с точностью до 4 знаков);
 - выход, пересчитанный в исходную шкалу $[c0; c1]$ по формуле из п. 2;
 - к какому классу ($c0$ или $c1$) ближе полученное значение.

Продемонстрировать работу режима функционирования на всех 4 примерах исходной таблицы истинности и не менее чем на 2–3 дополнительных парах (А, В), не входящих в обучающую выборку.

Изменения в архитектуре и алгоритме относительно ЛР1:

Архитектура сети (2-2-1, сигмоида на всех слоях) не менялась. Изменения – только в целевой функции и, дополнительно, во входной нормализации:

Нормализация целей (как и в ЛР1, поскольку сигмоида на выходе ограничена (0;1) и не может выдать –9 или 6):

$$y_{norm} = \frac{y - c_0}{c_1 - c_0}$$

Обратный пересчёт после обучения:

$$y = y_{norm} \cdot (c_1 - c_0) + c_0$$

Вывод градиента для связки ВСЕ + сигмоида (выходной слой):

Потери для одного примера:

$$L = -y \ln p - (1 - y) \ln(1 - p), \quad p = \sigma(z) = out$$

Цепное правило:

$$\frac{\partial L}{\partial z} = \frac{\partial L}{\partial p} \cdot \frac{\partial p}{\partial z}$$

где

$$\frac{\partial L}{\partial p} = -\frac{y}{p} + \frac{1 - y}{1 - p}, \quad \frac{\partial p}{\partial z} = p(1 - p)$$

Подставляем и сокращаем:

$$\frac{\partial L}{\partial z} = \left(-\frac{y}{p} + \frac{1 - y}{1 - p} \right) p(1 - p) = -y(1 - p) + (1 - y)p = p - y$$

Итог:

$$\delta_{out} = out - y$$


Градиент для скрытого слоя:

$$\delta_h = (\delta_{out} W_2^T) \odot h(1 - h)$$


Блок визуализации:


График сходимости:

График сходимости: MSE vs BCE



Разделяющая поверхность:





Вывод :

1. Какая функция потерь сходилась быстрее и устойчивее? Согласуется ли с теорией?

Быстрее сходится BCE: в среднем 638 эпох (448–934) против 2994 эпох (2027–4361) у MSE, то есть примерно в 4–5 раз. Это согласуется с теорией: у MSE + сигмоиды дельта выхода равна $(y - t) \cdot y(1 - y)$. Множитель $y(1 - y)$ почти обнуляется, когда сигмоида насыщена, и градиент затухает даже при большой ошибке. У BCE этот множитель сокращается, дельта равна просто $y - t$, и градиент остаётся значимым, пока ошибка велика.

Устойчивее оказался MSE: он сошёлся в 5 из 5 запусков, BCE в 4 из 5. Это не противоречит теории, но и не подтверждает её. Преимущество BCE в скорости и в отсутствии затухания градиента, а не в гарантии выхода из любого локального минимума. При выборке из 5 запусков делать общий вывод об устойчивости нельзя, нужно больше seed.

2. Как повлияла нормализация целей по сравнению с обучением на числах из $[-10; 10]$?

Здесь нужна оговорка. Обучать сеть с сигмной на выходе «напрямую» на числах 3 и -8 невозможно: сигмоида выдаёт только значения в (0; 1), поэтому Es не может достичь порога. В ЛР

№1 мы тоже нормализовали цели (в $[0.1; 0.9]$), так что сравнение идёт не между «с нормализацией» и «без», а между двумя вариантами нормализации:

- MSE с целями 0.1/0.9 (конфигурация А);
- BCE с целями 0/1 (конфигурация Б).

Нормализация сама по себе обязательна и не ускоряет и не замедляет обучение. Влияет скорее сочетание «цели + функция потерь»: цели 0.1/0.9 нужны MSE, чтобы сеть не требовала бесконечных весов; у BCE цели 0/1 допустимы, так как логарифмическая потеря сама подталкивает выход к границам без затухания градиента. Различие в скорости из п. 1 связано с функцией потерь, а не с самим фактом нормализации.

3. Точность восстановления шкалы $[c_0; c_1]$ и компромисс

MAE в исходной шкале (среднее по сошедшимся запускам):

MAE

А (MSE) 0.295

Б (BCE) 0.270

Значения почти одинаковые. Но к этому сравнению тоже есть оговорка: в А сеть тоже выдаёт значение в $(0.1; 0.9)$, которое пересчитывается в шкалу $[c_0; c_1]$, то есть «сразу в нужной шкале» она не выдаёт ни в одной конфигурации. Кроме того, близость MAE объясняется тем, что я подобрал пороги так, чтобы точность была сопоставимой ($E_{\text{BCE}} = 0.1$ примерно соответствует $E_{\text{MSE}} = 0.001$ по ошибке на выходе). Поэтому правильный вывод такой: при согласованных порогах точность одинакова, а различается только скорость. Реального компромисса между «удобством классификации» и «точностью регрессии» в этом эксперименте не наблюдается. Теоретически он существует: BCE оптимизирует вероятность класса, а не расстояние в исходной шкале, и если бы требовалась именно точность регрессии для промежуточных значений, MSE подходил бы лучше.

4. Устойчивость к инициализации

- А (MSE): 5 из 5 сошлись, разброс по эпохам 2027–4361 ($\text{std} \approx 933$).
- Б (BCE): 4 из 5 сошлись, разброс 448–934 ($\text{std} \approx 190$). Seed 3 не достиг критерия за 100 000 эпох: $E_s \approx 1.387$, accuracy 75%, MAE 2.75.

Случай seed 3 это застревание в неудачном стационарном состоянии (локальный минимум или плато). Значение $E_s = 1.387$ равно $2 \cdot \ln 2$, а $\text{MAE} = 2.75 = (5.5 + 5.5 + 0 + 0)/4$. Значит, два примера сеть классифицировала правильно, а на двух других выход остался около 0.5. (Ранее я написал, что на всех примерах выход около 0.5, это было неточно.) Для MSE таких случаев в серии не было, но это не доказывает отсутствие проблемы: у MSE выборка из пяти запусков тоже мала.

5. Подтвердилась ли линейная неразделимость независимо от числовых значений?

Да. Числовые классы получены из 0/1 линейным преобразованием (сдвиг и масштаб), которое не меняет взаимное расположение точек: те же четыре точки в вершинах прямоугольника, c_0 на одной диагонали, c_1 на другой. Любую прямую, отделяющую один угол, это расположение делает неподходящей. Вывод не зависит от конкретных значений 3 и -8 , лишь бы $c_0 \neq c_1$.

Экспериментально это показано в ЛР №1 (однослойный не сошёлся, $E_s \approx 0.32$); в ЛР №2 однослойный персептрон не обучался, а на данном варианте тот же факт виден на heatmap: границы нужны две, одной прямой не обойтись.

6. Влияет ли функция потерь на вывод о необходимости многослойной архитектуры?

Нет. Возможность решить XOR определяется архитектурой: способностью модели задать нужную разделяющую поверхность. Функция потерь определяет только то, как к этой поверхности идёт оптимизация (скорость, затухание градиента, плато). Однослойный нейрон с BCE по-прежнему даёт одну прямую, а значит XOR не решит; сеть 2-2-1 с любой из двух функций потерь его решает. Наш эксперимент это подтверждает: обе конфигурации с одним скрытым слоем обучились (А в 5 из 5, Б в 4 из 5), то есть вывод ЛР №1 не изменился.

7. Что показывает визуализация разделяющей поверхности?

На обеих картах граница классов состоит из **двух линий** (пунктир на уровне -2.5), которые образуют **полосу**. Это ровно то, что ожидается для XOR: каждый нейрон скрытого слоя задаёт одну прямую, а выходной нейрон выделяет пространство между ними.

- **А (MSE, seed 3):** полоса идёт вдоль диагонали $A = B$. В ней лежат точки $s0$ ((3;3) и (-8;-8)), вне полосы две точки $s1$.
- **Б (BCE, seed 2):** полоса идёт вдоль другой диагонали. В ней лежат точки $s1$ ((3;-8) и (-8;3)), вне неё точки $s0$.

Отличие визуально есть, но оно в ориентации и в том, какой класс оказался «внутри» полосы. Это зависит от случайного начального состояния (seed), а не от функции потерь: при другом seed у MSE может получиться такая же картина, как у BCE, и наоборот. Поэтому по одной паре представительных запусков нельзя утверждать, что тип потерь определяет форму границы. Принципиально же обе поверхности устроены одинаково: пересечение двух полуплоскостей, как и положено для решения XOR на двух скрытых нейронах. Для точек вне обучающих углов (например, (0;0) или (5;-2)) ответ определяется положением полос и может отличаться между запусками, что в отчёте стоит прямо отметить.

