Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №4

По дисциплине: «Модели решения задач в интеллектуальных системах»

Тема: «Многослойный персептрон для прогнозирования временного ряда: влияние размера окна и числа скрытых нейронов»

Выполнил:
Студент 4 курса
Группы ИИ-25
Трошин И.Д.
Проверила:
Андренко К.В.

Брест 2026

Цель работы: на основе многослойного персептрона p–N–1 решить задачу прогнозирования временного ряда. Научиться формировать обучающую выборку методом скользящего окна, нормализовать данные, оценивать качество одношагового и многошагового прогноза и исследовать влияние размера окна p и числа нейронов скрытого слоя N на точность прогноза и скорость обучения.

Вариант: как в прошлых ЛР
Вопросы к лабораторной: Вопросы всех 3 ЛР + вопросы для вывода из ЛР 4

Постановка задачи

Прогнозируемый ряд задаётся формулой:

$$x(k) = a \cdot cos(b \cdot k) + c \cdot sin(d \cdot k), k = 0,1,2,\ldots,199$$

Параметры a, b, c, d, размер окна p и число скрытых нейронов N берутся из таблицы варианта.

Первые 70 % точек (k = 0…139) образуют обучающий участок, остальные 30 % (k = 140…199) – тестовый участок. Сеть по p предыдущим значениям ряда предсказывает следующее:

$$\widehat{x(k)} = F(x(k-1), x(k-2), \ldots, x(k-p))$$

Задачи лабораторной работы

1. Сгенерировать ряд по формуле варианта и построить его график с отметкой границы между обучающим и тестовым участками.
2. Нормализовать ряд по минимуму и максимуму **обучающего участка**: $x_norm = (x - x_min) / (x_max - x_min)$. Записать формулу обратного пересчёта и использовать её при вычислении всех метрик в исходной шкале. **Объяснить**, почему min/max нельзя брать по всему ряду.
3. Сформировать обучающую и тестовую выборки методом скользящего окна размера p (вход – p значений, цель – следующее значение). Указать количество получившихся примеров в каждой выборке.
4. Реализовать многослойный персептрон p–N–1:
   - скрытый слой – сигмоида;
   - выходной слой – линейный (задача регрессии), f(s) = s;
   - функция потерь – MSE;
   - обучение – онлайн-режим, перемешивание порядка примеров в каждой эпохе;
   - вывести формулы градиентов для линейного выходного слоя и сигмоидного скрытого слоя и привести их в отчёте.
5. Критерий остановки: средняя по обучающей выборке ошибка Es ≤ Ee, где Ee = 10^{-4} (нормализованная шкала), либо достижение 20 000 эпох. Скорость обучения подобрать самостоятельно из диапазона 0.01–0.3 и обосновать выбор.
6. **Базовый эксперимент.** Обучить сеть с параметрами p и N из своего варианта. Зафиксировать число эпох, итоговую Es, а также метрики на обучающем и тестовом участках **в исходной шкале**: MAE, RMSE и MAPE (если ряд проходит через ноль – вместо MAPE использовать sMAPE, и пояснить почему).
7. **Исследование окна.** При фиксированном N из варианта обучить сеть для p ∈ {2, 4, p_вар, 2·p_вар}. Для каждого p выполнить по 5 запусков с разными seed и свести в таблицу: среднее и разброс числа эпох, среднее и разброс тестового MAE, число запусков, не достигших критерия остановки.
8. **Исследование скрытого слоя.** При фиксированном p из варианта обучить сеть для N ∈ {1, 2, N_вар, 2·N_вар}. Выполнить ту же серию из 5 запусков и заполнить аналогичную таблицу.
9. **Многошаговый прогноз.** Для лучшей по тестовому MAE конфигурации выполнить рекурсивный прогноз на 30 шагов вперёд, начиная с k = 140: каждое предсказание подставляется в окно как входное значение для следующего шага. Построить график «эталон – рекурсивный прогноз» и график абсолютной ошибки в зависимости от номера шага. Определить, на каком шаге ошибка превышает 5 % от размаха ряда.
10. Построить графики:
    - ряд с границей train/test и одношаговым прогнозом сети на обоих участках на одних осях;

- сходимость (Es от эпохи) для базовой конфигурации и для двух конфигураций из исследования окна на одних осях (логарифмическая шкала по Y);
- диаграмма рассеяния «эталон – прогноз» на тестовом участке с диагональю y = x;
- рекурсивный прогноз и рост ошибки по шагам (п. 9).

11. Реализовать режим функционирования: пользователь вводит p последовательных значений ряда в исходной шкале (либо номер k, с которого брать окно из ряда). Программа выводит:
- нормализованные входы;
- прогноз в нормализованной шкале (4 знака после запятой);
- прогноз в исходной шкале;
- истинное значение x(k) и абсолютную ошибку (если окно взято из ряда).

Продемонстрировать работу не менее чем на 3 окнах из обучающего участка, 3 окнах из тестового участка и 1–2 пользовательских окнах (в том числе с «выбросом»).

12. Вставить в отчет фото/скан рукописных расчётов. Вверху листа от руки должны быть написаны Ваша Фамилия, Инициалы, номер группы, вариант и дата выполнения:
- Графическая схема пайплайна (Блок-схема). Составьте корректную цепочку обработки данных, используя предложенный набор блоков (приложение 1). Объясните свой выбор.
- Ручной расчёт 1 шага обучения. На отдельном листе бумаги от руки распишите один полный шаг (Forward + Backward pass) для сети 3–2–1 со следующими параметрами, привязанными к вашему варианту V:
  - Входы: X = [0.2, 0.5, 0.8], Цель: d = 0.6
  - Веса скрытого слоя: W11 = 0.05*V, W12 = -0.2, W21 = 0.3, W22 = 0.05*V, W31 = -0.1, W32 = 0.4 (b1=0.1, b2=-0.1)
  - Веса выходного слоя: W_out1 = 0.5, W_out2 = -0.2*V (b_out = 0.2)

13. Сделать вывод: ответить на все вопросы ниже и проанализировать результаты.

Требования к реализации

- Скрытый слой – сигмоида, выходной слой – линейный. Веса инициализируются малыми случайными значениями, для воспроизводимости использовать фиксированный seed.
- Обучение – алгоритм обратного распространения в онлайн-режиме.
- Допускается использование NumPy и Matplotlib.
- Запрещено использование scikit-learn, PyTorch, TensorFlow и других ML-фреймворков, а также готовых функций для скользящего окна и расчёта метрик из внешних библиотек (кроме NumPy).
- Код должен быть структурирован: отдельные функции для генерации ряда, нормализации, построения окон, прямого и обратного проходов, обучения, метрик, рекурсивного прогноза и режима функционирования.

Вариант 13

Ряд: $x(k) = a \cdot cos(b \cdot k) + c \cdot sin(d \cdot k)$,
k = 0…199, p – размер окна, N – число скрытых нейронов.

Вариант	a	b	c	d	p	N
13	1.1	0.42	0.55	0.95	6	4

Ход работы

2 Описание метода

2.1 Нормализация данных

Ряд нормализуется по минимуму и максимуму обучающего участка (k = 0…139):

$$x_{norm} = (x - x_{min}) / (x_{max} - x_{min})$$

Обратный пересчёт, который используется при вычислении всех метрик в исходной шкале:

$$x = x_{norm} \cdot (x_{max} - x_{min}) + x_{min}$$

Для обучающего участка $x_{min} = -1.6150$, $x_{max} = 1.6463$.

Min/max нельзя брать по всему ряду: тогда параметры масштабирования зависели бы от тестовых значений, то есть информация о «будущем» попадала бы в процесс подготовки данных (утечка). В реальной задаче прогнозирования будущие значения неизвестны, поэтому оценка качества на тесте перестала бы быть честной.

2.2 Формирование выборок скользящим окном

Для каждого k вход образуют p предыдущих значений (x_{k-p}, …, x_{k-1}), целью является x_k. При p = 6 обучающая выборка содержит цели k = 6…139, то есть 134 примера, тестовая – цели k = 140…199, то есть 60 примеров. Окна первых тестовых примеров частично состоят из значений обучающего участка: это допустимо, так как входные значения известны на момент прогноза.

2.3 Архитектура сети и прямой проход

Сеть p–N–1: p входов, скрытый слой из N нейронов с сигмоидной функцией активации, один выходной нейрон с линейной функцией f(s) = s (задача регрессии). Вместо смещений используются пороги T:

$$s_j = \Sigma\, w_{ij} \cdot x_i - T_j, \;\; i = 1 \ldots p$$

$$h_j = 1 / (1 + e^{-s_\{j\}}), \;\; j = 1 \ldots N$$

$$y = \Sigma\, v_j \cdot h_j - T_{out}, \;\; j = 1 \ldots N$$

где w_{ij} – веса скрытого слоя, v_j – веса выходного слоя. Функция потерь – MSE; для одного примера и для всей выборки:

$$E = \tfrac{1}{2} \cdot (y - d)^2, \quad E_s = (1/M) \cdot \Sigma\, E_m$$

где d – целевое значение, M – число примеров обучающей выборки.

2.4 Вывод градиентов

Для линейного выходного слоя f(s) = s, f′(s) = 1, поэтому локальный градиент выходного нейрона совпадает с ошибкой:

$$\delta_{out} = (y - d) \cdot f'(s_{out}) = y - d$$

Градиенты по параметрам выходного слоя ($\partial s_{out}/\partial v_j = h_j$, $\partial s_{out}/\partial T_{out} = -1$):

$$\partial E/\partial v_j = \delta_{out} \cdot h_j$$

$$\partial E/\partial T_{out} = -\delta_{out}$$

Для сигмоидного скрытого слоя производная активации h′ = h·(1 − h), ошибка передаётся назад через вес v_j:

$$\delta_j = \delta_{out} \cdot v_j \cdot h_j \cdot (1 - h_j)$$

$$\partial E/\partial w_{ij} = \delta_j \cdot x_i$$

$$\partial E/\partial T_j = -\delta_j$$

Правила обновления параметров (α – скорость обучения):

$$v_j \leftarrow v_j - \alpha \cdot \delta_{out} \cdot h_j, \quad T_{out} \leftarrow T_{out} + \alpha \cdot \delta_{out}$$

$$w_{ij} \leftarrow w_{ij} - \alpha \cdot \delta_j \cdot x_i, \quad T_j \leftarrow T_j + \alpha \cdot \delta_j$$

2.5 Обучение и критерий остановки

Обучение выполняется в онлайн-режиме: веса обновляются после каждого примера, порядок примеров перемешивается в каждой эпохе. Начальные веса и пороги – малые случайные числа из диапазона [−0.5; 0.5], для воспроизводимости используется фиксированный seed (для серий запусков seed = 0…4).

Критерий остановки: средняя по обучающей выборке ошибка $E_s \le E_e = 10^{-4}$ (нормализованная шкала) либо достижение 20 000 эпох.

Скорость обучения $\alpha = 0.1$ выбрана из допустимого диапазона 0.01–0.3 как средняя: при малых значениях сходимость слишком медленная, при значениях у верхней границы диапазона в онлайн-режиме шаги по отдельным примерам сильнее раскачивают веса. Значение 0.1 даёт быструю сходимость с запасом по устойчивости.

2.6 Метрики качества

Метрики вычисляются в исходной шкале (после обратного пересчёта):

$$MAE = (1/M)\cdot\Sigma\ |x_m - \hat{x}_m|$$

$$RMSE = \sqrt{(\ (1/M)\cdot\Sigma\ (x_m - \hat{x}_m)^2\ )}$$

$$sMAPE = (100\ \%/M)\cdot\Sigma\ 2\cdot|x_m - \hat{x}_m| / (|x_m| + |\hat{x}_m|)$$

Ряд проходит через ноль, поэтому вместо MAPE используется sMAPE: в MAPE на каждое слагаемое делится на x_m, и вблизи нулевых значений ряда относительная ошибка становится неограниченно большой и не отражает реального качества прогноза.

2.7 Рекурсивный прогноз

Рекурсивный прогноз на 30 шагов вперёд начинается с k = 140: начальное окно состоит из истинных значений ряда до k = 139, далее каждое предсказание подставляется в окно как входное значение для следующего шага. Прогноз считается пригодным, пока абсолютная ошибка не превышает 5 % от размаха ряда. Размах всего ряда равен 3.2941, порог составляет 0.1647.

4 Результаты базового эксперимента

Базовый эксперимент выполнен для параметров варианта: p = 6, N = 4, α = 0.1, seed = 0. Критерий остановки $E_s \le 10^{-4}$ достигнут за 78 эпох.

Участок	Число эпох	E_s	MAE	RMSE	sMAPE, %
Обучающий	78	$9.736\cdot10^{-5}$	0.03922	0.04551	13.855
Тестовый	78	–	0.04008	0.04612	12.948

5 Исследование влияния размера окна и числа скрытых нейронов

Для каждой конфигурации выполнено по 5 запусков с разными seed (0…4). В таблицах указаны среднее и разброс (стандартное отклонение) числа эпох и тестового MAE, а также число запусков, не достигших критерия остановки за 20 000 эпох.

5.1 Исследование окна

При фиксированном N = 4 исследованы $p \in \{2, 4, 6, 12\}$.

p	N	Эпохи, среднее	Эпохи, разброс	Test MAE, среднее ± разброс	Не достигли E_e
2	4	20000	0	0.17267 ± 0.00434	5/5
4	4	756	32	0.03796 ± 0.00092	0/5

p	N	Эпохи, среднее	Эпохи, разброс	Test MAE, среднее ± разброс	Не достигли E_e
6	4	86	7	0.03844 ± 0.00115	0/5
12	4	27	12	0.03377 ± 0.00149	0/5

5.2 Исследование скрытого слоя

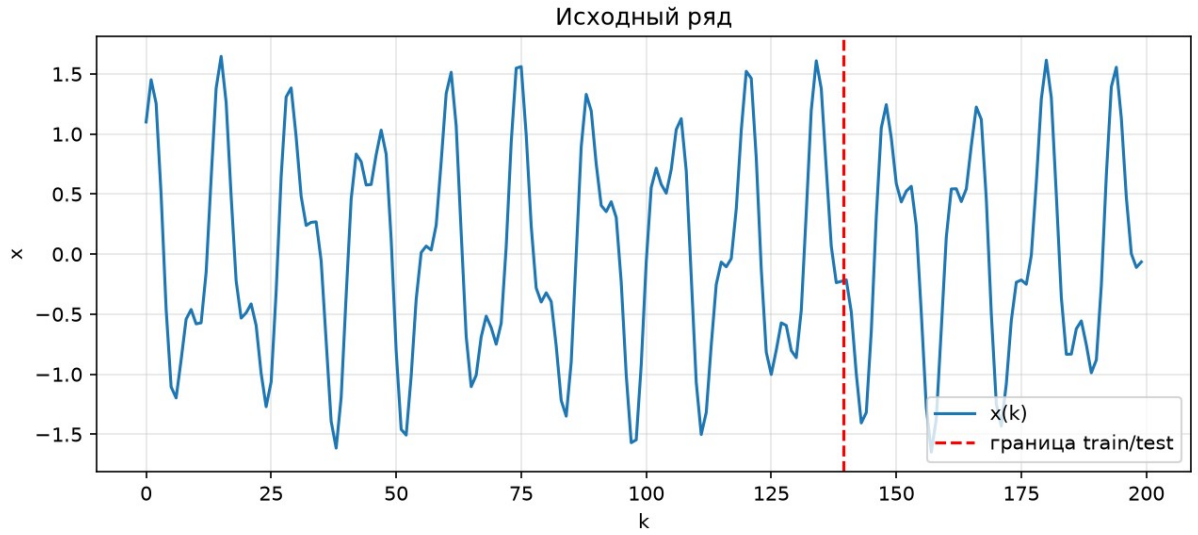
При фиксированном p = 6 исследованы $N \in \{1, 2, 4, 8\}$.

p	N	Эпохи, среднее	Эпохи, разброс	Test MAE, среднее ± разброс	Не достигли E_e
6	1	92	7	0.03802 ± 0.00187	0/5
6	2	89	6	0.03792 ± 0.00065	0/5
6	4	86	7	0.03844 ± 0.00115	0/5
6	8	81	6	0.03541 ± 0.00283	0/5

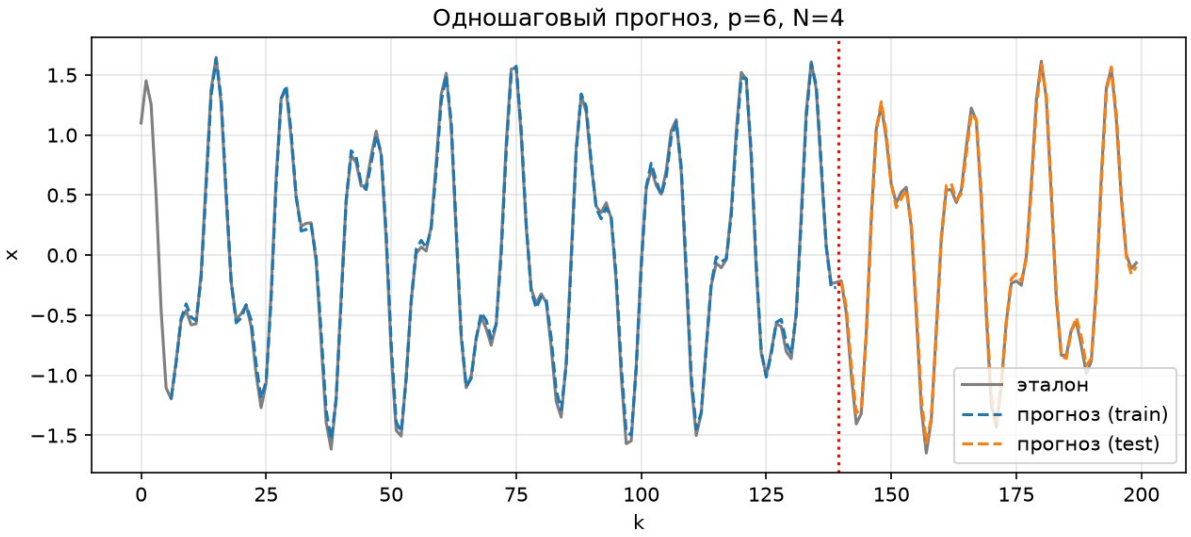
Лучшей по тестовому MAE оказалась конфигурация p = 12, N = 4; для неё построен рекурсивный прогноз.

6 Визуализация результатов

На рисунке 1 показан исходный ряд с границей между обучающим и тестовым участками (k = 140).



Одношаговый прогноз сети p = 6, N = 4 на обучающем и тестовом участках: прогноз практически совпадает с эталоном на обоих участках.



Сходимость базовой конфигурации и двух конфигураций из исследования окна. При p = 6 критерий достигнут за 78 эпох, при p = 12 – за 19 эпох; при p = 2 ошибка выходит на плато порядка $2 \cdot 10^{-3}$ и за 20 000 эпох критерий остановки не достигается.

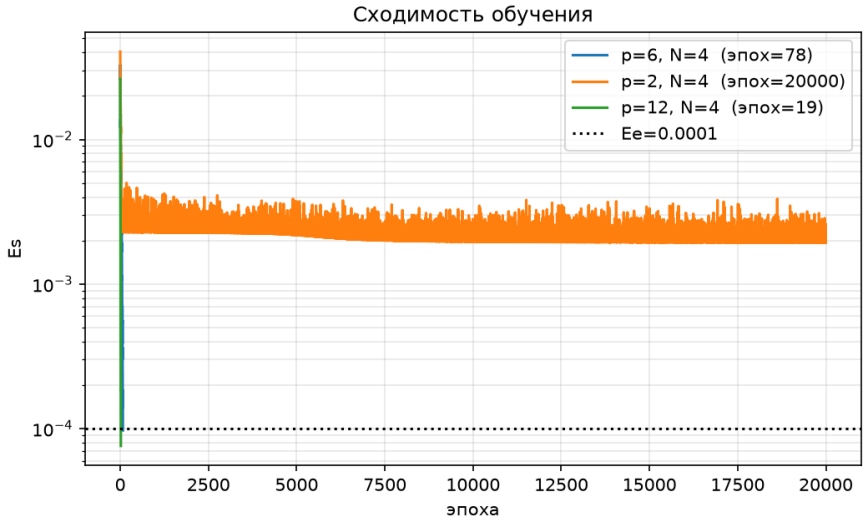
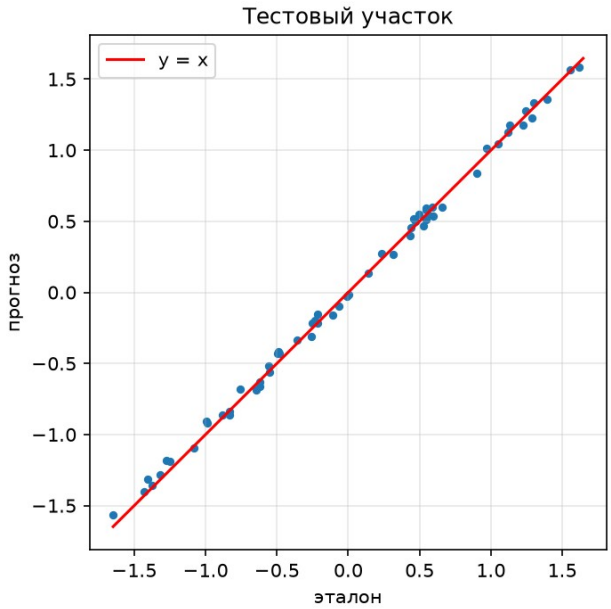
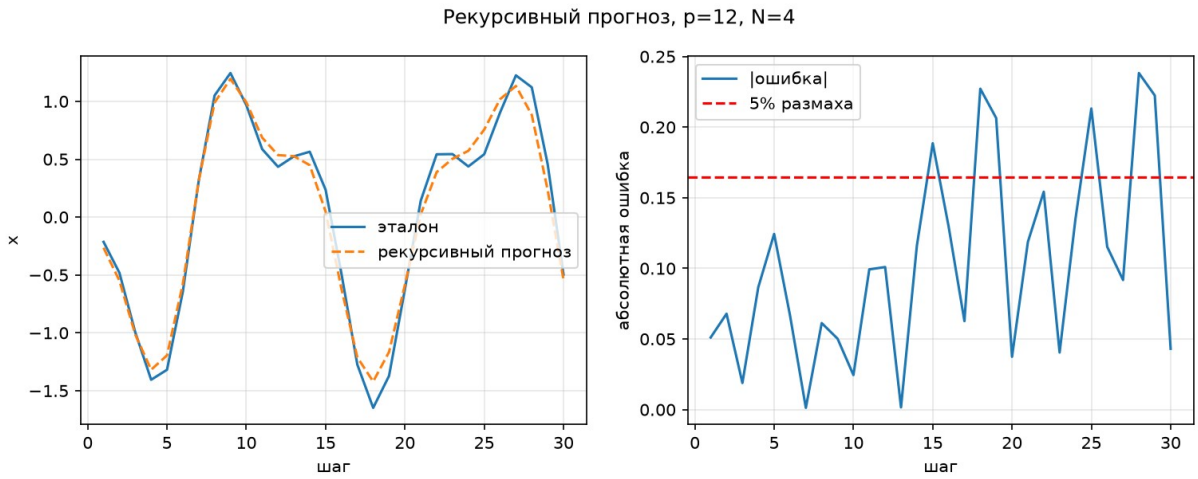


Диаграмма рассеяния «эталон – прогноз» на тестовом участке: точки лежат вдоль диагонали y = x с небольшим разбросом.



Рекурсивный прогноз на 30 шагов вперёд с k = 140 для лучшей по тестовому MAE конфигурации (p = 12, N = 4) и рост абсолютной ошибки по шагам показаны на рисунке 5. Ошибка впервые превышает 5 % размаха ряда (порог 0.1647) на шаге 15.



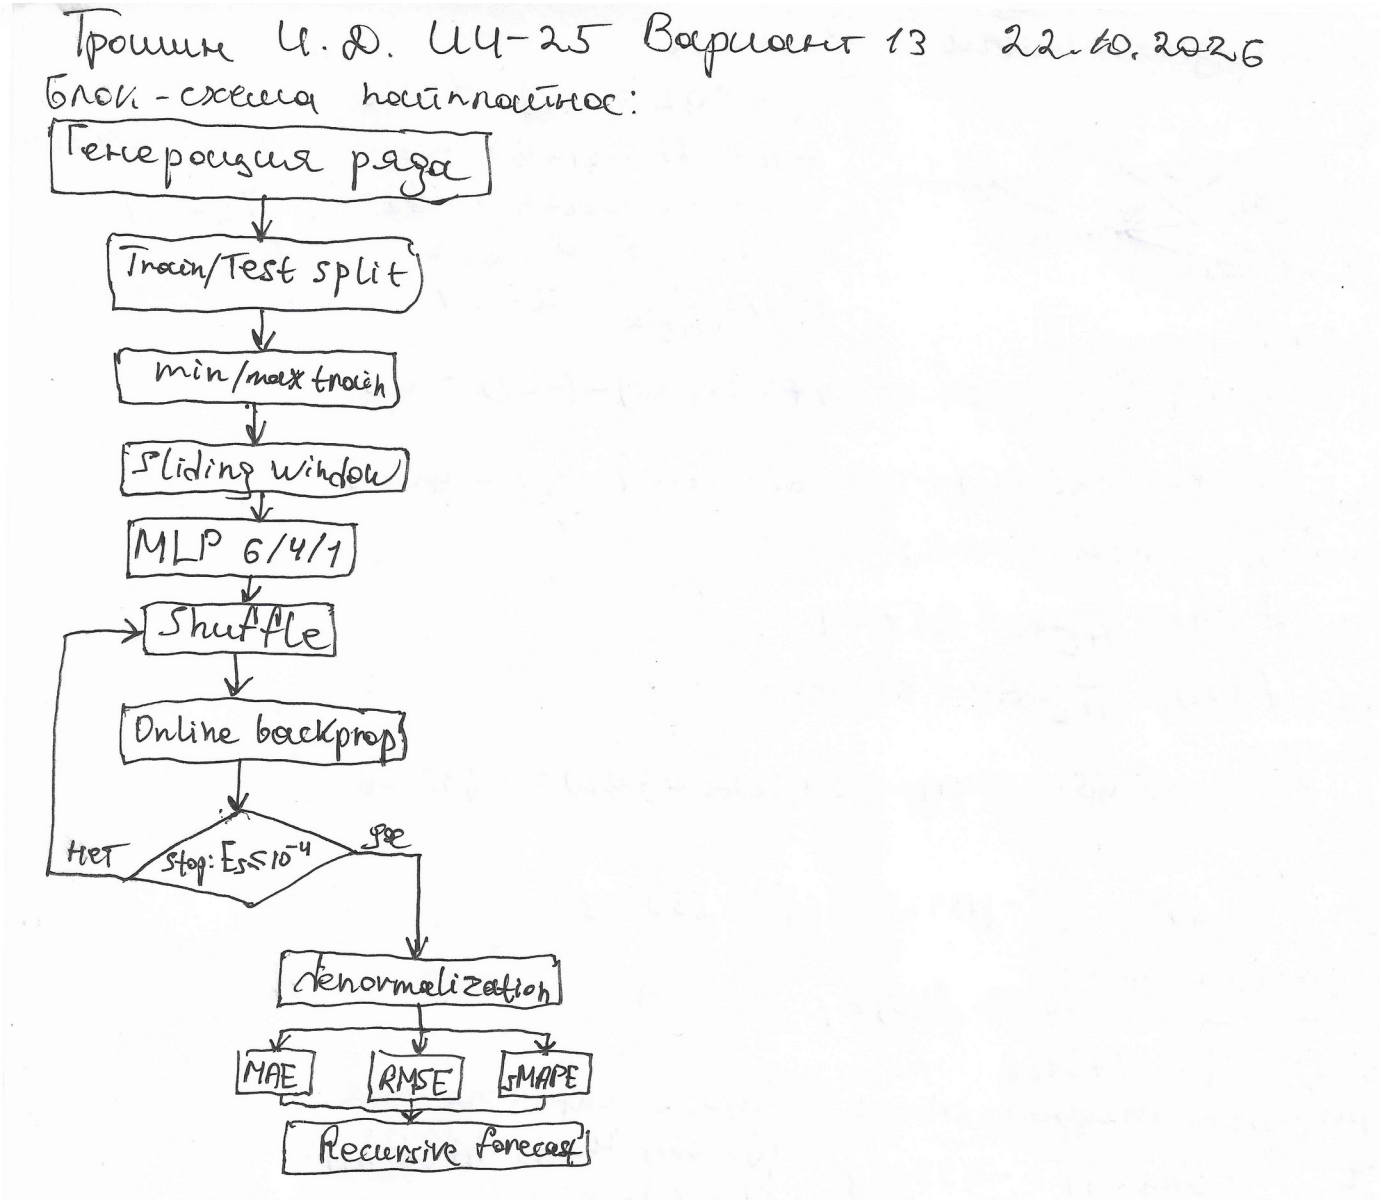
7 Режим функционирования

В режиме функционирования программа принимает p = 6 последовательных значений ряда в исходной шкале (или номер k, с которого окно берётся из ряда) и выводит нормализованные входы, прогноз в нормализованной шкале (4 знака после запятой), прогноз в исходной шкале, а также истинное значение x(k) и абсолютную ошибку, если окно взято из ряда. Результаты для трёх окон обучающего участка, трёх окон тестового участка и двух пользовательских окон (одно из них с выбросом: четвёртое значение окна k = 100 заменено на 3.0) приведены в таблице.

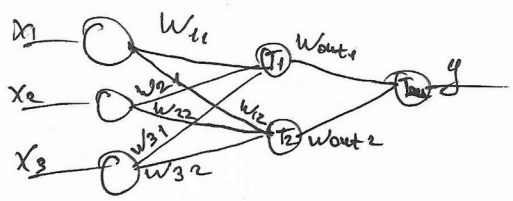
№	Окно	Нормализованные входы	Прогноз (норм.)	Прогноз (исходная шкала)	x(k)	Абс. ошибка
1	обучающий, k = 20	0.9184; 1.0000; 0.8828; 0.6439; 0.4270; 0.3319	0.3342	−0.5251	−0.4888	0.0363
2	обучающий, k = 60	0.3798; 0.4993; 0.5157; 0.5056; 0.5693; 0.7311	0.8868	1.2772	1.3374	0.0602
3	обучающий, k = 100	0.5888; 0.4238; 0.1868; 0.0139; 0.0212; 0.2128	0.4656	−0.0964	−0.0642	0.0322
4	тестовый, k = 150	0.0908; 0.2982; 0.5914; 0.8174; 0.8768; 0.7919	0.6784	0.5974	0.5875	0.0099
5	тестовый, k = 170	0.6617; 0.7721; 0.8707; 0.8389; 0.6357; 0.3430	0.1300	−1.1911	−1.2472	0.0561
6	тестовый, k = 190	0.2395; 0.2400; 0.3047; 0.3247;	0.2308	−0.8623	−0.8807	0.0184

№	Окно	Нормализованные входы	Прогноз (норм.)	Прогноз (исходная шкала)	x(k)	Абс. ошибка
		0.2637; 0.1924				
7	пользовательское: 0.9; 0.6; 0.1; −0.4; −0.9; −1.1	0.7712; 0.6792; 0.5259; 0.3726; 0.2192; 0.1579	0.1711	−1.0569	–	–
8	с выбросом (k = 100, четвёртое значение 3.0)	0.5888; 0.4238; 0.1868; 1.4151; 0.0212; 0.2128	−0.3235	−2.6702	−0.0642	2.6060

8 Рукописные расчёты



Расчет одного шага обучения:



$X = [0{,}2\ \ 0{,}5\ \ 0{,}8]\quad d = 0{,}6$

$w_{11} = 0{,}65\quad w_{21} = 0{,}3\quad w_{31} = -0{,}1\quad T_1 = -0{,}1$

$w_{12} = -0{,}2\quad w_{22} = 0{,}65\quad w_{32} = 0{,}4\quad T_2 = 0{,}1$

$w_{out1} = 0{,}5\quad w_{out2} = -2{,}6\quad T_{out} = -0{,}2$

$F(S) = \frac{1}{1+e^{-x}}\quad \alpha = 0{,}1$

Прямой проход:

$S_1 = \sum_{i=1}^{n} w_i x_i - T = 0{,}2 \cdot 0{,}65 + 0{,}5 \cdot 0{,}3 + 0{,}8 \cdot (-0{,}1) - (-0{,}1) = 0{,}3$

$S_2 = \sum_{i=1}^{n} w_i x_i - T = 0{,}2(-0{,}2) + 0{,}5 \cdot 0{,}65 + 0{,}8 \cdot 0{,}4 - 0{,}1 = 0{,}505$

Выходы скрытого слоя:

$h_1 = F(S_1) = \frac{1}{1+e^{-0{,}3}} = 0{,}57444$

$h_2 = f(S_2) = \frac{1}{1+e^{-0{,}505}} = 0{,}62365$

Выход:

$y = \sum_{i=1}^{n} w_i x_i - T = 0{,}5 \cdot 0{,}57444 - 2{,}6 \cdot 0{,}62365 - (-0{,}2) = -1{,}13426$

Ошибка:

$E = \frac{1}{2}(y-d)^2 = \frac{1}{2}(-1{,}13426 - 0{,}6)^2 = 1{,}50383$

Обратный проход:

Линейный выход $\Rightarrow f'(S) = 1$

$\delta_{out} = y - d = -1{,}73426$

Градиенты выходного слоя:

$\frac{\partial E}{\partial w_{out1}} = \delta_{out} \cdot h_1 = -0{,}99623$

$\frac{\partial E}{\partial w_{out2}} = \delta_{out} \cdot h_2 = -1{,}08156$

$\frac{\partial E}{\partial T_{out}} = -\delta_{out} = 1{,}73426$

Дельты скрытого слоя:

$\delta_j = \delta_{out} \cdot w_{outj} \cdot h_j(1-h_j)$:

$h_1(1-h_1) = 0{,}24446$

$h_2(1-h_2) = 0{,}23471$

$\delta_1 = -1{,}73426 \cdot 0{,}5 \cdot 0{,}24446 = -0{,}21198$

$\delta_2 = -1{,}73426 \cdot (-2{,}6) \cdot 0{,}23471 = 1{,}05833$

Градиенты скрытого слоя ($\frac{\partial E}{\partial w_{ij}} = \delta_i x_j$, $\frac{\partial E}{\partial T_j} = -\delta_j$):

$\frac{\partial E}{\partial w_{11}} = -0{,}04240\quad \frac{\partial E}{\partial w_{21}} = -0{,}10598\quad \frac{\partial E}{\partial w_{31}} = -0{,}16958\quad \frac{\partial E}{\partial T_1} = 0{,}21198$

$\frac{\partial E}{\partial w_{12}} = 0{,}21167\quad \frac{\partial E}{\partial w_{22}} = 0{,}52917\quad \frac{\partial E}{\partial w_{32}} = 0{,}84666\quad \frac{\partial E}{\partial T_2} = -1{,}05833$

Обновление весов ($w(t+1) = w(t) - \alpha \frac{\partial E}{\partial w(t)}$; $T(t+1) = T(t) - \alpha \frac{\partial E}{\partial T(t)}$):

$w_{out1} = 0{,}59362\quad w_{11} = 0{,}65424\quad w_{12} = -0{,}22117$

$w_{out2} = -2{,}49189\quad w_{21} = 0{,}31060\quad w_{22} = 0{,}59708$

$T_{out} = -0{,}37343\quad w_{31} = -0{,}08304\quad w_{32} = 0{,}31533$

$T_1 = -0{,}12120\quad T_2 = 0{,}20583$

Вывод:

1. Влияние размера окна. С ростом p число эпох до достижения критерия резко уменьшается: в среднем 756 эпох при p = 4, 86 при p = 6 и 27 при p = 12, а при p = 2 критерий за 20 000 эпох не достигается ни в одном из 5 запусков, тестовый MAE при этом 0.173 против 0.038 при p = 4. Сумма двух гармоник удовлетворяет линейному рекуррентному соотношению порядка 4 (каждая гармоника – порядка 2), поэтому для однозначного определения следующего значения нужно не менее четырёх предыдущих. Окна p = 2 недостаточно, чтобы разделить вклады двух частот, и сеть не может точно описать ряд. Начиная с p = 4 ошибка перестаёт заметно уменьшаться: тестовый MAE равен 0.0380 (p = 4), 0.0384 (p = 6) и 0.0338 (p = 12). Снижение при p = 12 невелико на фоне общего уровня ошибки около 0.04, который во многом задаётся самим порогом остановки E_e; более широкое окно добавляет избыточные входы и в основном ускоряет сходимость.

2. Влияние числа скрытых нейронов. Сумма двух гармоник при достаточном окне является линейной функцией входов, поэтому её способна воспроизвести даже минимальная сеть: нелинейность сигмоиды при малых весах слабо проявляется. Эксперимент это подтверждает: уже при N = 1 все 5 запусков достигают критерия (92 эпохи), с ростом N число эпох снижается лишь незначительно (89, 86 и 81 эпоха при N = 2, 4, 8), тестовый MAE составляет 0.0380, 0.0379, 0.0384 и 0.0354 для N = 1, 2, 4, 8, различия сопоставимы с разбросом по seed. Переобучение не наблюдается: в базовом эксперименте MAE на обучающем и тестовом участках равны 0.0392 и 0.0401, RMSE – 0.0455 и 0.0461, прогноз на тесте совпадает с эталоном. Таким образом, минимального N = 1 достаточно, чтобы воспроизвести сумму двух гармоник.

3. Линейный выход. В задаче регрессии выход должен принимать любые значения, а сигмоида ограничивает его диапазоном (0; 1) и насыщается у границ, где её производная близка к нулю, что замедляет обучение. Нормированные значения теста выходят за [0; 1] (минимум −0.0101), и сигмоидный выход не смог бы их воспроизвести. При обучении на ненормализованных значениях (до ±1.65) сигмоидный выход вообще не мог бы выдать отрицательные значения и значения больше 1, а входы с большими по модулю значениями быстро насыщали бы сигмоиды скрытого слоя. В ЛР №3 решалась задача классификации, где ограниченный выход уместен.

4. Нормализация по обучающему участку. Параметры масштабирования, вычисленные по всему ряду, использовали бы информацию о тесте (утечка данных), и оценка качества стала бы завышенной. Если нормализовать только по обучающему участку, тестовые значения могут выйти за [0; 1]: на нашем ряде нормированный тест лежит в диапазоне [−0.0101; 0.9903], так как локальные минимумы теста (около k = 157 и k = 171, x ≈ −1.65) ниже минимума обучающего участка (−1.615). На рисунке видно, что в крайней нижней точке прогноз (около −1.57) недооценивает эталон (около −1.65), то есть вблизи границы диапазона сеть теряет в точности. Ещё нагляднее выход за [0; 1] проявляется в режиме функционирования: у окна с выбросом нормированный вход равен 1.4151, и прогноз составил −2.6702 при истинном значении −0.0642 (ошибка 2.6060), так как линейный выход передаёт искажение входа без ограничения.

5. Устойчивость к инициализации. При $p \geq 4$ обучение устойчиво: во всех сериях по 5 запусков критерий E_e достигнут (0/5 неудачных), разброс числа эпох невелик (например, 756 ± 32 при $p = 4$, 86 ± 7 при $p = 6$), разброс тестового MAE не превышает 0.003. Все 5 запусков при $p = 2$ не достигли E_e за 20 000 эпох. Причина кроется в размере окна, а не в α или N: при $p = 2$ сети недостаточно информации о ряде, и ошибка не опускается ниже плато вне зависимости от начальных весов; при $p \geq 4$ и любом N из исследованного набора (1…8) при $\alpha = 0.1$ проблем со сходимостью нет.

6. Рекурсивный прогноз. При рекурсивном прогнозе сеть использует собственные предсказания как входы, поэтому ошибка предсказания на каждом шаге становится ошибкой входа на следующих p шагах и накапливается; при обучении сеть не видела таких зашумлённых окон. Ошибка растёт не монотонно (рисунок 5): на шагах 1, 5, 10, 20, 30 она равна 0.051, 0.124, 0.024, 0.037, 0.043, а максимум достигает около 0.24 на шаге 28, так как ряд периодический и ошибка по фазе то уменьшается, то увеличивается. Для сравнения, тестовый MAE одношагового прогноза составляет 0.034–0.040, поскольку там окна всегда состоят из истинных значений и ошибки не накапливаются. Порог 5 % размаха (0.1647) впервые превышен на шаге 15, поэтому пригодным можно считать горизонт около 14 шагов, что соответствует примерно одному периоду основной гармоники ($2\pi/0.42 \approx 15$ отсчётов).

7. Обобщающая способность. Различие ошибок на обучающем и тестовом участках характеризует способность сети обобщать закономерность на новые данные: в нашем эксперименте ошибки практически совпадают (MAE 0.0392 и 0.0401, sMAPE 13.9 % и 12.9 %), а прогноз на тесте близок к эталону, то есть сеть обобщает хорошо. Это объясняется тем, что ряд детерминирован, не содержит шума, а сеть мала по сравнению с числом обучающих примеров. Для улучшения обобщения при его ухудшении могут применяться ранняя остановка, уменьшение N, увеличение обучающей выборки и добавление шума к обучающим данным.