Министерство образования Республики Беларусь
Учреждение образования
«Брестский Государственный технический университет»
Кафедра ИИТ

Лабораторная работа №4

По дисциплине «Модели решения задач в ИС»

Тема: «Многослойный персептрон для прогнозирования временного ряда: влияние размера окна и числа скрытых нейронов»

Выполнил:
Студент 4 курса
Группы ИИ-25
Янушкевич В. А.
Проверила:
Андренко К. В.

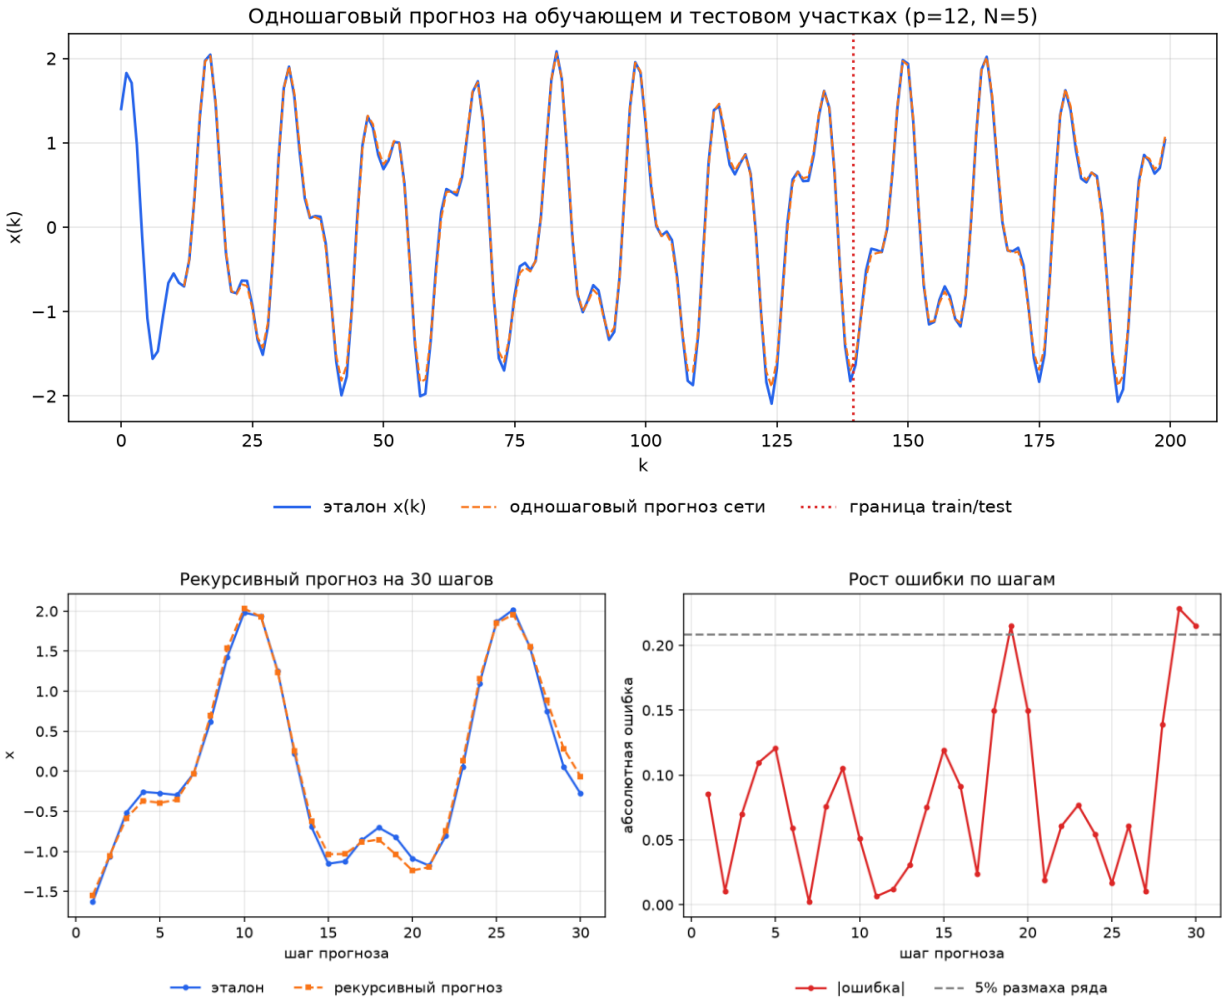
Брест 2026

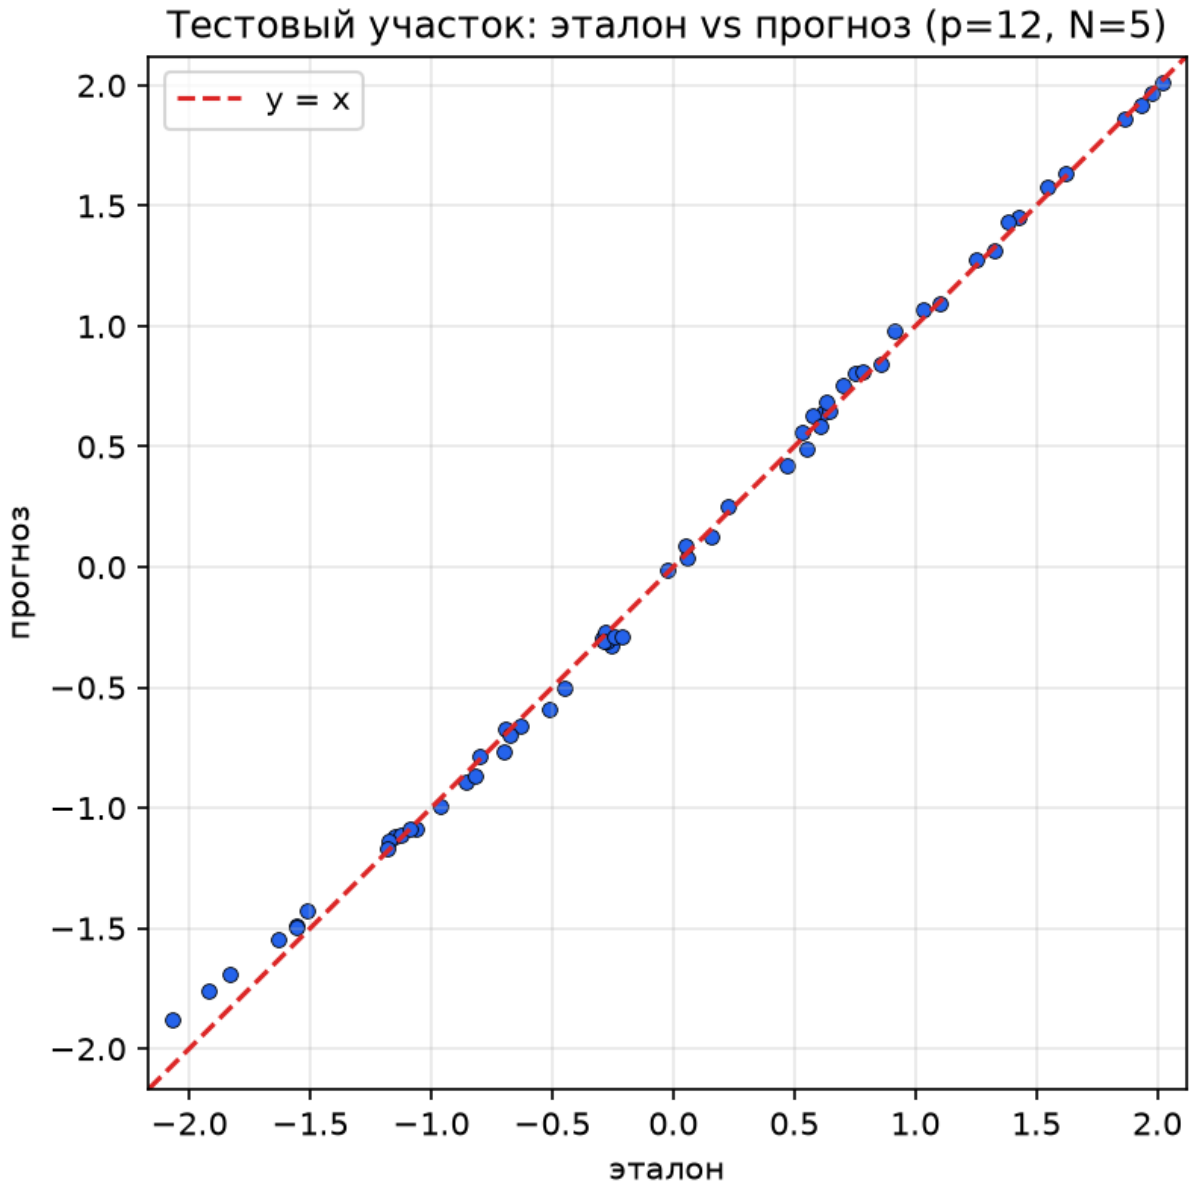
Цель работы: на основе многослойного персептрона p–N–1 решить задачу прогнозирования временного ряда. Научиться формировать обучающую выборку методом скользящего окна, нормализовать данные, оценивать качество одношагового и многошагового прогноза и исследовать влияние размера окна p и числа нейронов скрытого слоя N на точность прогноза и скорость обучения.

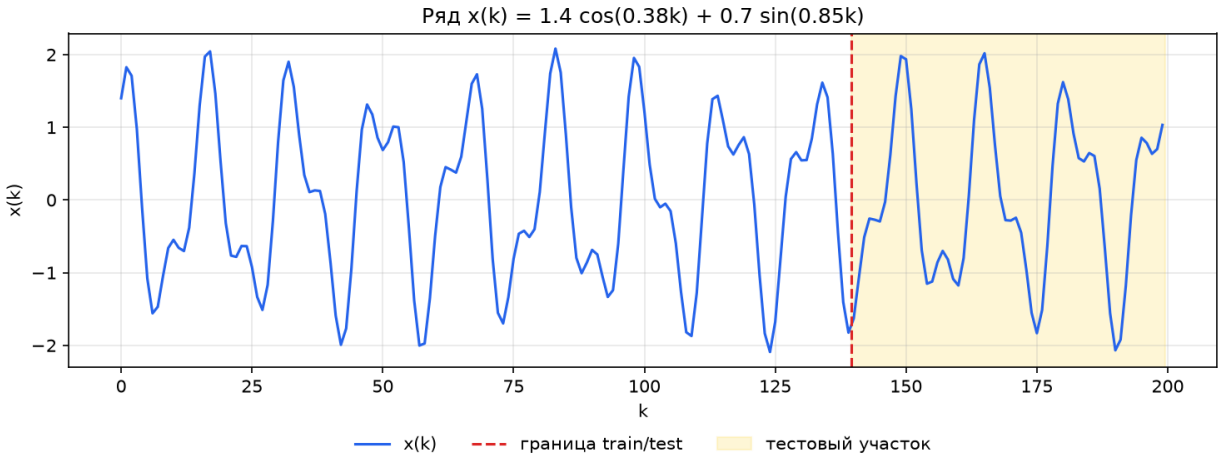
Вариант:

Вариант	a	b	c	d	p	N
11	1.4	0.38	0.7	0.85	6	5

Результат:




Тестовый участок: эталон vs прогноз (p=12, N=5)
y = x
прогноз
эталон
2.0
1.5
1.0
0.5
0.0
−0.5
−1.0
−1.5
−2.0
−2.0
−1.5
−1.0
−0.5
0.0
0.5
1.0
1.5
2.0


Ряд x(k) = 1.4 cos(0.38k) + 0.7 sin(0.85k)
x(k)
k
2
1
0
−1
−2
0
25
50
75
100
125
150
175
200
x(k)
граница train/test
тестовый участок

Вопросы:

1. Размер окна p. При p=2 качество плохое: тестовый MAE 0,188, и ни один из пяти запусков не достиг Ee за 20 000 эпох. Уже при p=4 тестовый MAE падает до 0,047, а при p=6 и p=12 остаётся около 0,046, так что ошибка перестаёт уменьшаться на p=4. Меняется только скорость обучения: 1208 эпох при p=4, около 120 при p=6 и около 21 при p=12. Окно в 2 значения не годится потому, что каждая гармоника подчиняется правилу «следующее значение = 2cos(ω)·предыдущее − то, что было перед ним», для которого нужны два прошлых значения. У ряда две гармоники, поэтому нужно минимум четыре значения. По двум сеть не может отделить одну гармонику от другой, и ошибка застревает на плато около 1,5·10^-3. Слишком большое окно точность не повышает, потому что всё нужное уже содержится в четырёх значениях, а остальные только повторяют информацию. Лишние входы ускоряют обучение, но все запуски всё равно останавливаются на одном уровне Es≈10^-4, поэтому и MAE получается почти одинаковым.

2. Число скрытых нейронов N. На точность N влияет слабо: тестовый MAE равен 0,0493 при N=1, 0,0478 при N=2, 0,0463 при N=5 и 0,0464 при N=10, то есть выигрыш заканчивается на N=5. На скорость обучения N почти не влияет (138, 142, 120 и 115 эпох). Переобучения нет: ошибки на обучении и на тесте практически совпадают, например при N=10 они равны 0,0467 и 0,0464. Минимального N=1 для заданной точности достаточно: все пять запусков сошлись. Вероятная причина в том, что следующее значение ряда линейно выражается через предыдущие, а сигмоида при малых весах работает почти как линейная функция, поэтому одного нейрона с линейным выходом хватает. При более строгом Ee или более сложном ряде нейронов понадобилось бы больше.

3. Линейный выход вместо сигмоиды. В ЛР №3 нужно было получить класс 0 или 1, то есть число между 0 и 1, и сигмоида для этого подходит. В регрессии выход может быть любым числом, и сигмоида создаёт проблемы. Она не может выдать значение за пределами диапазона обучающих данных, например новый пик выше прежних. У неё почти нулевая производная около 0 и 1, поэтому обучение замедляется как раз на пиках и впадинах. На ненормализованных данных, у нас от −2,1 до 2,1, сигмоида не могла бы выдавать ни отрицательные числа, ни числа больше 1, и ошибка осталась бы большой. Кроме того, крупные ненормализованные входы загоняют скрытые сигмоиды в насыщение. У линейного выхода градиент простой: δ = y − e.

4. Нормализация только по обучающему участку. Тестовый участок моделирует будущее, которого на момент обучения нет. Если взять минимум и максимум по всему ряду, в обучение просочится информация о тесте (утечка данных), и метрики станут оптимистичными. В реальном прогнозе будущих значений просто нет. Если тестовые значения выходят за диапазон от 0 до 1, сеть получает входы вне того диапазона, на котором училась, и ошибается сильнее. На наших данных этого не произошло: нормализованный тестовый участок лежит в пределах от 0,0056 до 0,9846, потому что обучающая часть уже содержит полный размах колебаний. Выход за диапазон виден только на пользовательском окне с выбросом: нормализованный вход равен 1,94, прогноз получается −0,53 в нормализованной шкале и −4,30 в исходной при настоящем значении −0,59.

5. Устойчивость к инициализации. Обучение очень устойчиво. При $p \geq 4$ и любом N сошлись все пять запусков, разброс небольшой: у базовой конфигурации 119,8 ± 2,5 эпохи и тестовый MAE 0,0463 ± 0,0023. Единственные провалы — при p=2: там не сошлись все пять запусков за 20 000 эпох. Причина в размере окна, то есть в нехватке информации, а не в случайной инициализации. При η от 0,01 до 0,3 и p=6 сошлись все запуски, а η влияет только на скорость: около 1144 эпох при 0,01 и около 45 при 0,3. От N сходимость тоже не зависит.

6. Рекурсивный прогноз. Каждое предсказание содержит небольшую ошибку, а затем подставляется в окно, и следующий прогноз строится уже на неточных данных, поэтому ошибки накапливаются. В нашем запуске (p=12, N=5) средняя ошибка на 30 шагах около 0,082 против 0,041 у одношагового прогноза, то есть примерно вдвое выше. Растёт она не монотонно, а волнами, сильнее всего на крутых участках ряда. В первые 17 шагов она не превышает 0,12, затем порог 5% размаха (0,209) впервые превышается на шаге 19 (0,215), после этого ошибка снова падает и опять превышает порог на шагах 29 и 30 (0,228 и 0,215). По критерию 5% прогноз можно считать пригодным примерно на 18 шагов, это около одного периода медленной гармоники (16–17 шагов).

7. Обобщающая способность и шум. Ошибки на обучающем и тестовом участках почти равны (MAE 0,0498 и 0,0502 у базовой конфигурации), то есть сеть хорошо обобщает. Переобучение выглядело бы как малая ошибка на обучении и заметно большая на тесте. Здесь ряд детерминированный, а тест является продолжением той же закономерности. Для улучшения обобщения можно использовать раннюю остановку (у нас её роль играет

критерий Es ≤ 10^-4), уменьшение N, добавление шума как регуляризацию и увеличение обучающей выборки, но на нашем ряду они почти не нужны, потому что разрыва между обучением и тестом нет. В эксперименте с шумом в обучающий участок добавлялся гауссов шум (σ = 5% размаха), а проверка шла на чистом ряде. Тестовый MAE вырос с 0,046 до 0,187 при N=5 и до 0,178 при N=10. Ошибка на чистых обучающих данных (0,19 и 0,18) при этом совпадает с тестовой, то есть сеть не запомнила шум, а просто стала менее точной, потому что училась на зашумлённых данных, и часть ошибки даёт усиление шума во входах. Увеличение N до 10 заметно не ухудшило результат. Это проверка влияния шума в данных, а не регуляризация шумом, так что вывод относится только к первому.

Вывод: на основе многослойного персептрона p–N–1 решил задачу прогнозирования временного ряда. Научился формировать обучающую выборку методом скользящего окна, нормализовать данные, оценивать качество одношагового и многошагового прогноза и исследовал влияние размера окна p и числа нейронов скрытого слоя N на точность прогноза и скорость обучения.