Министерство образования Республики Беларусь
Учреждение образования
«Брестский Государственный технический университет»
Кафедра ИИТ

Лабораторная работа №4

По дисциплине «Модели решения задач в ИС»

Тема: «Многослойный персептрон для прогнозирования временного ряда: влияние размера окна и числа скрытых нейронов»

Выполнил:
Студент 4 курса
Группы ИИ-25
Янушкевич В. А.
Проверила:
Андренко К. В.

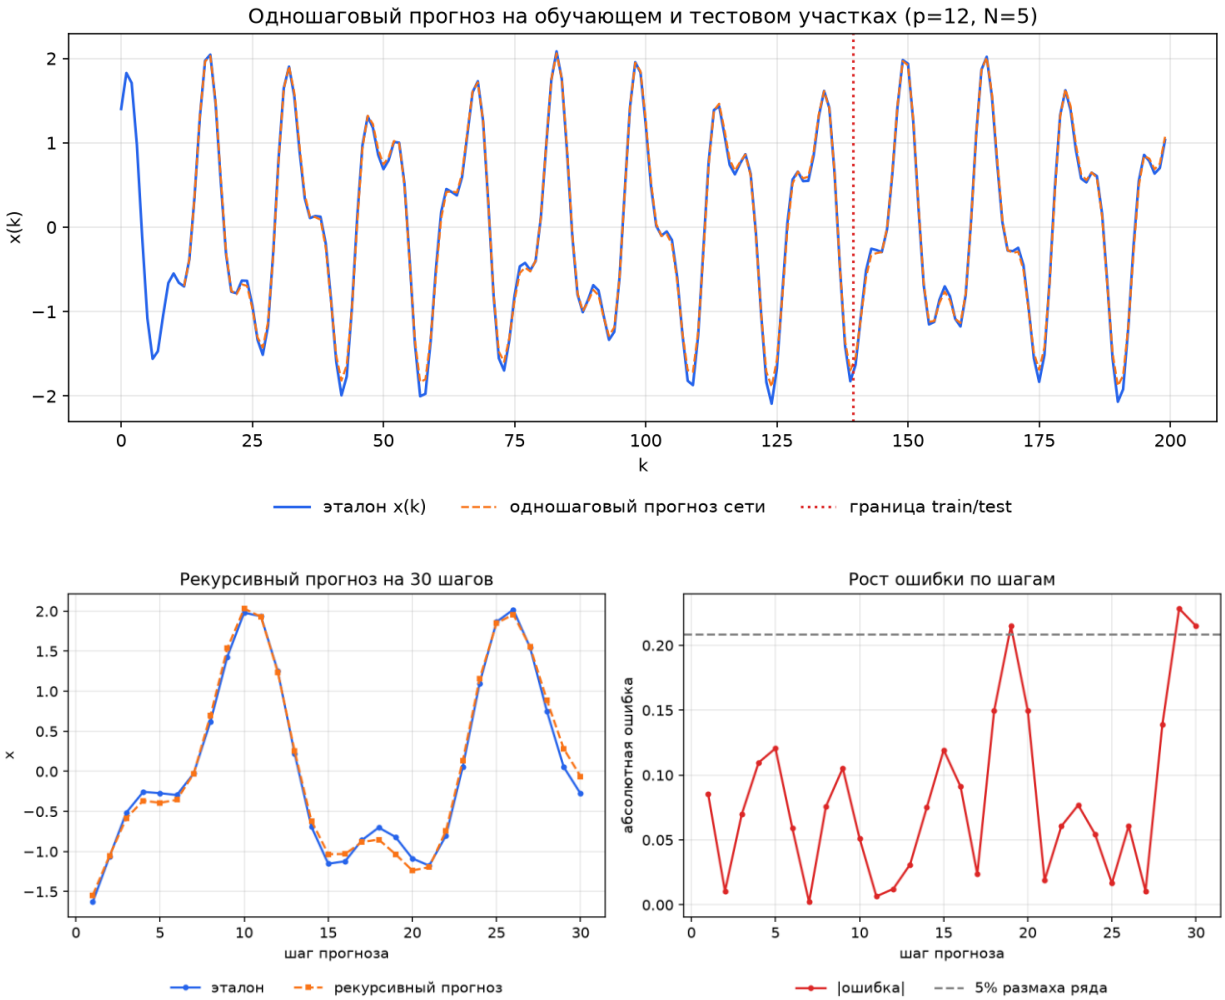
Брест 2026

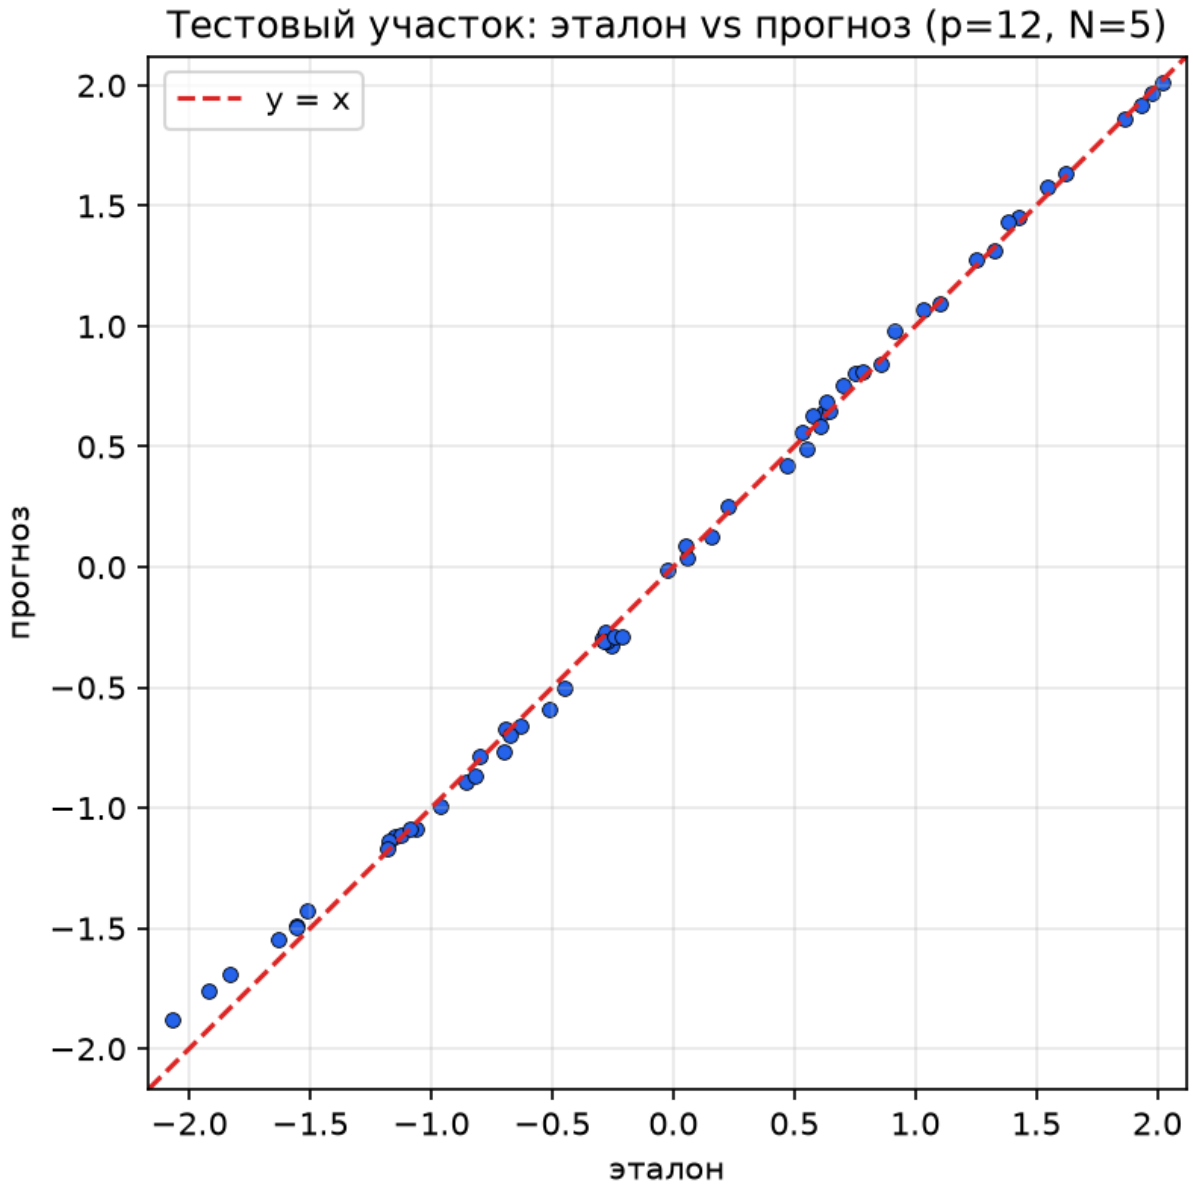
Цель работы: на основе многослойного персептрона p–N–1 решить задачу прогнозирования временного ряда. Научиться формировать обучающую выборку методом скользящего окна, нормализовать данные, оценивать качество одношагового и многошагового прогноза и исследовать влияние размера окна p и числа нейронов скрытого слоя N на точность прогноза и скорость обучения.

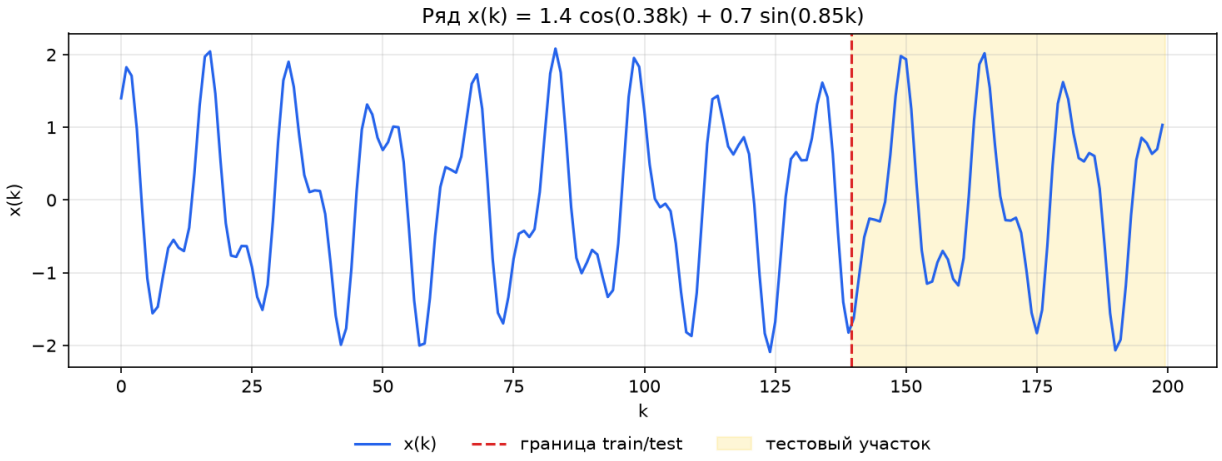
Вариант:

Вариант	a	b	c	d	p	N
11	1.4	0.38	0.7	0.85	6	5

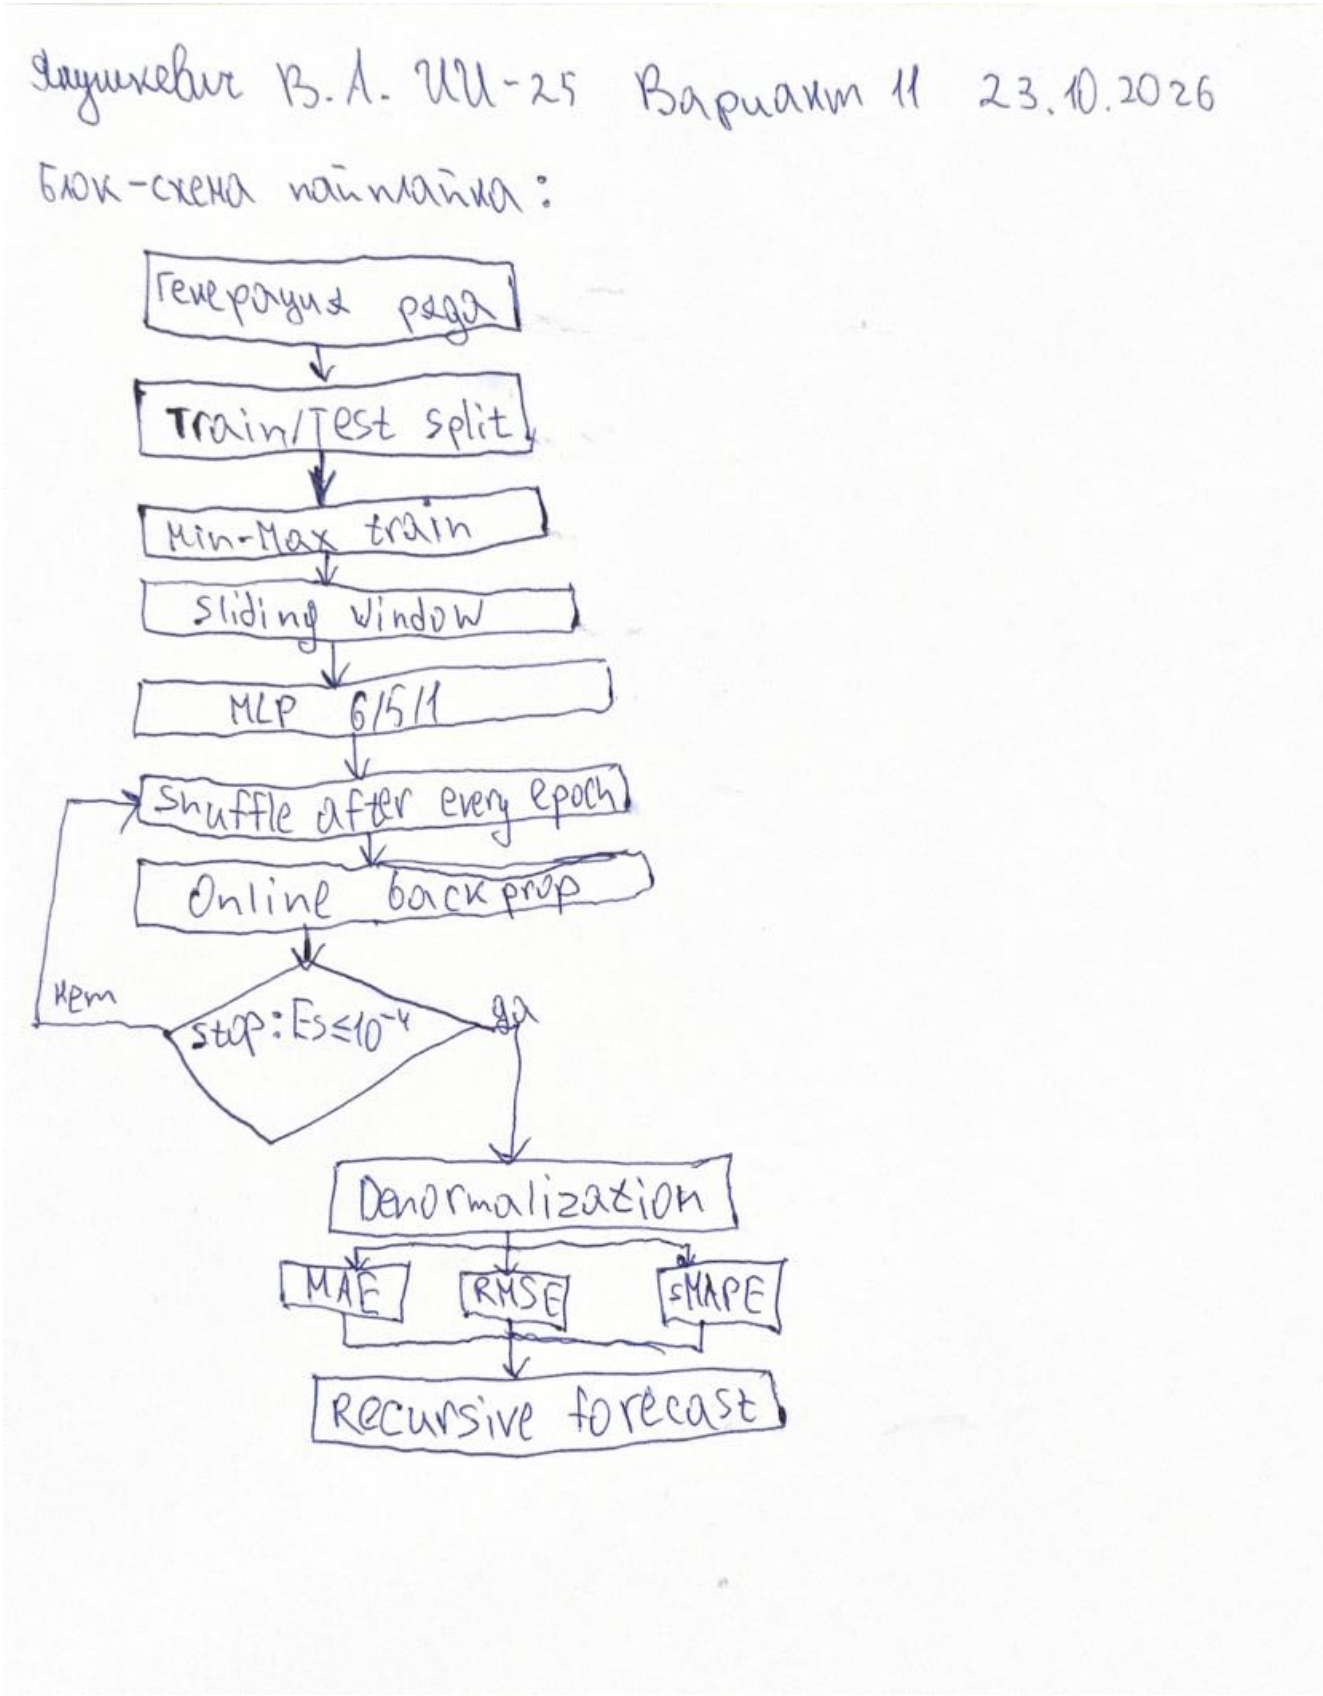
Результат:



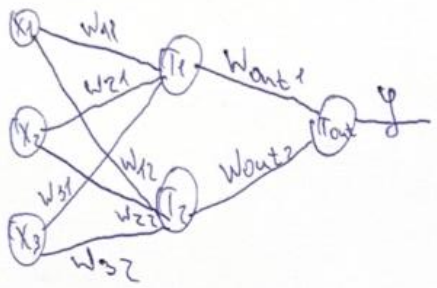

Тестовый участок: эталон vs прогноз (p=12, N=5)
y = x
прогноз
эталон
2.0
1.5
1.0
0.5
0.0
−0.5
−1.0
−1.5
−2.0
−2.0
−1.5
−1.0
−0.5
0.0
0.5
1.0
1.5
2.0


Ряд x(k) = 1.4 cos(0.38k) + 0.7 sin(0.85k)
x(k)
k
2
1
0
−1
−2
0
25
50
75
100
125
150
175
200
x(k)
граница train/test
тестовый участок

Рукописные расчеты:



Расчёт одного шага обучения:



$X = [0,2\ \ 0,5\ \ 0,8]$ $d = 0,6$

$W_{11} = 0,55$ $W_{21} = 0,3$ $W_{31} = -0,1$ $T_1 = -0,1$

$W_{12} = -0,2$ $W_{22} = 0,55$ $W_{32} = 0,4$ $T_2 = 0,1$

$W_{out1} = 0,5$ $W_{out2} = -2,2$ $T_{out} = -0,2$

$F(S) = \frac{1}{1+e^{-s}}$ $\alpha = 0,1$

Прямой проход:

$S_1 = \sum_{i=1}^{n} w_i x_i - T_1 = 0,2 \cdot 0,55 + 0,5 \cdot 0,3 + 0,8 \cdot (-0,1) - (-0,1) = 0,28;$

$S_2 = 0,2 \cdot (-0,2) + 0,5 \cdot 0,55 + 0,8 \cdot 0,4 - 0,1 = 0,455;$

Выходы скрытого слоя:

$h_1 = F(S_1) = \frac{1}{1+e^{-0,28}} = 0,56955;$

$h_2 = \frac{1}{1+e^{-0,455}} = 0,61183;$

Выход:

$y = \sum_{i=1}^{n} w_i x_i - T = 0,5 \cdot 0,56955 - 2,2 \cdot 0,61183 - (-0,2) = -0,86125;$

Ошибка:

$E = \frac{1}{2}(y-d)^2 = \frac{1}{2}(-0,86125 - 0,6)^2 = 1,06762;$

Обратный проход:

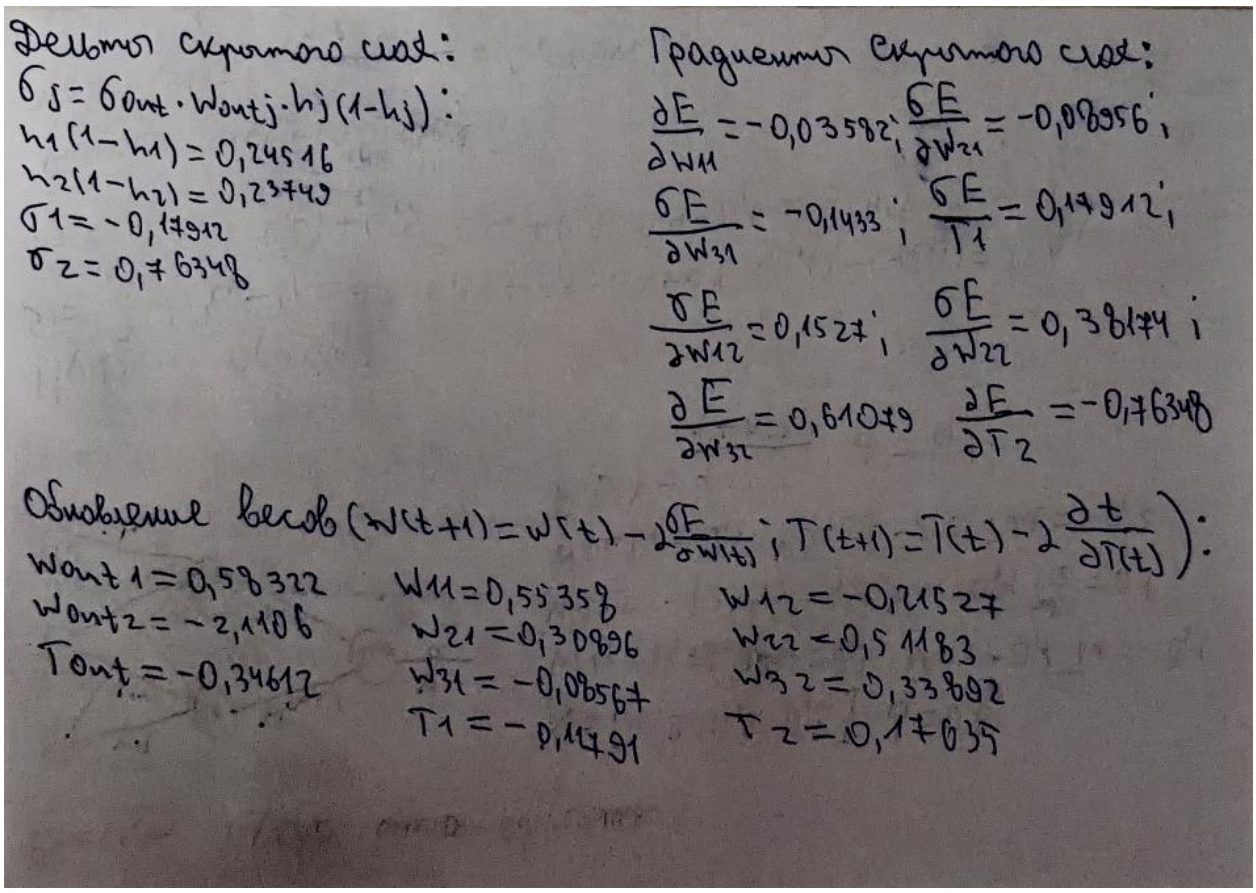
Линейный выход $\Rightarrow f'(S) = 1;$

$\sigma_{out} = y - d = -1,46125;$

Градиенты выходного слоя:

$\frac{\partial E}{\partial W_{out1}} = -0,83225$ $\frac{\partial E}{\partial T_{out}} = 1,46125$

$\frac{\partial E}{\partial W_{out2}} = -0,89403$



Вопросы:

1. Размер окна p. При p=2 качество плохое: тестовый MAE 0,188, и ни один из пяти запусков не достиг Ee за 20 000 эпох. Уже при p=4 тестовый MAE падает до 0,047, а при p=6 и p=12 остаётся около 0,046, так что ошибка перестаёт уменьшаться на p=4. Меняется только скорость обучения: 1208 эпох при p=4, около 120 при p=6 и около 21 при p=12. Окно в 2 значения не годится потому, что каждая гармоника подчиняется правилу «следующее значение = 2cos(ω)·предыдущее − то, что было перед ним», для которого нужны два прошлых значения. У ряда две гармоники, поэтому нужно минимум четыре значения. По двум сеть не может отделить одну гармонику от другой, и ошибка застревает на плато около 1,5·10^-3. Слишком большое окно точность не повышает, потому что всё нужное уже содержится в четырёх значениях, а остальные только повторяют информацию. Лишние входы ускоряют обучение, но все запуски всё равно останавливаются на одном уровне Es≈10^-4, поэтому и MAE получается почти одинаковым.

2. Число скрытых нейронов N. На точность N влияет слабо: тестовый MAE равен 0,0493 при N=1, 0,0478 при N=2, 0,0463 при N=5 и 0,0464 при N=10, то есть выигрыш заканчивается на N=5. На скорость обучения N почти не влияет (138, 142, 120 и 115 эпох). Переобучения нет: ошибки на обучении и

на тесте практически совпадают, например при N=10 они равны 0,0467 и 0,0464. Минимального N=1 для заданной точности достаточно: все пять запусков сошлись. Вероятная причина в том, что следующее значение ряда линейно выражается через предыдущие, а сигмоида при малых весах работает почти как линейная функция, поэтому одного нейрона с линейным выходом хватает. При более строгом Ее или более сложном ряде нейронов понадобилось бы больше.

3. Линейный выход вместо сигмоиды. В ЛР №3 нужно было получить класс 0 или 1, то есть число между 0 и 1, и сигмоида для этого подходит. В регрессии выход может быть любым числом, и сигмоида создаёт проблемы. Она не может выдать значение за пределами диапазона обучающих данных, например новый пик выше прежних. У неё почти нулевая производная около 0 и 1, поэтому обучение замедляется как раз на пиках и впадинах. На ненормализованных данных, у нас от −2,1 до 2,1, сигмоида не могла бы выдавать ни отрицательные числа, ни числа больше 1, и ошибка осталась бы большой. Кроме того, крупные ненормализованные входы загоняют скрытые сигмоиды в насыщение. У линейного выхода градиент простой: $\delta = y - e$.

4. Нормализация только по обучающему участку. Тестовый участок моделирует будущее, которого на момент обучения нет. Если взять минимум и максимум по всему ряду, в обучение просочится информация о тесте (утечка данных), и метрики станут оптимистичными. В реальном прогнозе будущих значений просто нет. Если тестовые значения выходят за диапазон от 0 до 1, сеть получает входы вне того диапазона, на котором училась, и ошибается сильнее. На наших данных этого не произошло: нормализованный тестовый участок лежит в пределах от 0,0056 до 0,9846, потому что обучающая часть уже содержит полный размах колебаний. Выход за диапазон виден только на пользовательском окне с выбросом: нормализованный вход равен 1,94, прогноз получается −0,53 в нормализованной шкале и −4,30 в исходной при настоящем значении −0,59.

5. Устойчивость к инициализации. Обучение очень устойчиво. При $p \geq 4$ и любом N сошлись все пять запусков, разброс небольшой: у базовой конфигурации 119,8 ± 2,5 эпохи и тестовый MAE 0,0463 ± 0,0023. Единственные провалы — при p=2: там не сошлись все пять запусков за 20 000 эпох. Причина в размере окна, то есть в нехватке информации, а не в случайной инициализации. При η от 0,01 до 0,3 и p=6 сошлись все запуски, а η влияет только на скорость: около 1144 эпох при 0,01 и около 45 при 0,3. От N сходимость тоже не зависит.

6. Рекурсивный прогноз. Каждое предсказание содержит небольшую ошибку, а затем подставляется в окно, и следующий прогноз строится уже на неточных данных, поэтому ошибки накапливаются. В нашем запуске (p=12, N=5) средняя ошибка на 30 шагах около 0,082 против 0,041 у одношагового прогноза, то есть примерно вдвое выше. Растёт она не монотонно, а волнами, сильнее всего на крутых участках ряда. В первые 17 шагов она не превышает 0,12, затем порог 5% размаха (0,209) впервые превышается на шаге 19 (0,215), после этого ошибка снова падает и опять превышает порог на шагах 29 и 30 (0,228 и 0,215). По критерию 5% прогноз можно считать пригодным примерно на 18 шагов, это около одного периода медленной гармоники (16–17 шагов).

7. Обобщающая способность. Ошибки на обучающем и тестовом участках практически совпадают (MAE 0.0498 и 0.0502, RMSE 0.0589 и 0.0591), а прогноз на тесте близок к эталону, то есть сеть хорошо обобщает закономерность на новые данные. Переобучение проявлялось бы как малая ошибка на обучении при заметно большей на тесте; здесь его нет, так как ряд детерминирован, не содержит шума, а тестовый участок продолжает ту же закономерность. Для улучшения обобщения при его ухудшении могут применяться ранняя остановка, уменьшение N, добавление шума к обучающим данным и увеличение обучающей выборки. В нашей работе эти меры отдельно не проверялись, и эксперимент с добавлением шума не проводился; по смыслу к ранней остановке близок критерий $E_s \le 10^{-4}$, а в исследовании числа нейронов уменьшение N тестовую ошибку не улучшило. Поскольку разрыва между обучением и тестом нет, заметного выигрыша от этих мер на нашем ряде ожидать не приходится.

Вывод: на основе многослойного персептрона p–N–1 решил задачу прогнозирования временного ряда. Научился формировать обучающую выборку методом скользящего окна, нормализовать данные, оценивать качество одношагового и многошагового прогноза и исследовал влияние размера окна p и числа нейронов скрытого слоя N на точность прогноза и скорость обучения.