Министерство образования Республики Беларусь

Учреждение образования

«Брестский Государственный технический университет»

Кафедра ИИТ

**Лабораторная работа №4**

По дисциплине «Модели решения задач в интеллектуальных системах»

Тема: «Многослойный персептрон для прогнозирования временного ряда: влияние размера окна и числа скрытых нейронов»

**Выполнил:**

Студент 4 курса

Группы ИИ-25

Елец Ю. А.

**Проверил:**

Андренко К.В.

Брест 2026

**Цель работы:** на основе многослойного персептрона p–N–1 решить задачу прогнозирования временного ряда. Научиться формировать обучающую выборку методом скользящего окна, нормализовать данные, оценивать качество одношагового и многошагового прогноза и исследовать влияние размера окна p и числа нейронов скрытого слоя N на точность прогноза и скорость обучения.

**Задачи лабораторной работы:**

1. Сгенерировать ряд по формуле варианта и построить его график с отметкой границы между обучающим и тестовым участками.
2. Нормализовать ряд по минимуму и максимуму обучающего участка: x_norm = (x - x_min) / (x_max - x_min). Записать формулу обратного пересчёта и использовать её при вычислении всех метрик в исходной шкале. Объяснить, почему min/max нельзя брать по всему ряду.
3. Сформировать обучающую и тестовую выборки методом скользящего окна размера p (вход – p значений, цель – следующее значение). Указать количество получившихся примеров в каждой выборке.
4. Реализовать многослойный персептрон p–N–1:
   - скрытый слой – сигмоида;
   - выходной слой – линейный (задача регрессии), f(s) = s;
   - функция потерь – MSE;
   - обучение – онлайн-режим, перемешивание порядка примеров в каждой эпохе;
   - вывести формулы градиентов для линейного выходного слоя и сигмоидного скрытого слоя и привести их в отчёте.
5. Критерий остановки: средняя по обучающей выборке ошибка $E_s \le E_e$, где $E_e = 10^{-4}$ (нормализованная шкала), либо достижение 20 000 эпох. Скорость обучения подобрать самостоятельно из диапазона 0.01–0.3 и обосновать выбор.
6. **Базовый эксперимент.** Обучить сеть с параметрами p и N из своего варианта. Зафиксировать число эпох, итоговую $E_s$, а также метрики на обучающем и тестовом участках **в исходной шкале**: MAE, RMSE и MAPE (если ряд проходит через ноль – вместо MAPE использовать sMAPE, и пояснить почему).
7. **Исследование окна.** При фиксированном N из варианта обучить сеть для $p \in \{2, 4, p_{вар}, 2 \cdot p_{вар}\}$. Для каждого p выполнить по 5 запусков с разными seed и свести в таблицу: среднее и разброс числа эпох, среднее и разброс тестового MAE, число запусков, не достигших критерия остановки.
8. **Исследование скрытого слоя.** При фиксированном p из варианта обучить сеть для $N \in \{1, 2, N_{вар}, 2 \cdot N_{вар}\}$. Выполнить ту же серию из 5 запусков и заполнить аналогичную таблицу.
9. **Многошаговый прогноз.** Для лучшей по тестовому MAE конфигурации выполнить рекурсивный прогноз на 30 шагов вперёд, начиная с k = 140: каждое предсказание подставляется в окно как входное значение для следующего шага. Построить график «эталон – рекурсивный прогноз» и график абсолютной ошибки в зависимости от номера шага. Определить, на каком шаге ошибка превышает 5 % от размаха ряда.
10. Построить графики:
    - ряд с границей train/test и одношаговым прогнозом сети на обоих участках на одних осях;
    - сходимость ($E_s$ от эпохи) для базовой конфигурации и для двух конфигураций из исследования окна на одних осях (логарифмическая шкала по Y);
    - диаграмма рассеяния «эталон – прогноз» на тестовом участке с диагональю y = x;
    - рекурсивный прогноз и рост ошибки по шагам (п. 9).

11. Реализовать режим функционирования: пользователь вводит p последовательных значений ряда в исходной шкале (либо номер k, с которого брать окно из ряда). Программа выводит:
    - нормализованные входы;
    - прогноз в нормализованной шкале (4 знака после запятой);
    - прогноз в исходной шкале;
    - истинное значение x(k) и абсолютную ошибку (если окно взято из ряда).

Продемонстрировать работу не менее чем на 3 окнах из обучающего участка, 3 окнах из тестового участка и 1–2 пользовательских окнах (в том числе с «выбросом»).

12. Вставить в отчет фото/скан рукописных расчётов. Вверху листа от руки должны быть написаны Ваша Фамилия, Инициалы, номер группы, вариант и дата выполнения:
    - Графическая схема пайплайна (Блок-схема). Составьте корректную цепочку обработки данных, используя предложенный набор блоков (приложение 1). Объясните свой выбор.
    - Ручной расчёт 1 шага обучения. На отдельном листе бумаги от руки распишите один полный шаг (Forward + Backward pass) для сети 3–2–1 со следующими параметрами, привязанными к вашему варианту V:
    - - Входы: X = [0.2, 0.5, 0.8], Цель: d = 0.6
    - - Веса скрытого слоя: W11 = 0.05*V, W12 = -0.2, W21 = 0.3, W22 = 0.05*V, W31 = -0.1, W32 = 0.4 (b1=0.1, b2=-0.1)
    - - Веса выходного слоя: W_out1 = 0.5, W_out2 = -0.2*V (b_out = 0.2)
13. Сделать вывод: ответить на все вопросы ниже и проанализировать результаты

**Вариант 4**

| Вариант | a | b | c | d | p | N |
|---|---|---|---|---|---|---|
| 4 | 0.8 | 0.2 | 0.4 | 0.5 | 8 | 4 |

Ряд: xk=a·cosb·k+c·sind·k, k = 0…199, p – размер окна, N – число скрытых нейронов

**Описание метода:**

**1. Нормализация:**

Min/max считаются только по обучающему участку (k = 0…139), чтобы тест не участвовал в настройке масштаба

$$x_{min} = \min_{k=0..139} x(k), \qquad x_{max} = \max_{k=0..139} x(k)$$

$$x_{norm}(k) = \frac{x(k) - x_{min}}{x_{max} - x_{min}}$$

Обратный пересчёт (для всех метрик и графиков в исходной шкале):

$$x(k) = x_{norm}(k) \cdot (x_{max} - x_{min}) + x_{min}$$

Почему нельзя по всему ряду. Тестовая часть не должна участвовать в подготовке данных, иначе модель получает подсказку о том, какими будут значения, которые она должна предсказывать. При нормировке по train тестовые точки иногда выходят за пределы [0; 1] (амплитуда тестового отрезка может слегка отличаться от обучающего).

**2. Формирование выборки методом скользящего окна**

Для размера окна *p* и целевого индекса *k*:

вход: $\left(x_{norm}(k-p),\ x_{norm}(k-p+1),\ \ldots,\ x_{norm}(k-1)\right)$, цель: $x_{norm}(k)$

Разбиение на участки:

- Обучающий: k = p…139. Для p = 8 это 132 примера.

- Тестовый: k = 140…199 – 60 примеров. Окна теста могут начинаться в конце обучающего отрезка – это допустимо, поскольку эти значения на момент прогноза уже известны.

**3. Архитектура MLP p–N–1**

- Входной слой: p значений (скользящее окно).
- Скрытый слой: N нейронов с сигмоидной активацией.
- Выходной слой: один нейрон с линейной активацией.
- Функция потерь: MSE, усреднённая по всем примерам эпохи.
- Обучение: онлайн-режим, порядок примеров перемешивается в начале каждой эпохи.

Прямой проход:

$$S_j = \sum_{i=1}^{p} x_i w_{ij} + b_j, \qquad y_j = F(S_j) = \sigma(S_j) = \frac{1}{1+e^{-S_j}}, \qquad j = 1, \ldots, N$$

$$S = \sum_{j=1}^{N} y_j\, w_j + b, \qquad y = F(S) = S$$

**4. Вывод градиентов**

Функция потерь для одного примера: $E=1/2(e-y)^2$, где $e$ – целевое значение.

Выходной нейрон (линейная активация, производная равна 1):

$$\delta = (e - y) \cdot F'(S) = (e - y) \cdot 1 = e - y$$

Скрытый слой (сигмоида; ошибка передаётся обратно через веса следующего слоя):

$$\delta_j = \left(\delta \cdot w_j\right) \cdot y_j(1 - y_j)$$

Обобщённое дельта-правило (обновление весов):

$$w_j(t+1) = w_j(t) + \eta\, \delta\, y_j, \qquad b(t+1) = b(t) + \eta\, \delta$$

$$w_{ij}(t+1) = w_{ij}(t) + \eta\, \delta_j\, x_i, \qquad b_j(t+1) = b_j(t) + \eta\, \delta_j$$

**5. Формулы метрик**

Все метрики вычисляются в исходной шкале, после обратного преобразования прогнозов.

Пусть ek– истинное значение, yk – прогноз, n – количество примеров.

$$MAE = \frac{1}{n}\sum_{k=1}^{n} |y_k - e_k|, \qquad RMSE = \sqrt{\frac{1}{n}\sum_{k=1}^{n} (y_k - e_k)^2}$$

$$MAPE = \frac{100\%}{n}\sum_{k=1}^{n} \left|\frac{y_k - e_k}{e_k}\right|$$

Почему вместо MAPE применяется sMAPE. Ряд 0.8cos(0.2k) + 0.4sin(0.5k) периодически проходит через ноль. В таких точках знаменатель MAPE близок к нулю, и метрика либо резко возрастает, либо становится неопределённой. Чтобы избежать этого, применяется симметричная версия:

$$sMAPE = \frac{100\%}{n}\sum_{k=1}^{n} \frac{2\,|y_k - e_k|}{|y_k| + |e_k|}$$

Небольшая добавка $10^{-12}$ в знаменателе защищает от деления на ноль, когда и прогноз, и истинное значение одновременно равны нулю. Благодаря этому метрика остаётся корректной на всём диапазоне ряда.

**Результат:**

```
train: k=0..139 (140 точек); test: k=140..199 (60 точек)
```

```
min по train: -1.1999, max по train: 1.0824
Окон train: 132, окон test: 60

Базовый эксперимент: p=8, N=4, seed=0
эпохи=313  Es=9.893300e-05  сошлось=True
train: MAE=0.0183  RMSE=0.0227  sMAPE=6.66%
test:  MAE=0.0196  RMSE=0.0237  sMAPE=7.62%

Исследование p: N=4, 5 seed
p= 2  эпохи 20000±0  тест. MAE 0.0419±0.0017  не сошлось 5/5
p= 4  эпохи 9303±541  тест. MAE 0.0182±0.0001  не сошлось 0/5
p= 8  эпохи 304±23  тест. MAE 0.0195±0.0001  не сошлось 0/5
p=16  эпохи 23±2  тест. MAE 0.0152±0.0018  не сошлось 0/5

Исследование N: p=8, 5 seed
N= 1  эпохи 333±9  тест. MAE 0.0196±0.0002  не сошлось 0/5
N= 2  эпохи 338±25  тест. MAE 0.0195±0.0003  не сошлось 0/5
N= 4  эпохи 304±23  тест. MAE 0.0195±0.0001  не сошлось 0/5
N= 8  эпохи 304±11  тест. MAE 0.0193±0.0003  не сошлось 0/5

Лучшая по среднему тест. MAE: p=16, N=4, MAE=0.0152

Рекурсивный прогноз (p=16, N=4, steps=30): MAE=0.0313
размах train=2.2822, порог 5%=0.1141, первый шаг превышения: не превышен

Режим функционирования:
k=11 (train)
нормализованные входы: [0.9899, 0.9293, 0.8200, 0.6775, 0.5238, 0.3829, 0.2748,
0.2118]
нормализованный прогноз: 0.1930
прогноз (ряд): -0.7593
истинный x(k): -0.7530
абсолютная ошибка: 0.0063

k=47 (train)
нормализованные входы: [0.6508, 0.6347, 0.5816, 0.4904, 0.3705, 0.2399, 0.1210,
0.0357]
нормализованный прогноз: 0.0019
прогноз (ряд): -1.1954
истинный x(k): -1.1990
абсолютная ошибка: 0.0035

k=121 (train)
нормализованные входы: [0.2297, 0.3602, 0.4817, 0.5756, 0.6320, 0.6507, 0.6415,
0.6210]
нормализованный прогноз: 0.5967
прогноз (ряд): 0.1619
истинный x(k): 0.1869
абсолютная ошибка: 0.0250

k=148 (test)
нормализованные входы: [0.3240, 0.3484, 0.3447, 0.3140, 0.2670, 0.2213, 0.1964,
0.2089]
нормализованный прогноз: 0.2511
прогноз (ряд): -0.6268
истинный x(k): -0.5882
абсолютная ошибка: 0.0386

k=163 (test)
нормализованные входы: [0.9975, 0.9582, 0.8832, 0.7925, 0.7071, 0.6440, 0.6118,
0.6094]
```

```
нормализованный прогноз: 0.6224
прогноз (ряд): 0.2207
истинный x(k): 0.2296
абсолютная ошибка: 0.0089

k=192 (test)
нормализованные входы: [0.6073, 0.6215, 0.6673, 0.7415, 0.8316, 0.9182, 0.9803,
0.9997]
нормализованный прогноз: 0.9741
прогноз (ряд): 1.0232
истинный x(k): 1.0049
абсолютная ошибка: 0.0184

окно 1 (с выбросом в середине +3)
нормализованные входы: [0.3206, 0.2754, 0.2280, 0.1983, 1.5181, 0.2547, 0.3524,
0.4868]
нормализованный прогноз: 0.0921
прогноз (ряд): -0.9897

окно 2 (без выброса)
нормализованные входы: [0.3000, 0.3000, 0.3000, 0.3000, 0.3000, 0.3000, 0.3000,
0.3000]
нормализованный прогноз: 0.3138
прогноз (ряд): -0.4838

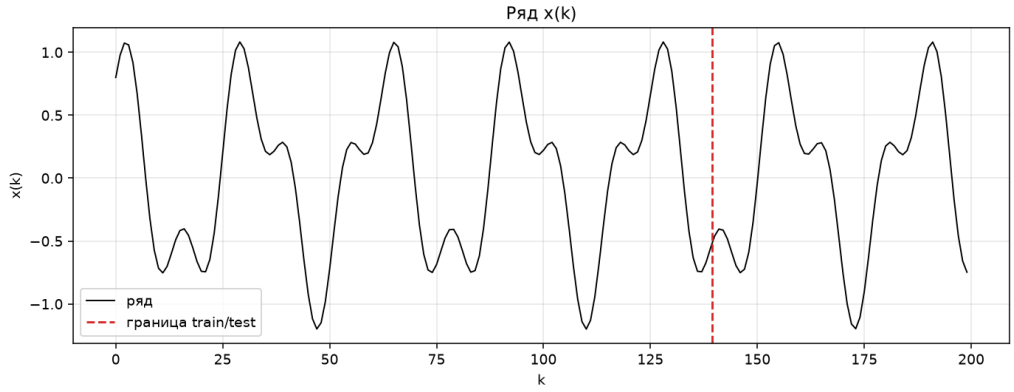
Интерактивный режим, для выхода введите q
Введите номер k (8..199) или 8 чисел в исходной шкале: 22
k=22 (train)
нормализованные входы: [0.3106, 0.3431, 0.3492, 0.3268, 0.2836, 0.2353, 0.2013,
0.1997]
нормализованный прогноз: 0.2274
прогноз (ряд): -0.6809
истинный x(k): -0.6459
абсолютная ошибка: 0.0350

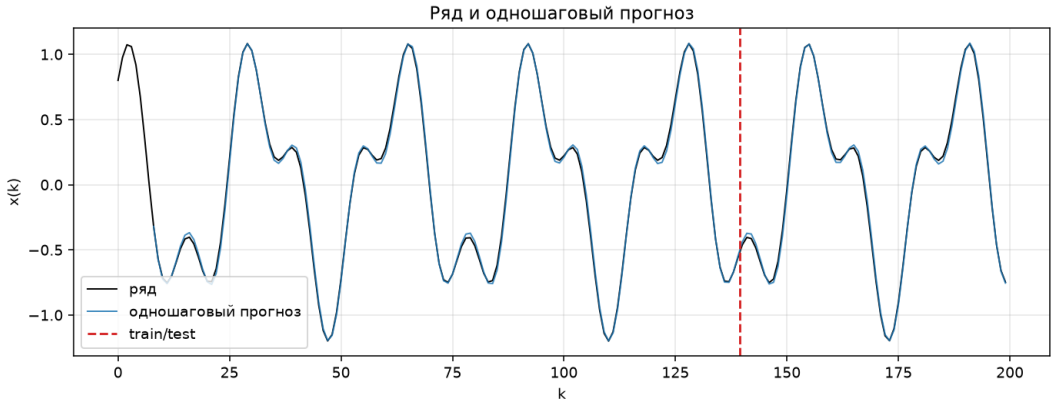
Введите номер k (8..199) или 8 чисел в исходной шкале: 196
k=196 (test)
нормализованные входы: [0.8316, 0.9182, 0.9803, 0.9997, 0.9660, 0.8795, 0.7510,
0.5999]
нормализованный прогноз: 0.4547
прогноз (ряд): -0.1620
истинный x(k): -0.1735
абсолютная ошибка: 0.0114

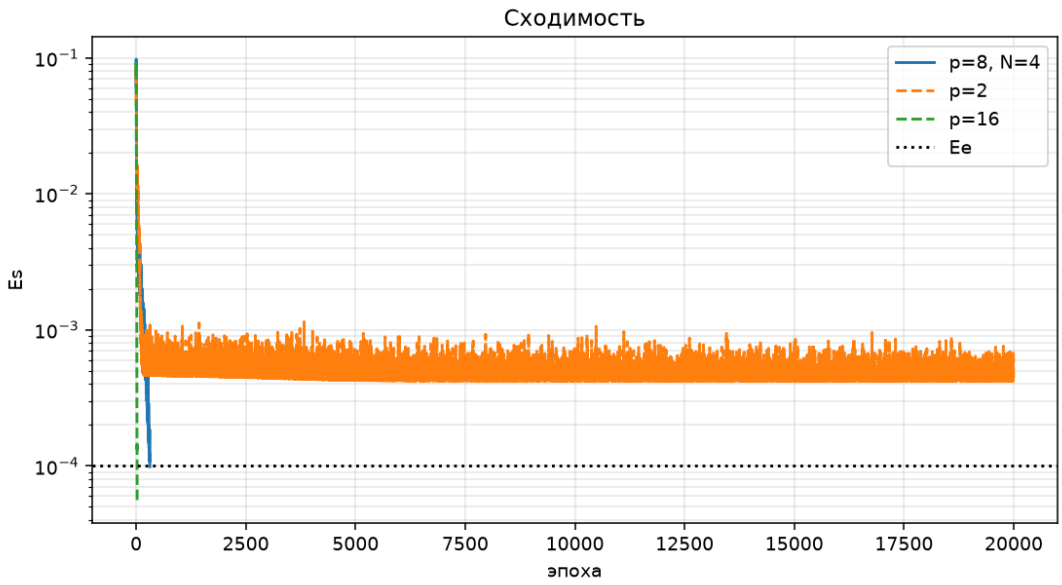
Введите номер k (8..199) или 8 чисел в исходной шкале: 0.3846 0.5382 0.9233 0.9327
0.9660 0.8795 0.7510 0.5945
нормализованные входы: [0.6943, 0.7616, 0.9303, 0.9344, 0.9490, 0.9111, 0.8548,
0.7862]
нормализованный прогноз: 0.7083
прогноз (ряд): 0.4165

Введите номер k (8..199) или 8 чисел в исходной шкале: q
графики сохранены в: c:\Users\User\Documents\lab4_mrzvis\figures
```

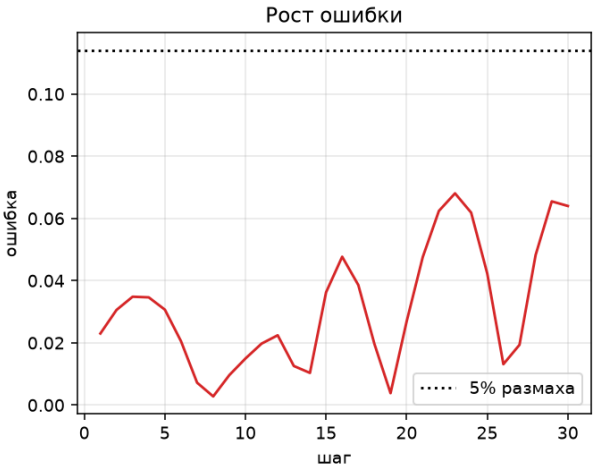
**Графики:**

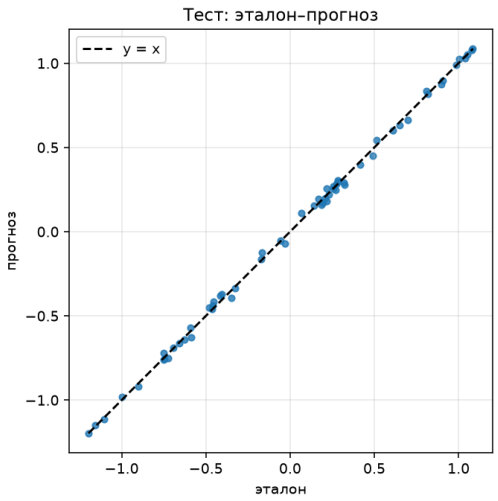

Ряд x(k)
x(k)
k
ряд
граница train/test


Ряд и одношаговый прогноз
x(k)
k
ряд
одношаговый прогноз
train/test

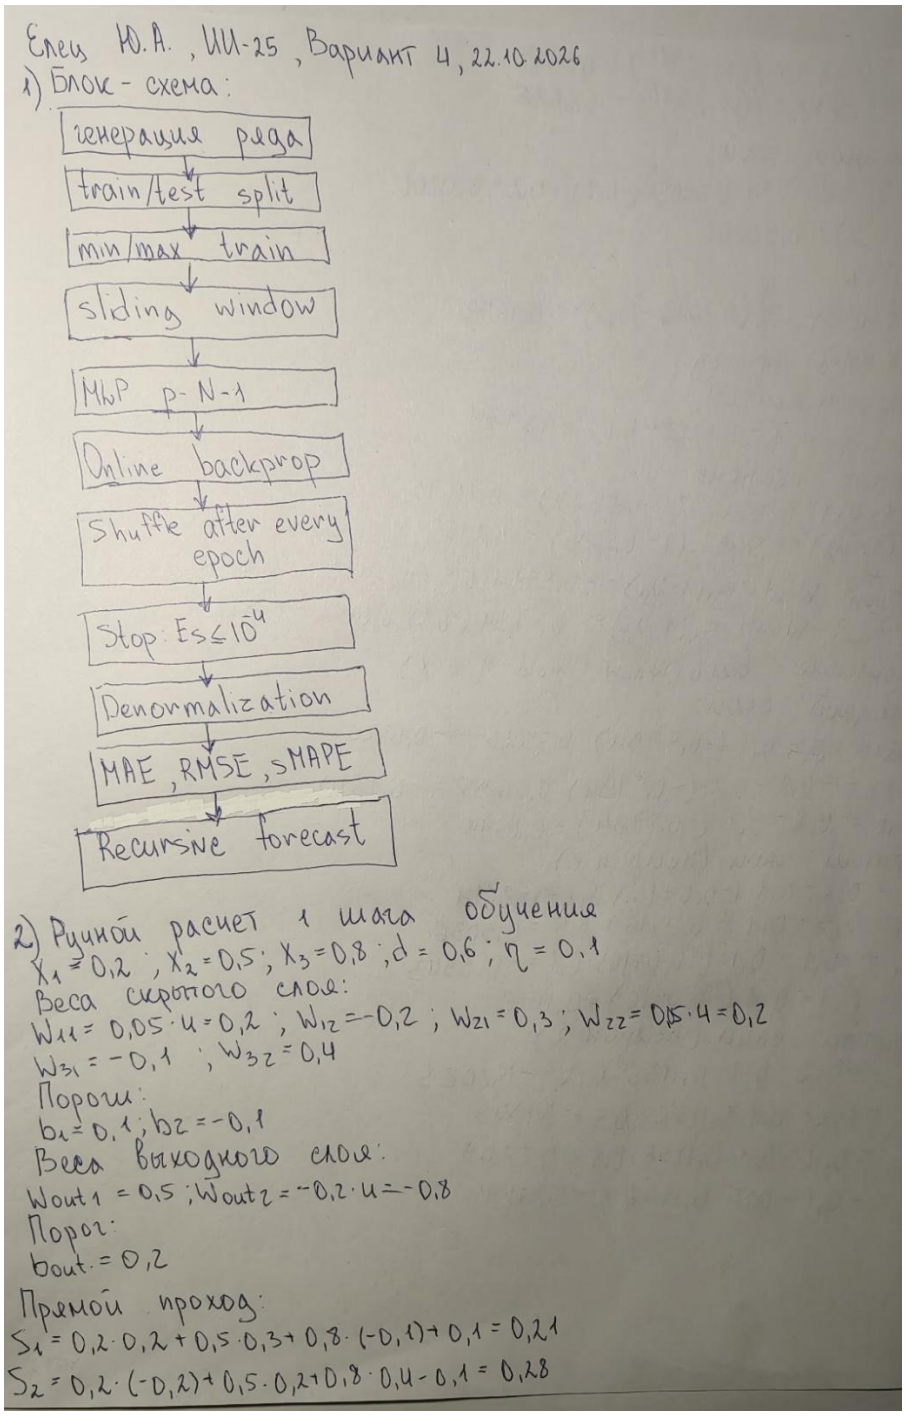

Сходимость
Es
эпоха
p=8, N=4
p=2
p=16
Ee

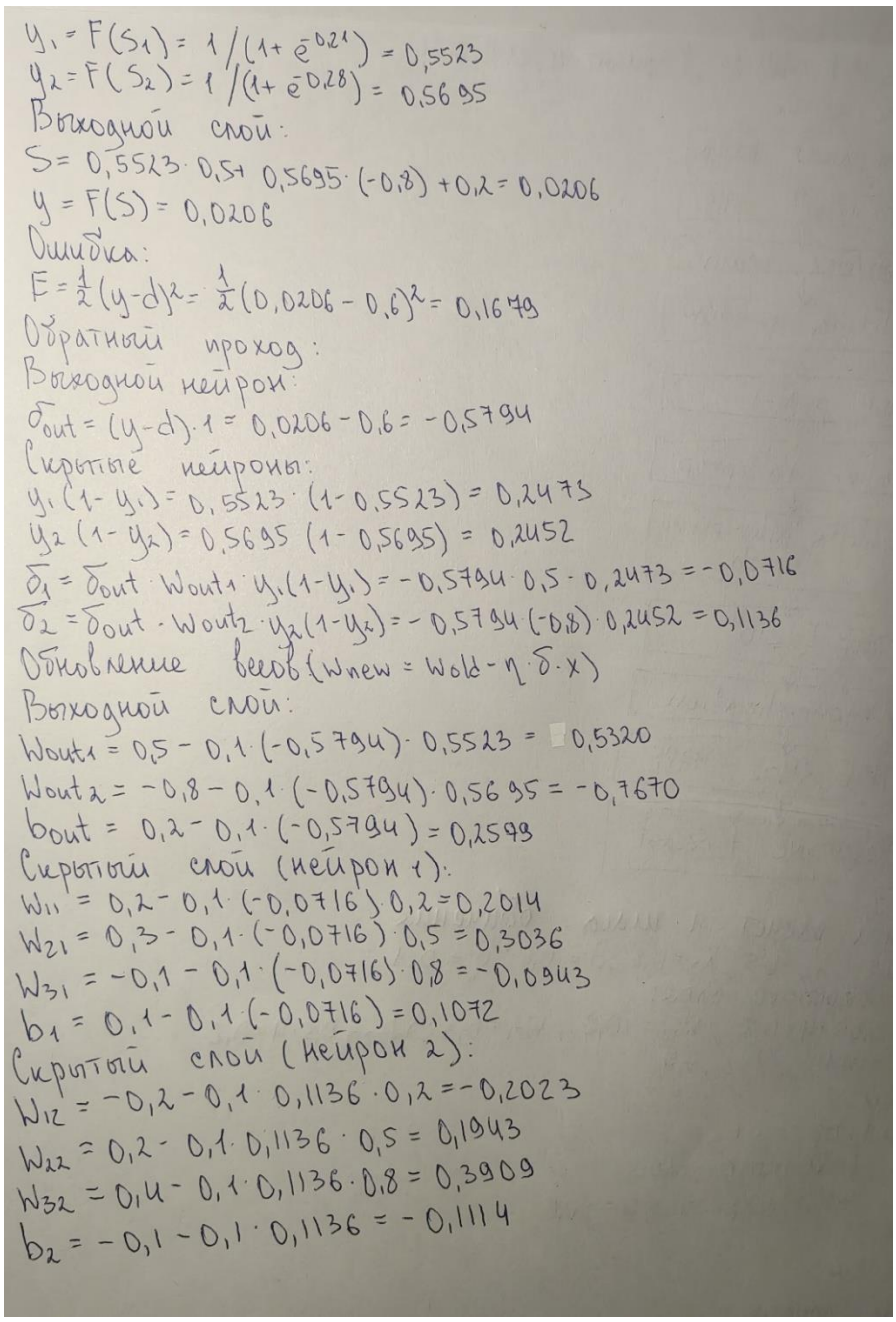

Рекурсивный прогноз на 30 шагов
x
шаг от k=140
эталон
рекурсия


Рост ошибки
ошибка
шаг
5% размаха


Тест: эталон–прогноз
y = x
прогноз
эталон
1.0
0.5
0.0
−0.5
−1.0
−1.0
−0.5
0.0
0.5
1.0

**Рукописи:**


Елец Ю.А., ИИ-25, Вариант 4, 22.10.2026
1) Блок-схема:
генерация ряда
train/test split
min/max train
sliding window
MLP p-N-1
Online backprop
Shuffle after every epoch
Stop: Es≤10^-4
Denormalization
MAE, RMSE, sMAPE
Recursive forecast
2) Ручной расчет 1 шага обучения
x1=0,2; x2=0,5; x3=0,8; d=0,6; η=0,1
Веса скрытого слоя:
w11=0,05·4=0,2; w12=-0,2; w21=0,3; w22=0,5·4=0,2
w31=-0,1; w32=0,4
Пороги:
b1=0,1; b2=-0,1
Веса выходного слоя:
wout1=0,5; wout2=-0,2·4=-0,8
Порог:
bout=0,2
Прямой проход:
S1=0,2·0,2+0,5·0,3+0,8·(-0,1)+0,1=0,21
S2=0,2·(-0,2)+0,5·0,2+0,8·0,4-0,1=0,28




**Вопросы:**

**1. Как размер окна p влияет на качество прогноза? При каком p ошибка перестаёт уменьшаться? Почему слишком маленькое окно (p = 2) не позволяет точно описать ряд из двух гармоник, а слишком большое не даёт выигрыша?**

С увеличением p точность растёт лишь до определённого момента. При p=2 модель ни разу не достигла критерия остановки (5 из 5 запусков провалились, MAE 0.0419), по двум точкам нельзя восстановить сумму двух гармоник. На p=4 ошибка уже 0.0182, но сходимость долгая (около 9300 эпох). Дальше p=8 даёт 0.0195, а p=16 – 0.0152. Существенного улучшения после p=8 не происходит, при этом параметров становится вдвое больше. Избыточно большое окно не помогает, потому что соседние входы сильно коррелируют и только усложняют обучение.

**2. Как число скрытых нейронов N влияет на точность и скорость обучения? Наблюдается ли переобучение (малая ошибка на обучении при заметно большей на тесте)? Достаточно ли минимального N, чтобы воспроизвести сумму двух гармоник?**

Минимального N=1 уже достаточно (MAE 0.0196), чтобы описать сумму двух гармоник. Оптимальным оказался N=4 (0.0195), а N=8 дал почти то же (0.0193). Признаков переобучения

не видно: ошибки на train и test практически совпадают. Число эпох обучения от N почти не зависит (304–338).

**3 Почему на выходе для задачи прогнозирования используется линейная функция, а не сигмоида (как в ЛР №3)? Что произошло бы при сигмоиде на выходе и при обучении на ненормализованных значениях?**

Решаемая задача – это регрессия и значения ряда лежат в [−1.1999; 1.0824], то есть вне интервала (0; 1). Сигмоида на выходе ограничила бы прогноз этим интервалом и не смогла бы выдать отрицательные значения. На ненормализованных данных она быстро насыщалась бы, градиент стремился к нулю и обучение остановилось, не достигнув критерия остановки.

**4. Почему нормализация должна опираться только на обучающий участок? К чему приводит выход тестовых значений за диапазон [0; 1] и как это проявляется на ваших данных?**

Считать min/max по всему ряду нельзя, так как тест «подсказывает» свои границы, это утечка данных. При нормировке по train тест может выйти за [0; 1], если его амплитуда больше. В данном варианте этого не случилось, но даже если бы вышло, то линейный выход спокойно бы это обработал (он экстраполирует), а сигмоида упёрлась бы в 0/1 и дала бы ошибку.

**5. Насколько устойчиво обучение к случайной инициализации весов (по сериям из 5 запусков)? Были ли запуски, не достигшие Ее за 20 000 эпох, и от чего это зависит (η, N, p)?**

Все конфигурации, кроме p=2, сошлись во всех 5 запусках (0 провалов), а разброс test MAE не превышает 0.0005. Единственные провалы (5 из 5) относятся к p=2 и причина не в инициализации, а в недостатке информации во входе: двух отсчётов мало для двух гармоник. От N и конкретных весов устойчивость почти не зависит, при η=0.1 обучение стабильно во всех остальных случаях.

**6. Как растёт ошибка рекурсивного многошагового прогноза с увеличением горизонта? Объясните накопление ошибки и сравните одношаговый прогноз с многошаговым. До какого горизонта прогноз можно считать пригодным?**

Одношаговый прогноз (MAE = 0.0152) точен, потому что на каждом шаге подаются реальные значения. В рекурсивном (MAE = 0.0313) каждое предсказание подставляется обратно в окно, и его ошибка накапливается. Порог 5% размаха (0.1141) за 30 шагов не превышен, ошибка колеблется в пределах 0.00–0.09. На данном ряде прогноз пригоден на всём горизонте 30 шагов.

**7. Как согласуется различие между ошибкой на обучающем и тестовом участках с понятием обобщающей способности? Какие меры (ранняя остановка, уменьшение N, добавление шума, увеличение обучающей выборки) могли бы улучшить обобщение? Что показал эксперимент с шумом?**

Разрыв между train и test MAE мал (0.0183 против 0.0196), поэтому обобщающая способность хорошая, переобучения нет. Меры для улучшения: ранняя остановка (уже реализована), уменьшение N (N = 4 оптимально), добавление шума (в работе не ставился) или увеличение выборки (140 точек маловато для p = 16). Эксперимент с шумом не проводился, но теоретически он снизил бы разрыв train/test, но немного увеличил бы MAE на чистых данных.

**Вывод:** в данной лабораторной работе я на основе многослойного персептрона p–N–1 решила задачу прогнозирования временного ряда, научилась формировать обучающую выборку методом скользящего окна, нормализовать данные, оценивать качество одношагового и многошагового прогноза и исследовать влияние размера окна p и числа нейронов скрытого слоя N на точность прогноза и скорость обучения.