

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №2

По дисциплине: «Модели решения задач в интеллектуальных системах»
Тема: «Многослойный персептрон для задачи «исключающее ИЛИ» с числовыми классами: сравнение функций потерь MSE и Binary Cross-Entropy»

Выполнил:
Студент 4 курса
Группы ИИ-25
Жук Б.Д.
Проверила:
Андренко К.В.

Цель работы: на основе многослойного персептрона архитектуры 2-2-1, реализованного в Лабораторной работе №1 для задачи XOR с числовыми классами c_0 и c_1 из диапазона $[-10; 10]$, реализовать альтернативную функцию потерь – бинарную кросс-энтропию (Binary Cross-Entropy, BCE) – и провести сравнительный анализ обучения сети с MSE (Лабораторная работа №1) и с BCE по скорости сходимости, качеству обучения и устойчивости к выбору начальных весов.

Задание:

- взять за основу код многослойного персептрона 2-2-1 из Лабораторной работы №1;
- поскольку BCE определена для выходов в диапазоне $(0; 1)$, а целевые значения в вашем варианте – произвольные числа c_0 и c_1 из диапазона $[-10; 10]$, реализовать нормализацию (масштабирование) целевых значений перед обучением и обратное преобразование выхода сети после обучения:
 - привести c_0 и c_1 к бинарным меткам 0 и 1;
 - обучать сеть на нормализованных целевых значениях с функцией потерь BCE;
 - при выводе результата преобразовывать выход сети $\hat{y} \in (0; 1)$ обратно в шкалу $[c_0; c_1]$.
- реализовать корректный градиент для связки BCE + сигмоида на выходном слое; для скрытого слоя градиент передаётся по стандартному правилу цепочки.
- обучить сеть на полной таблице истинности своего варианта (4 примера) в двух конфигурациях:
 - **конфигурация А (базовая, из ЛР №1):** MLP 2-2-1, функция потерь MSE, целевые значения – исходные c_0/c_1 , выходной слой – сигмоида. Результаты можно взять из отчёта по ЛР №1 или, при необходимости, повторить обучение с фиксацией всех метрик.
 - **конфигурация Б (новая):** MLP 2-2-1, функция потерь BCE, целевые значения – нормализованные $(0/1)$, с последующим пересчётом выхода в шкалу $[c_0; c_1]$.

Критерий остановки для обеих конфигураций одинаков – суммарная ошибка $E_s \leq E_e$ (используйте то же значение E_e , что и в ЛР №1, либо согласуйте новое значение отдельно для MSE и для BCE, поскольку это разные по своей природе величины – обоснуйте выбор в отчёте);

- для каждой конфигурации зафиксировать:
 - количество эпох до достижения критерия остановки (либо факт недостижения за максимально допустимое число эпох);
 - итоговую суммарную ошибку;
 - ассигасу на всех 4 примерах таблицы истинности;
 - среднюю абсолютную ошибку в исходной шкале $[c_0; c_1]$.
- провести не менее 5 запусков обучения для каждой конфигурации с разной случайной инициализацией весов (менять seed) и сравнить устойчивость сходимости: в скольких из 5 запусков сеть достигла критерия остановки, и какой разброс по числу эпох наблюдается;

- построить общий график зависимости суммарной ошибки от номера эпохи для конфигурации А (MSE) и конфигурации Б (BCE) на одних осях (для представительного запуска каждой конфигурации);
- реализовать блок визуализации результатов, включающий:
 - **график сходимости**– суммарная ошибка E_s от номера эпохи, конфигурации А и Б на одних осях, разными цветами/стилями линий, с обозначением порога E_e ;
 - **диаграмму разброса числа эпох по 5 запускам**(bar chart или scatter) для конфигурации А и конфигурации Б – наглядно показывающую устойчивость сходимости из п. 6 (например, столбики числа эпох для каждого из 5 seed, сгруппированные по конфигурации; запуски, не достигшие критерия останова, отметить отдельно, например штриховкой или отдельным цветом);
 - **визуализацию разделяющей поверхности скрытого слоя** – для представительного обученного экземпляра каждой конфигурации построить на плоскости (А, В) карту выходного значения сети (heatmap или contour plot) с наложенными точками обучающей выборки (4 примера таблицы истинности), закрашенными по истинному классу. Диапазон осей А и В – $[-10; 10]$ (весь допустимый диапазон входных значений). Для конфигурации Б цветовую шкалу можно строить как по нормализованному $\hat{y} \in (0; 1)$, так и по пересчитанному значению в шкале $[c_0; c_1]$ – выбрать более наглядный вариант и обосновать выбор;
 - **диаграмму сравнения точности восстановления шкалы**– столбчатую диаграмму средней абсолютной ошибки для конфигурации А и конфигурации Б, чтобы наглядно сопоставить точность регрессии к исходной шкале $[c_0; c_1]$.

Каждый график должен иметь подписанные оси, заголовок и легенду (где применимо). Разделяющую поверхность и графики точности рекомендуется разместить рядом (например, subplot 2×2 или отдельными рисунками) для удобства сравнения в отчёте;

- реализовать режим функционирования сети: пользователь вводит пару чисел (А, В) из диапазона $[-10; 10]$ (не обязательно совпадающих с c_0 и c_1). Сеть должна выводить:
 - выход в нормализованной шкале $\hat{y} \in (0; 1)$ (с точностью до 4 знаков);
 - выход, пересчитанный в исходную шкалу $[c_0; c_1]$ по формуле из п. 2;
 - к какому классу (c_0 или c_1) ближе полученное значение.

Продемонстрировать работу режима функционирования на всех 4 примерах исходной таблицы истинности и не менее чем на 2–3 дополнительных парах (А, В), не входящих в обучающую выборку.

Вариант 5 ($c_0 = 1, c_1 = 8$)

А	В	$A \oplus B$
1	1	1
1	8	8
8	1	8
8	8	1

Изменения в архитектуре и алгоритме относительно ЛР1:

Архитектура сети (2-2-1, сигмоида на всех слоях) не менялась. Изменения – только в целевой функции и, дополнительно, во входной нормализации:

Нормализация целей (как и в ЛР1, поскольку сигмоида на выходе ограничена (0;1) и не может выдать -9 или 6):

$$y_{norm} = \frac{y - c_0}{c_1 - c_0}$$

Обратный пересчёт после обучения:

$$y = y_{norm} \cdot (c_1 - c_0) + c_0$$

Вывод градиента для связки ВСЕ + сигмоида (выходной слой):

Потери для одного примера:

$$L = -y \ln p - (1 - y) \ln(1 - p), \quad p = \sigma(z) = out$$

Цепное правило:

$$\frac{\partial L}{\partial z} = \frac{\partial L}{\partial p} \cdot \frac{\partial p}{\partial z}$$

где

$$\frac{\partial L}{\partial p} = -\frac{y}{p} + \frac{1-y}{1-p}, \quad \frac{\partial p}{\partial z} = p(1-p)$$

Подставляем и сокращаем:

$$\frac{\partial L}{\partial z} = \left(-\frac{y}{p} + \frac{1-y}{1-p} \right) p(1-p) = -y(1-p) + (1-y)p = p - y$$

Итог:

$$\delta_{out} = out - y$$

Градиент для скрытого слоя:

$$\delta_h = (\delta_{out} W_2^T) \odot h(1-h)$$

Результаты обучения (5 запусков, разные seed):

```
MSE:
Seed 1: эпохи = 34121, ошибка = 0.001000, accuracy = 100.00%, MAE = 0.155758
Seed 2: эпохи = 33210, ошибка = 0.001000, accuracy = 100.00%, MAE = 0.156262
Seed 3: эпохи = 32749, ошибка = 0.001000, accuracy = 100.00%, MAE = 0.156256
Seed 4: эпохи = 32317, ошибка = 0.001000, accuracy = 100.00%, MAE = 0.156268
Seed 5: эпохи = 32686, ошибка = 0.001000, accuracy = 100.00%, MAE = 0.156223

BCE:
Seed 1: эпохи = 47851, ошибка = 0.001000, accuracy = 100.00%, MAE = 0.003499
Seed 2: эпохи = 88292, ошибка = 0.001000, accuracy = 100.00%, MAE = 0.003499
Seed 3: эпохи = 48941, ошибка = 0.001000, accuracy = 100.00%, MAE = 0.003499
Seed 4: эпохи = 47518, ошибка = 0.001000, accuracy = 100.00%, MAE = 0.003499
Seed 5: эпохи = 47382, ошибка = 0.001000, accuracy = 100.00%, MAE = 0.003499
```

Сравнение на одном seed=4:

MSE:

```
Seed: 1
Эпох: 34121
Ошибка: 0.00099997
Accuracy: 100.00%
MAE: 0.155758
```

BCE:

```
Seed: 1
Эпох: 47851
Ошибка: 0.00100000
Accuracy: 100.00%
MAE: 0.003499
```

Блок визуализации:

График сходимости:





Диаграмма числа эпох по 5 запускам:



Разделяющая поверхность:






Диаграмма MAE:



```
Режим функционирования MSE
Введите A и B из диапазона [-10; 10].
Для выхода введите q.
A = 1
B = 8
y = 7,854434768293977
Ближайший класс: c1 (8)
A = 8
B = 8
y = 1,1403649800693212
Ближайший класс: c0 (1)
A = 8
B = 1
y = 7,819460093173622
Ближайший класс: c1 (8)
A = 1
B = 1
y = 1,1565187076668142
Ближайший класс: c0 (1)
```

```
Режим функционирования BCE
Введите A и B из диапазона [-10; 10].
Для выхода введите q.
A = 1
B = 8
y = 7,99688937540878
Ближайший класс: c1 (8)
A = 8
B = 8
y = 1,0029382427997025
Ближайший класс: c0 (1)
A = 8
B = 1
y = 7,99537609311962
Ближайший класс: c1 (8)
A = 1
B = 1
y = 1,0033226829078525
Ближайший класс: c0 (1)
```

Вопросы:

1. Какая функция потерь дала более быструю/устойчивую сходимость?

Одинаково. Это не согласуется с теоретическим преимуществом BCE: градиент связки BCE+сигмоида равен просто $(out - y)$ и не гаснет при насыщении выхода, тогда как у MSE градиент содержит множитель $out(1 - out)$, который стремится к нулю при насыщении сигмоиды – отсюда более медленное и менее надёжное обучение (эффект «исчезающего градиента»).

2. Как нормализация целей повлияла на обучение по сравнению с обучением на «сырых» числах $[-10; 10]$?

Напрямую на c0/c1 без нормализации обучение с сигмоидой на выходе вообще невозможно: сигмоида ограничена $(0; 1)$ и никогда не выдаст 1 или 8, поэтому суммарная ошибка застревает на уровне сотен и критерий $E_e = 0.001$ недостижим в принципе. Нормализация – не опция, а обязательное условие корректной работы сигмоидного выхода.

3. Точность восстановления шкалы [c0; c1]: MSE vs BCE, есть ли компромисс?

MAE у BCE (~ 0.037) на два порядка меньше, чем у MSE (~ 0.155). Компромисса не обнаружено: BCE выигрывает и по устойчивости классификации, и по точности регрессии к исходной шкале, поскольку логистическая ошибка сильнее «выталкивает» выход к 0/1, а после денормализации это даёт значения, очень близкие к истинным c0/c1.

4. Устойчивость к случайной инициализации весов?

MSE – устойчива: все 5 запусков сошлись с примерно одинаковым числом эпох. BCE – неустойчива: все 5 запусков сошлись к $E_e = 0.001$ с сильно отличающимся числом эпох (разброс около 40000 эпох).

5. Подтвердилось ли наблюдение о линейной неразделимости XOR независимо от числовых меток?

Да, полностью: та же архитектура 2-2-1 со скрытым слоем успешно решает задачу для c0=1/c1=8, как и для классического 0/1 в ЛР1 – линейная неразделимость определяется структурой данных XOR, а не конкретными значениями меток классов.

6. Как выбор функции потерь соотносится с необходимостью скрытого слоя?

Никак не влияет на этот вывод – он определяется исключительно архитектурой. И MSE, и BCE обучались на одной и той же сети со скрытым слоем; функция потерь меняет лишь скорость и устойчивость сходимости, но не принципиальную возможность разделить линейно неразделимые данные – это обеспечивает только наличие скрытого слоя.

7. Что показывает визуализация разделяющей поверхности?

Граница у обеих конфигураций – две параллельные диагональные линии, отделяющие $(1, 1)/(8, 8)$ от $(1, 8)/(8, 1)$, что соответствует ожидаемой для XOR форме (пересечение двух полуплоскостей скрытого слоя).

Вывод: реализовал альтернативную функцию потерь – бинарную кросс-энтропию (Binary Cross-Entropy, BCE) – и провёл сравнительный анализ обучения сети с MSE и с BCE по скорости сходимости, качеству обучения и устойчивости к выбору начальных весов.